

# Pronóstico fotovoltaico a corto plazo bajo escasez de datos mediante evaluación *Leave-One-Plant-Out* Un enfoque *Cross-Site* multi-planta frente a modelos locales

César David Aular Muñoz   Sergio Hernández

Departamento de Computación e Industrias  
Facultad de Ciencias de la Ingeniería  
Universidad Católica del Maule

Chilean Workshop on Pattern Recognition (CWPR) — 2026



# Agenda

- ① El problema
- ② Metodología
- ③ Resultados
- ④ Conclusiones


- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones

# El problema del *Cold-Start* fotovoltaico

- Una planta FV **recién conectada** no tiene historial de generación.
- Los modelos clásicos entrenan **uno por planta** con meses o años de datos locales.
- Aplicados a una planta nueva: **no se pueden entrenar** o se degradan gravemente.

## Consecuencia

Incertidumbre justo cuando más se necesita certeza  
→ mayores costos de balance y riesgo financiero, en especial para los pequeños PMGD.



El problema del arranque en frío, tomado de los sistemas de recomendación.

# La idea: aprendizaje *Cross-Site*

Abandonar el supuesto **un-modelo-por-planta**.


Un único modelo **global** entrenado sobre **muchas plantas a la vez**:

- absorbe patrones compartidos clima  $\rightarrow$  potencia,
- los **transfiere** a una planta jamás vista,
- pronostica **desde la primera hora** de conexión.

**Pregunta central (adversarial):**

*¿realmente supera a una línea base local madura, o el premio de la transferencia se desvanece con una comparación justa?*

Transferencia Cross-Site: pre-entrenamiento multi-planta e inferencia sobre una planta sin historia



# Hipótesis y objetivos

## Hipótesis

El modelo global multi-sitio es *más preciso* que un modelo entrenado localmente con la historia propia del centro.

## Objetivos específicos

- 1 Adaptar una arquitectura Transformer al entrenamiento multi-serie.
- 2 Evaluarla frente a modelos locales bajo un protocolo *Cold-Start* estricto.
- 3 Integrar datos multimodales sin fuga de información.

## La brecha en la literatura


Rara vez se combinan a la vez:

- 1 evaluación **ciega** a la planta objetivo (sin *fine-tuning*),
- 2 contraste **justo** contra locales maduros,
- 3 caracterización **probabilística**.

- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones

# Arquitectura del sistema

Arquitectura de componentes del sistema y stack tecnológico



*Persistencia en capas Medallion (todo Parquet): `landing` → `bronze` → `silver` → `gold` → `results` /*

# Protocolo *Leave-One-Plant-Out* (LOPO)

- Para cada planta objetivo: los globales entrenan con las  $N - 1$  **restantes** (2014–2024 completo).
- La planta objetivo es **invisible** durante el entrenamiento.
- Métricas: **mediana** sobre 94 plantas, solo observaciones reales.

Validación *Leave-One-Plant-Out*: la planta objetivo es invisible durante el entrenamiento global



## Integridad Zero-Shot (no negociable)

Ninguna variable puede ser función de la generación del objetivo. Verificado por pruebas automatizadas.

# La lección de la fuga de datos

Un *prior* de eficiencia calculado **por-fila** desde el objetivo

$$PR = \frac{y}{\text{capacidad}} \implies \text{corr}(PR, y) = 1,0$$

rRMSE falso

≈ 0,8 % (demasiado bueno para ser verdad)

rRMSE honesto (tras corregir)

≈ 56 %

El *prior* regional se agrega **solo sobre las plantas de entrenamiento** (por macrozona y estación).


# Semilla *Cold-Start* sintética

Los modelos profundos necesitan una ventana de contexto que la planta nueva no tiene. Se siembra sintéticamente:

$$\hat{y}_{\text{seed}}(t) = \text{capacidad} \cdot PR_{\text{regional}} \cdot s(t)$$

- $s(t)$ : perfil solar determinista;  $PR_{\text{regional}}$ : solo plantas de entrenamiento.
- Solo el clima exógeno (conocido/pronosticable) y la geografía estática usan valores reales del objetivo.
- La generación de contexto es **100% sintética** → cero fuga.

Protocolo de evaluación Cold-Start: contexto sintético, horizontes y ventanas de sensibilidad



Inicio de la ventana (análisis de sensibilidad):

- Raw: primera hora registrada (incluye rampa de puesta en marcha)
- Operacional: primera producción sostenida
- Estacionales: primera ventana sostenida que inicia en Verano / Otoño / Invierno / Primavera (historia posterior de la misma planta)

# Ocho configuraciones y ventanas de evaluación


## 5 globales (Cross-Site)

- TFT, Informer, N-HiTS, LSTM
- XGBoost global

## 3 locales (estrictas)

- XGBoost, LSTM, N-HiTS
- entrenados solo con la historia propia


**Horizontes:** *day1* (24 h) y *rollout7d* (7 días autorregresivos).



**Raw** (incluye rampa) · **Operacional** (producción sostenida) · **Estacionales**.

# ¿Dónde están las plantas? El corpus sobre el mapa

Ubicación de las plantas evaluadas  
(87 de 94 georreferenciadas · área  $\propto$  capacidad instalada)



- **94 plantas** del Sistema Eléctrico Nacional, a lo largo de todo el gradiente solar de Chile (Arica  $\rightarrow$  zona sur).
- **Norte Grande y Norte Chico**: pocas plantas pero **grandes** (utility scale, hasta 200 MW) y de alta irradiancia.
- **Zona Central**: muchas plantas **pequeñas** (PMGD, mediana  $\approx$  3 MW) — el segmento que más sufre el arranque en frío.


## Por qué importa para la transferencia

La **macrozona** es la única señal espacial que ven los modelos, y es la clave sobre la que se agrega el *prior* regional que siembra el contexto sintético.

- 1 El problema
- 2 Metodología
- 3 Resultados**
- 4 Conclusiones

# Precisión puntual — ventana *cold-start*, 94 plantas (roll-out 7 días)


| Config.  | Tipo   | NRMSE  | rRMSE |
|----------|--------|--------|-------|
| XGBoost  | Local  | 13,2 % | 60 %  |
| XGBoost  | Global | 17,1 % | 75 %  |
| N-HiTS   | Local  | 17,6 % | 85 %  |
| Informer | Global | 22,8 % | 107 % |
| TFT      | Global | 23,6 % | 113 % |
| LSTM     | Local  | 23,9 % | 129 % |
| LSTM     | Global | 24,8 % | 109 % |
| N-HiTS   | Global | 30,7 % | 148 % |



NRMSE = RMSE / capacidad instalada. **94 plantas**.

El **XGBoost local** es el más preciso (13 % de la potencia nominal). Normalizar por **capacidad** hace los números interpretables —y cambia el orden del par LSTM respecto de rRMSE.

# Sensibilidad estacional: el invierno es el gran desafío



## rRMSE roll-out por estación

- XGBoost global: 52 % (verano) → **134 %** (invierno)
- XGBoost local: 40 % → **115 %**

Mayor variabilidad nubosa y menor irradiación invernal debilitan la señal determinista del perfil solar.

**Implicación operativa:** la incertidumbre de un parque nuevo depende fuertemente de la **estación de su puesta en marcha.**

# Calidad probabilística: la calibración no se transfiere

| Config.  | Tipo          | Cobertura diaria   | Pinball P95 (MWh) |
|----------|---------------|--------------------|-------------------|
| XGBoost  | <b>Local</b>  | <b>0,86</b>        | <b>0,035</b>      |
| XGBoost  | <b>Global</b> | 0,97 (sobre-cubre) | 0,092             |
| LSTM     | <b>Global</b> | 0,53               | 0,159             |
| Informer | <b>Global</b> | 0,64               | 0,115             |
| TFT      | <b>Global</b> | 0,38               | 0,158             |
| N-HiTS   | <b>Global</b> | 0,37               | 0,372             |

- Nominal = 0,90. **Ningún paradigma calibra idealmente**, con desvíos opuestos.
- Redes globales **subcalibradas** (bandas demasiado estrechas); XGBoost global **sobre-cubre**.
- **XGBoost local** es el más cercano al nominal y con menor pinball.

## Contraste de la hipótesis — con test estadístico

La hipótesis se **RECHAZA**, y ahora con significancia

**XGBoost local** gana a **XGBoost global** en **77 de 94 plantas** ( $p < 10^{-7}$ , Wilcoxon pareado con corrección de Holm).


A igualdad de arquitectura: ningún global gana significativamente

- **N-HiTS local** supera a **N-HiTS global** en **88/94** ( $p < 10^{-10}$ ).
- El par **LSTM** es un **empate estadístico**: 49/45 plantas,  $p = 1,00$ . El matiz que sugerían las medianas **no sobrevive** al test pareado.

El valor real: disponibilidad inmediata

En el arranque en frío puro (historia local nula) el modelo global **no tiene competidor local posible**.

## Ejemplo de roll-out Cold-Start a 7 días



El modelo global, **sin haber visto jamás la planta**, reproduce el ciclo diario y la magnitud de los picos usando solo el clima entrante y la geografía estática.

- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones**

# Conclusiones

- ① **Resultado negativo riguroso:** bajo un protocolo estrictamente ciego, un XGBoost local maduro sigue siendo el estándar a batir. La hipótesis se rechaza.
- ② **El paradigma global conserva un régimen propio:** el arranque en frío puro, donde entrega pronósticos coherentes y accionables desde la hora cero.
- ③ Cuatro hallazgos metodológicos transferibles:
  - las rampas de puesta en marcha distorsionan las métricas (análisis Raw/Operacional);
  - el invierno es sistemáticamente la estación más difícil;
  - la calibración probabilística no se transfiere a las redes profundas;
  - la integridad del *target* (nunca imputar *y*) es esencial para la honestidad de las métricas.

## Trabajo futuro

- **Fine-tuning en dos etapas:** pre-entrenar global → ajustar con los primeros días reales; cierra la brecha con el local a medida que crece la historia.
- **Máscaras de intermitencia** en la atención: excluir la noche determinista y concentrar capacidad en la señal productiva.
- **Recalibración conformal** de los intervalos bajo transferencia.
- **Más datos y cómputo:** ampliar el corpus y el presupuesto de pasos (posible sub-entrenamiento de TFT/Informer en 6 GB).
- **Máscara astronómica** para el forzamiento nocturno independiente de sensores.

# Gracias

¿Preguntas?



César David Aular Muñoz · Sergio Hernández  
cesaraular02@gmail.com · Universidad Católica del Maule

## Backup — Tests estadísticos (Friedman + Wilcoxon-Holm)

**Diseño pareado y balanceado:** 94 plantas  $\times$  8 configuraciones sobre la misma grilla horaria canónica  $\rightarrow$  aplica la comparación por rangos de Demšar (2006).

- **Friedman (omnibus):**  $\chi^2 = 260,7$ ,  $p < 10^{-50}$  — las configuraciones no son equivalentes.
- **Ranking medio** (1 = mejor): XGB local 1,80 · N-HiTS local 3,32 · XGB global 3,34 · TFT 5,10 · Informer 5,15 · LSTM local 5,30 · LSTM global 5,41 · N-HiTS global 6,59.
- **Mejor por planta:** XGB local en 60/94, XGB global en 15, N-HiTS local en 10.

### Por qué la mediana marginal engañaba

rRMSE mediano sugería **LSTM global** (118 %) mejor que **LSTM local** (147 %). Pero la **mediana de las diferencias por planta** es  $\approx 0$  y levemente a favor del local: la brecha la producían unas pocas plantas donde el local falla mucho, no una ventaja sistemática del global.

## Backup — Causalidad temporal de los baselines locales

### Qué se hizo exactamente

Los baselines locales se entrenan con la historia **completa** de la planta **menos todas las ventanas de evaluación** (Raw, Operacional y las 4 estacionales), con los *lags* hacia esas ventanas enmascarados.

- No hay fuga del *target*: ningún rezago apunta dentro de una ventana.
- Pero el entrenamiento **sí incluye horas posteriores** a la ventana predicha → **no es estrictamente causal**.
- Es una elección de diseño: representa el modelo maduro que el operador tendría *tras acumular historia* — el rival más fuerte posible.

### Por qué esto refuerza la conclusión

El sesgo favorece al lado **local**, que **gana**; y el espejo (LOPO oculta la planta pero **no el calendario**) favorece al lado **global**, que **pierde igual**. Ambos sesgos empujan contra la conclusión reportada.

### Fórmula

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- Eleva al **cuadrado** cada error antes de promediar → penaliza las desviaciones grandes de forma **cuadrática**, no lineal ni logarítmica.
- Ideal para el pronóstico FV: castiga con fuerza los errores en los **picos de inyección** de mediodía.
- Comparte unidades con la variable (MWh), a diferencia del MSE.
- **rRMSE** = RMSE normalizado por la generación media horaria de la ventana (ver backup siguiente).

## Backup — ¿Por qué el rRMSE supera el 100 %?

$$\text{rRMSE} = \frac{\text{RMSE}}{\bar{y}_{\text{ventana}}} \times 100$$

- El denominador  $\bar{y}$  incluye las **horas nocturnas de generación nula**.
- Esto **deprime la media** y por tanto **infla** sistemáticamente el indicador.
- Valores  $> 100\%$  son **esperables** en pronóstico horario FV bajo esta normalización.
- Su valor no es la magnitud absoluta, sino la **comparación relativa** entre arquitecturas sobre **ventanas idénticas**.

Todas las configuraciones se comparan sobre la misma grilla horaria canónica → comparación estrictamente pareada.

## Backup — Calibración de XGBoost (global vs. local)

### XGBoost global: 0,97 (sobre-cubre)

- Regresión cuantílica sobre un contexto **heterogéneo** ( $N - 1$  plantas).
- Bandas **demasiado anchas**: casi nunca fallan, pero pierden utilidad operativa.
- Un defecto **simétrico** al de las redes, no una virtud.

### XGBoost local: 0,86 (casi nominal)

- Ajustado a la variabilidad **real** de la propia planta.
- Pinball P95 = **0,035** MWh vs. 0,092 del global.
- Intervalos más estrechos y **mejor centrados**.

### ¿Por qué las redes profundas subcalibran?

Su escalador local se ajusta sobre el **contexto sintético**, cuya varianza (perfil solar idealizado) es menor que la real  $\rightarrow$  bandas estrechas. Los baselines locales profundos, con contexto real, mejoran (LSTM local 0,79).

- **Precisión fp32** completa: la mezcla fp16 introducía inestabilidad numérica en el entrenamiento.
- **GPU RTX 2060 (6 GB)**: la VRAM la gobierna  $\text{batch\_size} \times \text{windows\_batch\_size}$ , no el tamaño del corpus  $\rightarrow$  no se trunca la historia.
- **Presupuesto por época corregido**: cada paso consume  $\text{batch} \times \text{windows\_batch}$  ventanas; la fórmula ingenua  $\text{filas}/\text{batch}$  sobreestimaba  $\sim 250\times$ .
- **Early stopping** sobre  $\text{val\_size}=168$ ; tuning cacheado una vez por modelo y reusado entre folds (fuga a nivel de hiperparámetro: despreciable y documentada).
- Toda predicción se fuerza a  $\hat{y} \geq 0$  y a cero de noche (consistencia física).

## Backup — Tabla completa (day1 y roll-out)

| Config.  | Tipo   | NRMSE (% cap.) |        | rRMSE (%) |        | Cob. | Pinball |
|----------|--------|----------------|--------|-----------|--------|------|---------|
|          |        | day1           | roll7d | day1      | roll7d |      |         |
| XGBoost  | Local  | 9,5            | 13,2   | 45,6      | 59,9   | 0,86 | 0,035   |
| XGBoost  | Global | 15,6           | 17,1   | 64,0      | 75,1   | 0,97 | 0,092   |
| N-HiTS   | Local  | 14,2           | 17,6   | 62,3      | 85,2   | 0,72 | 0,096   |
| Informer | Global | 21,0           | 22,8   | 96,6      | 106,5  | 0,64 | 0,115   |
| TFT      | Global | 22,0           | 23,6   | 105,1     | 112,7  | 0,38 | 0,158   |
| LSTM     | Local  | 16,3           | 23,9   | 102,6     | 128,8  | 0,72 | 0,235   |
| LSTM     | Global | 22,6           | 24,8   | 99,7      | 108,6  | 0,53 | 0,159   |
| N-HiTS   | Global | 28,6           | 30,7   | 129,8     | 148,2  | 0,37 | 0,372   |

Ventana *cold-start*, mediana sobre las **94 plantas** (Operacional donde hay rampa  $>24$  h; Raw en el resto).