



Proyecto de Título – Anteproyecto

Análisis comparativo de un enfoque multi-sitio frente a modelos locales para la proyección a corto plazo de generación fotovoltaica bajo escasez de datos.

Nombre Estudiante: César David Aular Muñoz
Rut Estudiante: 26.271.734-8
Año de Ingreso: 2026
Carrera: Ingeniería Civil Informática
Email Institucional: cesar.aular@alumnos.ucm.cl
Teléfono: +569 951 666 48
Actividad Curricular: INF613 – Módulo Integrador de Formación Profesional
Académico/a: Dr. Sergio Hernández Álvarez



Índice de Contenidos

Introducción	3
1. Problemática	4
2. Cliente y/o Público objetivo	4
3. Carta de Compromiso	5
4. Propuesta de Solución	6
5. Objetivos	7
5.1. Objetivo General	7
5.2. Objetivos Específicos	7
6. Alcance del Proyecto	8
7. Planificación del proyecto	9

Introducción

En las últimas décadas, la energía solar ha cobrado una gran relevancia, llegando a representar una parte sustancial de la generación de energía renovable a nivel mundial gracias a los avances en las tecnologías fotovoltaicas y a la creciente demanda energética. La expansión de la infraestructura de energía solar es un pilar fundamental para la electrificación, la transición energética global y el cumplimiento de los compromisos de cero emisiones netas para mitigar los efectos del cambio climático. Sin embargo, la generación fotovoltaica está sujeta a una alta variabilidad e intermitencia, ya que depende directamente de factores meteorológicos dinámicos como la Irradiancia Horizontal Global (GHI), la temperatura, la nubosidad y la velocidad del viento. Por lo tanto, la estimación precisa de la productividad en plantas de energía renovable es un desafío crítico para la planificación, operación y optimización de los sistemas energéticos de la red.

Tradicionalmente, los modelos predictivos de generación solar se han abordado mediante técnicas estadísticas y algoritmos clásicos que se entrenan de manera local utilizando los datos históricos específicos de cada planta. Este enfoque presenta dos limitaciones fundamentales. En primer lugar, dependen fuertemente de la disponibilidad de un volumen considerable de datos históricos locales, lo cual dificulta enormemente su aplicación en escenarios de puesta en marcha de nuevas instalaciones (el problema de **cold-start** o arranque en frío). En segundo lugar, omiten el aprovechamiento de los patrones meteorológicos y operativos que son compartidos entre distintas plantas y regiones climáticas, los cuales poseen un alto valor para mejorar la capacidad predictiva y la generalización de los modelos.

Para superar estas barreras de disponibilidad de datos, la investigación reciente ha comenzado a integrar técnicas avanzadas de Deep Learning, donde arquitecturas como los Transformers (ej. Temporal Fusion Transformer, Informer o PatchTST) han demostrado una capacidad superior para procesar secuencias largas y extraer dependencias temporales complejas a partir de datos meteorológicos multivariados. Complementariamente, el uso de enfoques de **Transfer Learning** (aprendizaje por transferencia) permite que un modelo pre-entrenado a partir de bases de datos a gran escala y de múltiples regiones transfiera características y patrones climáticos generales hacia instalaciones locales con escasez de datos.

El presente proyecto busca abordar el problema del **cold-start** a través del desarrollo y validación de una arquitectura de **Cross-Site Learning** (aprendizaje multi-sitio). Mediante el uso de un modelo Transformer de estado del arte, el proceso de entrenamiento se adaptará para aprender simultáneamente de múltiples series temporales de distintas plantas solares, integrando variables exógenas dinámicas (clima) y características estáticas (ubicación geográfica).

El desarrollo de este proyecto aporta valor empírico y metodológico en dos frentes principales. En primer lugar, proporciona una herramienta validada para la industria, permitiendo a los operadores estimar con mayor precisión la producción de nuevos parques solares desde sus etapas iniciales sin depender de recolecciones de datos locales prolongadas. En segundo lugar, aporta evidencia sólida sobre la eficacia de aplicar técnicas de **Transfer Learning** y arquitecturas Transformer en series de tiempo energéticas, estableciendo un marco de evaluación riguroso frente a modelos tradicionales de Machine Learning (como XGBoost o LSTM) entrenados de manera estrictamente local.

Desarrollo

1. Problemática

La transición hacia una matriz energética sostenible ha impulsado una expansión acelerada de proyectos fotovoltaicos. Tal como indica la Comisión Nacional de Energía (2026), el 75 % de los 5.333 MW de nueva capacidad eléctrica actualmente en etapa de construcción en el país corresponde a parques solares. Sin embargo, esta inyección masiva de energía choca con una barrera crítica para la toma de decisiones: la escasez de datos meteorológicos y operativos durante las etapas iniciales de un proyecto. Para generar proyecciones confiables y superar el problema del *Cold-Start*, los algoritmos predictivos tradicionales —entrenados de manera aislada para cada instalación— requieren de un mínimo de un año ininterrumpido de registros locales (Zhaoyang Zhu, 2023). Esto fomenta un profundo aislamiento del aprendizaje técnico, impidiendo que el conocimiento atmosférico generalizado (*enfoque Multi-Sitio*) se transfiera, lo que condena a los nuevos actores del mercado a operar con altos niveles de incertidumbre algorítmica desde su puesta en marcha.

Esta falta de predictibilidad a corto plazo desencadena severas ineficiencias operativas y un alto riesgo financiero a lo largo de la red. A nivel sistémico, Coordinador Eléctrico Nacional (2025) reporta que las imprecisiones en los pronósticos de inyección renovable han introducido un error financiero del 4,62 % sobre la estimación de los costos operativos totales del Sistema Eléctrico Nacional. Más grave aún, la incapacidad de anticipar con exactitud la generación exacerba los cuellos de botella en la transmisión, derivando en niveles críticos de vertimiento de energía limpia (*curtailment*). Durante 2025, el vertimiento físico alcanzó los 6.084 GWh (Asociación Chilena de Energías Renovables y Almacenamiento (ACERA), 2025), lo que se ha traducido en pérdidas de ingresos para las generadoras equivalentes a 562 millones de dólares acumulados en los últimos tres años (Ember, 2025). Finalmente, en el ecosistema a menor escala, esta incertidumbre algorítmica expone directamente a los Pequeños Medios de Generación Distribuida (PMGD) a un riesgo de mermas financieras estimado en hasta 7.400 millones de dólares anuales ante la falta de certeza horaria en sus esquemas de inyección (Energía Estratégica, 2025).

2. Cliente y/o Público objetivo

El público objetivo y los principales beneficiarios de esta solución abarcan un espectro amplio dentro del ecosistema de generación de energía renovable. En primer lugar, la herramienta se orienta a operadores, administradores de parques solares a gran escala y coordinadores de redes eléctricas, quienes requieren sistemas predictivos robustos para minimizar la incertidumbre en la toma de decisiones, optimizando la planificación energética y reduciendo el riesgo financiero ante desvíos en el despacho durante las etapas iniciales de una planta.

En segundo lugar, esta propuesta integra a los actores del segmento de Pequeños Medios de Generación Distribuida (PMGD) y a los desarrolladores de sistemas de autoconsumo fotovoltaico a pequeña y mediana escala (comercial e industrial). Para este nicho, donde la instalación de sensorica avanzada o la recopilación de años de datos locales resulta económicamente inviable, un modelo multi-sitio pre-entrenado les permitirá acceder a proyecciones a corto plazo continuas y confiables desde su puesta en marcha, permitiendo rentabilizar sus operaciones y gestionar su inyección a la red sin la barrera de entrada que supone el modelado de datos aislado y tradicional




3. Carta de Compromiso

Dada la naturaleza de la presente investigación, el desarrollo del modelo no se encuentra aunado a la intervención o patrocinio exclusivo de una entidad privada específica para su ejecución técnica. El acceso a los activos de datos necesarios para el cumplimiento de los objetivos planteados ha sido gestionado bajo protocolos internos, lo que garantiza la viabilidad y autonomía del estudio en sus etapas de entrenamiento y validación. No obstante, se mantiene la disposición para formalizar vínculos de colaboración técnica con organismos del sector en fases posteriores, con el fin de robustecer la transferencia tecnológica de los resultados obtenidos.


4. Propuesta de Solución

La propuesta de solución consiste en el diseño e implementación de un modelo global pre-entrenado mediante un enfoque multi-sitio, capaz de extraer patrones atmosféricos generalizables a partir de un conjunto diverso de plantas de generación consolidadas. El objetivo es transferir este conocimiento hacia instalaciones nuevas que sufren de escasez de datos e intermitencias (*Cold-Start*), logrando proyecciones de generación continuas y robustas a pesar de la deficiencia inicial en sus registros.

(a) Paradigma Local: Entrenamiento con Datos Óptimos



(b) Paradigma Local: Escenario Cold-Start (Escasez de Datos)



(c) Propuesta: Arquitectura Transformer Multi-Sitio (Cross-Site Learning)




Figura 1: Diseño arquitectónico integral del flujo predictivo. **(a)** El protocolo de datos ingiere información multimodal de plantas consolidadas y de la instalación *Cold-Start* (1), logrando series consolidadas (2). **(b)** La arquitectura Transformer (*Cross-Site Learning*) procesa esta información consolidada, transfiriendo patrones atmosféricos para generar proyecciones robustas, normalizadas y continuas de la Potencia Activa (3), superando las intermitencias de la entrada.

Desde el punto de vista algorítmico, el núcleo del proyecto recae en la parametrización y validación de una arquitectura de redes neuronales basada en mecanismos de atención (*Transformers*) de estado del arte. A diferencia del entrenamiento local tradicional que requiere series de tiempo impecables y extensas, el proceso de entrenamiento de esta arquitectura se adaptará para procesar simultáneamente múltiples series temporales de diferentes parques solares (*Cross-Site Learning*).

El flujo de procesamiento integrará datos multimodales: por un lado, se ingerirán variables exógenas dinámicas (condiciones meteorológicas con intermitencias, valores nulos o lecturas en cero) y, por otro, características estáticas (coordenadas espaciales de cada estación). La red Transformer se encargará de imputar tácitamente estas intermitencias a través del contexto aprendido, entregando como salida una proyección continua y completa. Para validar la eficacia de este enfoque global, se desarrollará un *benchmark* riguroso que contrastará su rendimiento frente a modelos tradicionales de aprendizaje automático (algoritmos basados en árboles de decisión y redes neuronales recurrentes) entrenados bajo el paradigma estrictamente local.

5. Objetivos

5.1. Objetivo General

Analizar y comparar el desempeño de un modelo global de aprendizaje multi-sitio frente a modelos locales entrenados con datos históricos, en la estimación de la productividad de plantas de energía renovable, considerando su capacidad de generalización y su rendimiento en escenarios de escasez de datos e intermitencia.

5.2. Objetivos Específicos


1. Seleccionar y configurar una arquitectura Transformer preexistente que sea adecuada para el pronóstico de series de tiempo. Posteriormente, adaptar su proceso de entrenamiento con el fin de que el modelo sea capaz de procesar y aprender de manera simultánea a partir de múltiples series temporales provenientes de diferentes plantas solares, reemplazando así el tradicional enfoque de entrenamiento aislado.
2. Evaluar la efectividad del modelo global pre-entrenado durante la puesta en marcha de una nueva planta renovable que cuente con una escasa cantidad de datos con respecto a modelos tradicionales (como XGBoost o LSTM) entrenados de manera estrictamente local.
3. Integrar datos multimodales para dotar al modelo de la capacidad de procesar diversas fuentes de información, integrando de manera conjunta tanto variables exógenas dinámicas, que representan las condiciones meteorológicas, como características estáticas referentes a la ubicación espacial y geográfica de cada estación.



6. Alcance del Proyecto

Con el propósito de analizar y comparar el desempeño predictivo de modelos globales frente a modelos locales, el alcance de este proyecto se focaliza en el dominio de la producción de energía solar mediante el estudio de una muestra de 10 a 15 instalaciones geográficamente distribuidas. Esta configuración experimental permite integrar series de tiempo de producción y variables meteorológicas para evaluar la capacidad de generalización y la respuesta del modelo ante la escasez de datos. Técnicamente, el trabajo se concentra en la parametrización, el entrenamiento multi-sitio y la validación de arquitecturas de estado del arte, empleando modelos XGBoost y LSTM únicamente como líneas base comparativas. Finalmente, para mantener el foco en la evaluación del rendimiento del modelado, se excluyen explícitamente el desarrollo de nuevas estrategias o metodologías desde cero, el despliegue en entornos de producción (MLOps), la integración con sistemas SCADA y cualquier análisis de viabilidad financiera o rentabilidad operativa sobre los activos estudiados. De manera que el proyecto se compone de la recopilación y preprocesado de datos, la configuración de la estrategia de orquestación para el testeo, el entrenamiento de los modelos base, la ejecución y posterior comparación entre el modelo globalmente entrenado y las baseline en situaciones de "Cold-Start". Todo circunscrito por un repositorio con los pipelines de datos, entrenamiento y posterior testeo.

7. Planificación del proyecto



Bibliografía

- Arslan, Z., Sahin, M. E., & Ulutas, H. (2025). Comparative Evaluation of Machine Learning and Transformer-Based Deep Learning for Solar Energy Forecasting on a Real-World Dataset. *Arabian Journal for Science and Engineering*, 51, 6833-6863.
- Asociación Chilena de Energías Renovables y Almacenamiento (ACERA). (2025, diciembre). *Boletín Estadístico ACERA*. <https://cdn.acera.cl/wp-content/uploads/2026/01/2025-12-Boletin-Estadisticas-ACERA.pdf>
- Bai, S., Kolter, J. Z., & Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*.
- Bak, S., Choi, S., Yang, D., Kim, D., Rho, H., & Lee, K. (2025). Transfer Learning for Photovoltaic Power Forecasting Across Regions Using Large-Scale Datasets. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2025.3591040>
- Benidis, K., Rangapuram, S. S., Flunkert, V., Wang, Y., Maddix, D., Turkmen, A. C., Gasthaus, J., Bohlke-Schneider, M., Salinas, D., & Stella, L. (2022). Deep learning for time series forecasting: Tutorial and literature survey. *ACM Computing Surveys*, 55(6), 1-36.
- Comisión Nacional de Energía. (2026, marzo). *Reporte Mensual Sector Energético* (inf. téc.). Gobierno de Chile. https://www.cne.cl/wp-content/uploads/2026/03/RMensual_v202603.pdf
- Coordinador Eléctrico Nacional. (2025). *Informe del Coordinador Independiente del Sistema Eléctrico Nacional* (inf. téc.). CEN. <https://www.coordinador.cl/wp-content/uploads/2025/02/IE-Coordinador-Independiente-Sistema-Elctrico-Nacional-2024-114.pdf>
- Damato, S., Rubattu, N., Azzimonti, D., & Corani, G. (2026). Intermittent time series forecasting: local vs global models. *arXiv preprint arXiv:2601.14031*.
- El-Saieed, A. M. (2025). An Adaptive Transformer Model for Long-Term Time-Series Forecasting of Temperature and Radiation in Photovoltaic Energy Generation. *Applied Computational Intelligence and Soft Computing*, 2025. <https://doi.org/10.1155/2025/3691929>
- Ember. (2025, julio). *Reducing curtailment in Chile: Key to unlocking the full potential of renewable energy*. <https://ember-energy.org/app/uploads/2025/09/EN-Report-Reducing-curtailment-in-Chile-key-to-unlocking-the-full-potential-of-renewable-energy.pdf>
- Energía Estratégica. (2025). *Alertan que los PMGD podrían enfrentar pérdidas por 7400 millones anuales si avanza la bolsa PYME en Chile*. <https://www.energiaestrategica.com/alertan-que-los-pmgd-podrian-enfrentar-perdidas-por-7400-millones-anuales-si-avanza-la-bolsa-pyme-en-chile>
- Gu, A., & Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*.
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780.
- Li, R., Wang, D., Wang, Z., Liang, S., Li, Z., Xie, Y., & He, J. (2024). Transformer approach to now-casting solar energy using geostationary satellite data. *Applied Energy*, 353, 122112.
- López Santos, M., García-Santiago, X., Echevarría Camarero, F., Blázquez Gil, G., & Carrasco Ortega, P. (2022). Application of Temporal Fusion Transformer for Day-Ahead PV Power Forecasting. *Energies*, 15(14), 5232.



- Mishra, A., et al. (2025). SPIRIT: Short-term Prediction of solar IRradlance for zero-shot Transfer learning using Foundation Models. *arXiv preprint arXiv:2502.10307*.
- Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2022). A time series is worth 64 words: Long-term forecasting with transformers. *arXiv preprint arXiv:2211.14730*.
- Oreshkin, B. N., Carпов, D., Chapados, N., & Bengio, Y. (2020). N-BEATS: Neural basis expansion analysis for interpretable time series forecasting. *arXiv preprint arXiv:1905.10437*.
- Salinas, D., Flunkert, V., Gasthaus, J., & Stella, L. (2020). DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3), 1181-1191.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121-11128.
- Zhaoyang Zhu, e. a. (2023). Energy forecasting with robust, flexible, and explainable machine learning algorithms. *AI Magazine*. https://www.researchgate.net/publication/374680104_Energy_forecasting_with_robust_flexible_and_explainable_machine_learning_algorithms
- Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). Informer: Beyond efficient transformer for long sequence time-series forecasting. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(12), 11106-11115.