

César David Aular Muñoz

Escuela Ingeniería Civil Informática
Universidad Católica del Maule

Examen de Título — Junio 2026



Agenda

- ① El problema
- ② Metodología
- ③ Resultados
- ④ Conclusiones


- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones

El problema del *Cold-Start* fotovoltaico

- Una planta FV **recién conectada** no tiene historial de generación.
- Los modelos clásicos entrenan **uno por planta** con meses o años de datos locales.
- Aplicados a una planta nueva: **no se pueden entrenar** o se degradan gravemente.

Consecuencia

Incertidumbre justo cuando más se necesita certeza
→ mayores costos de balance y riesgo financiero, en especial para los pequeños PMGD.



El problema del arranque en frío, tomado de los sistemas de recomendación.

La idea: aprendizaje *Cross-Site*

Abandonar el supuesto **un-modelo-por-planta**.


Un único modelo **global** entrenado sobre **muchas plantas a la vez**:

- absorbe patrones compartidos clima $\rightarrow$ potencia,
- los **transfiere** a una planta jamás vista,
- pronostica **desde la primera hora** de conexión.

Pregunta central (adversarial):

¿realmente supera a una línea base local madura, o el premio de la transferencia se desvanece con una comparación justa?

Transferencia Cross-Site: pre-entrenamiento multi-planta e inferencia sobre una planta sin historia



Hipótesis y objetivos

Hipótesis

El modelo global multi-sitio es *más preciso* que un modelo entrenado localmente con la historia propia del centro.

Objetivos específicos

- 1 Adaptar una arquitectura Transformer al entrenamiento multi-serie.
- 2 Evaluarla frente a modelos locales bajo un protocolo *Cold-Start* estricto.
- 3 Integrar datos multimodales sin fuga de información.

La brecha en la literatura


Rara vez se combinan a la vez:

- 1 evaluación **ciega** a la planta objetivo (sin *fine-tuning*),
- 2 contraste **justo** contra locales maduros,
- 3 caracterización **probabilística**.

- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones

Arquitectura del sistema

Arquitectura de componentes del sistema y stack tecnológico



Protocolo *Leave-One-Plant-Out* (LOPO)

- Para cada planta objetivo: los globales entrenan con las $N - 1$ **restantes** (2014–2024 completo).
- La planta objetivo es **invisible** durante el entrenamiento.
- Métricas: **mediana** sobre 94 plantas, solo observaciones reales.

Integridad Zero-Shot (no negociable)

Ninguna variable puede ser función de la generación del objetivo. Verificado por pruebas automatizadas.



La lección de la fuga de datos

Un *prior* de eficiencia calculado **por-fila** desde el objetivo

$$PR = \frac{y}{\text{capacidad}} \implies \text{corr}(PR, y) = 1,0$$

rRMSE falso

≈ 0,8 % (demasiado bueno para ser verdad)

rRMSE honesto (tras corregir)

≈ 56 %

El *prior* regional se agrega **solo sobre las plantas de entrenamiento** (por macrozona y estación).


Semilla *Cold-Start* sintética

Los modelos profundos necesitan una ventana de contexto que la planta nueva no tiene. Se siembra sintéticamente:

$$\hat{y}_{\text{seed}}(t) = \text{capacidad} \cdot PR_{\text{regional}} \cdot s(t)$$

- $s(t)$: perfil solar determinista; PR_{regional} : solo plantas de entrenamiento.
- Solo el clima exógeno (conocido/pronosticable) y la geografía estática usan valores reales del objetivo.
- La generación de contexto es **100% sintética** → cero fuga.

Protocolo de evaluación Cold-Start: contexto sintético, horizontes y ventanas de sensibilidad



Inicio de la ventana (análisis de sensibilidad):

- Raw: primera hora registrada (incluye rampa de puesta en marcha)
- Operacional: primera producción sostenida
- Estacionales: primera ventana sostenida que inicia en Verano / Otoño / Invierno / Primavera (historia posterior de la misma planta)

Ocho configuraciones y ventanas de evaluación


5 globales (Cross-Site)

- TFT, Informer, N-HiTS, LSTM
- XGBoost global

3 locales (estrictas)

- XGBoost, LSTM, N-HiTS
- entrenados solo con la historia propia

Horizontes: *day1* (24 h) y *rollout7d* (7 días autorregresivos).




Raw (incluye rampa) · **Operacional** (producción sostenida) · **Estacionales**.

- 1 El problema
- 2 Metodología
- 3 Resultados**
- 4 Conclusiones

Precisión puntual — ventana operacional (roll-out 7 días)


Config.	Tipo	rRMSE
XGBoost	Local	62 %
XGBoost	Global	95 %
N-HiTS	Local	104 %
LSTM	Global	118 %
Informer	Global	129 %
TFT	Global	133 %
LSTM	Local	147 %
N-HiTS	Global	150 %



fondo naranja = paradigma local (requiere historia propia de la planta)

El **XGBoost local** es el más preciso; entre las redes globales la **LSTM** supera a la atención (Informer/TFT) — coherente con Zeng et al. (2023).

Sensibilidad estacional: el invierno es el gran desafío



rRMSE roll-out por estación

- XGBoost global: 52 % (verano) → **134 %** (invierno)
- XGBoost local: 40 % → **115 %**

Mayor variabilidad nubosa y menor irradiación invernal debilitan la señal determinista del perfil solar.

Implicación operativa: la incertidumbre de un parque nuevo depende fuertemente de la **estación de su puesta en marcha.**

Calidad probabilística: la calibración no se transfiere

Config.	Tipo	Cobertura diaria	Pinball P95 (MWh)
XGBoost	Local	0,86	0,033
XGBoost	Global	0,99 (sobre-cubre)	0,091
LSTM	Global	0,54	0,140
Informer	Global	0,65	0,114
TFT	Global	0,44	0,123
N-HiTS	Global	0,36	0,277

- Nominal = 0,90. **Ningún paradigma calibra idealmente**, con desvíos opuestos.
- Redes globales **subcalibradas** (bandas demasiado estrechas); XGBoost global **sobre-cubre**.
- **XGBoost local** es el más cercano al nominal y con menor pinball.

Contraste de la hipótesis

En precisión absoluta: la hipótesis se

Ningún modelo global alcanza al mejor baseline local (XGBoost local 62 % vs. global 95 %).


El único matiz: a igualdad de arquitectura

- **LSTM global** (118 %) **supera** a **LSTM local** (147 %) — el clima generalizado excede la historia local limitada.
- Pero **N-HiTS local** (104 %) supera a **N-HiTS global** (150 %) — la ventaja global no es universal.

El valor real: disponibilidad inmediata

En el arranque en frío puro (historia local nula) el modelo global **no tiene competidor local posible**.

Ejemplo de roll-out Cold-Start a 7 días



El modelo global, **sin haber visto jamás la planta**, reproduce el ciclo diario y la magnitud de los picos usando solo el clima entrante y la geografía estática.

- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones**

Conclusiones

- ① **Resultado negativo riguroso:** bajo un protocolo estrictamente ciego, un XGBoost local maduro sigue siendo el estándar a batir. La hipótesis se rechaza.
- ② **El paradigma global conserva un régimen propio:** el arranque en frío puro, donde entrega pronósticos coherentes y accionables desde la hora cero.
- ③ Cuatro hallazgos metodológicos transferibles:
 - las rampas de puesta en marcha distorsionan las métricas (análisis Raw/Operacional);
 - el invierno es sistemáticamente la estación más difícil;
 - la calibración probabilística no se transfiere a las redes profundas;
 - la integridad del *target* (nunca imputar *y*) es esencial para la honestidad de las métricas.

Trabajo futuro

- **Fine-tuning en dos etapas:** pre-entrenar global → ajustar con los primeros días reales; cierra la brecha con el local a medida que crece la historia.
- **Máscaras de intermitencia** en la atención: excluir la noche determinista y concentrar capacidad en la señal productiva.
- **Recalibración conformal** de los intervalos bajo transferencia.
- **Más datos y cómputo:** ampliar el corpus y el presupuesto de pasos (posible sub-entrenamiento de TFT/Informer en 6 GB).
- **Máscara astronómica** para el forzamiento nocturno independiente de sensores.

Gracias

¿Preguntas?



César David Aular Muñoz
cesaraular02@gmail.com

Fórmula

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- Eleva al **cuadrado** cada error antes de promediar → penaliza las desviaciones grandes de forma **cuadrática**, no lineal ni logarítmica.
- Ideal para el pronóstico FV: castiga con fuerza los errores en los **picos de inyección** de mediodía.
- Comparte unidades con la variable (MWh), a diferencia del MSE.
- **rRMSE** = RMSE normalizado por la generación media horaria de la ventana (ver backup siguiente).

Backup — ¿Por qué el rRMSE supera el 100 %?

$$\text{rRMSE} = \frac{\text{RMSE}}{\bar{y}_{\text{ventana}}} \times 100$$

- El denominador $\bar{y}$ incluye las **horas nocturnas de generación nula**.
- Esto **deprime la media** y por tanto **infla** sistemáticamente el indicador.
- Valores $> 100 \%$ son **esperables** en pronóstico horario FV bajo esta normalización.
- Su valor no es la magnitud absoluta, sino la **comparación relativa** entre arquitecturas sobre **ventanas idénticas**.

Todas las configuraciones se comparan sobre la misma grilla horaria canónica → comparación estrictamente pareada.

Backup — Calibración de XGBoost (global vs. local)

XGBoost global: 0,99 (sobre-cubre)

- Regresión cuantílica sobre un contexto **heterogéneo** ($N - 1$ plantas).
- Bandas **demasiado anchas**: casi nunca fallan, pero pierden utilidad operativa.
- Un defecto **simétrico** al de las redes, no una virtud.

XGBoost local: 0,86 (casi nominal)

- Ajustado a la variabilidad **real** de la propia planta.
- Pinball P95 = **0,033** MWh vs. 0,091 del global.
- Intervalos más estrechos y **mejor centrados**.

¿Por qué las redes profundas subcalibran?

Su escalador local se ajusta sobre el **contexto sintético**, cuya varianza (perfil solar idealizado) es menor que la real $\rightarrow$ bandas estrechas. Los baselines locales profundos, con contexto real, mejoran (LSTM local 0,79).

- **Precisión fp32** completa: la mezcla fp16 introducía inestabilidad numérica en el entrenamiento.
- **GPU RTX 2060 (6 GB)**: la VRAM la gobierna $\text{batch_size} \times \text{windows_batch_size}$, no el tamaño del corpus $\rightarrow$ no se trunca la historia.
- **Presupuesto por época corregido**: cada paso consume $\text{batch} \times \text{windows_batch}$ ventanas; la fórmula ingenua $\text{filas}/\text{batch}$ sobreestimaba $\sim 250\times$.
- **Early stopping** sobre $\text{val_size}=168$; tuning cacheado una vez por modelo y reusado entre folds (fuga a nivel de hiperparámetro: despreciable y documentada).
- Toda predicción se fuerza a $\hat{y} \geq 0$ y a cero de noche (consistencia física).

Backup — Tabla completa (day1 y roll-out)

Config.	Tipo	rRMSE (%)		sMAPE (%)	
		day1	roll7d	day1	roll7d
XGBoost	Local	40,6	62,2	51,4	51,5
XGBoost	Global	77,5	95,4	39,8	40,7
N-HiTS	Local	73,6	104,0	56,9	69,1
LSTM	Global	103,4	118,2	86,3	91,8
Informer	Global	96,9	129,3	82,2	89,0
TFT	Global	110,2	133,1	89,5	96,2
LSTM	Local	102,6	146,9	82,2	91,4
N-HiTS	Global	130,6	150,4	95,8	96,9

Ventana operacional, mediana sobre 33 plantas con rampa distinguible.