

Análisis comparativo de un enfoque multi-sitio frente a modelos locales para la proyección a corto plazo de generación fotovoltaica bajo escasez de datos

César David Aular Muñoz

Escuela Ingeniería Civil Informática
Universidad Católica del Maule

Proyecto de Título — Junio 2026



Agenda

- ① El problema
- ② Metodología
- ③ Resultados
- ④ Conclusiones


- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones

El problema del *Cold-Start* fotovoltaico

- Una planta FV **recién conectada** no tiene historial de generación.
- Los modelos clásicos entrenan **uno por planta** con meses o años de datos locales.
- Aplicados a una planta nueva: **no se pueden entrenar** o se degradan gravemente.

Consecuencia

Incertidumbre justo cuando más se necesita certeza
→ mayores costos de balance y riesgo financiero, en especial para los pequeños PMGD.



El problema del arranque en frío, tomado de los sistemas de recomendación.

La idea: aprendizaje *Cross-Site*

Abandonar el supuesto **un-modelo-por-planta**.


Un único modelo **global** entrenado sobre **muchas plantas a la vez**:

- absorbe patrones compartidos clima $\rightarrow$ potencia,
- los **transfiere** a una planta jamás vista,
- pronostica **desde la primera hora** de conexión.

Pregunta central (adversarial):

¿realmente supera a una línea base local madura, o el premio de la transferencia se desvanece con una comparación justa?

Transferencia Cross-Site: pre-entrenamiento multi-planta e inferencia sobre una planta sin historia



Hipótesis y objetivos

Hipótesis

El modelo global multi-sitio es *más preciso* que un modelo entrenado localmente con la historia propia del centro.

Objetivos específicos

- 1 Adaptar una arquitectura Transformer al entrenamiento multi-serie.
- 2 Evaluarla frente a modelos locales bajo un protocolo *Cold-Start* estricto.
- 3 Integrar datos multimodales sin fuga de información.

La brecha en la literatura


Rara vez se combinan a la vez:

- 1 evaluación **ciega** a la planta objetivo (sin *fine-tuning*),
- 2 contraste **justo** contra locales maduros,
- 3 caracterización **probabilística**.

- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones

Arquitectura del sistema

Arquitectura de componentes del sistema y stack tecnológico



Protocolo *Leave-One-Plant-Out* (LOPO)

- Para cada planta objetivo: los globales entrenan con las $N - 1$ **restantes** (2014–2024 completo).
- La planta objetivo es **invisible** durante el entrenamiento.
- Métricas: **mediana** sobre 94 plantas, solo observaciones reales.

Validación *Leave-One-Plant-Out*: la planta objetivo es invisible durante el entrenamiento global



Integridad Zero-Shot (no negociable)

Ninguna variable puede ser función de la generación del objetivo. Verificado por pruebas automatizadas.

La lección de la fuga de datos

Un *prior* de eficiencia calculado **por-fila** desde el objetivo

$$PR = \frac{y}{\text{capacidad}} \implies \text{corr}(PR, y) = 1,0$$

rRMSE falso

≈ 0,8 % (demasiado bueno para ser verdad)

rRMSE honesto (tras corregir)

≈ 56 %

El *prior* regional se agrega **solo sobre las plantas de entrenamiento** (por macrozona y estación).


Semilla *Cold-Start* sintética

Los modelos profundos necesitan una ventana de contexto que la planta nueva no tiene. Se siembra sintéticamente:

$$\hat{y}_{\text{seed}}(t) = \text{capacidad} \cdot PR_{\text{regional}} \cdot s(t)$$

- $s(t)$: perfil solar determinista; PR_{regional} : solo plantas de entrenamiento.
- Solo el clima exógeno (conocido/pronosticable) y la geografía estática usan valores reales del objetivo.
- La generación de contexto es **100% sintética** → cero fuga.

Protocolo de evaluación Cold-Start: contexto sintético, horizontes y ventanas de sensibilidad



Inicio de la ventana (análisis de sensibilidad):

- Raw: primera hora registrada (incluye rampa de puesta en marcha)
- Operacional: primera producción sostenida
- Estacionales: primera ventana sostenida que inicia en Verano / Otoño / Invierno / Primavera (historia posterior de la misma planta)

Ocho configuraciones y ventanas de evaluación


5 globales (Cross-Site)

- TFT, Informer, N-HiTS, LSTM
- XGBoost global

3 locales (estrictas)

- XGBoost, LSTM, N-HiTS
- entrenados solo con la historia propia


Horizontes: *day1* (24 h) y *rollout7d* (7 días autorregresivos).



Raw (incluye rampa) · **Operacional** (producción sostenida) · **Estacionales**.

¿Dónde están las plantas? El corpus sobre el mapa

Ubicación de las plantas evaluadas
(87 de 94 georreferenciadas · área $\propto$ capacidad instalada)



- **94 plantas** del Sistema Eléctrico Nacional, a lo largo de todo el gradiente solar de Chile (Arica $\rightarrow$ zona sur).
- **Norte Grande y Norte Chico**: pocas plantas pero **grandes** (utility scale, hasta 200 MW) y de alta irradiancia.
- **Zona Central**: muchas plantas **pequeñas** (PMGD, mediana ≈ 3 MW) — el segmento que más sufre el arranque en frío.


Por qué importa para la transferencia

La **macrozona** es la única señal espacial que ven los modelos, y es la clave sobre la que se agrega el *prior* regional que siembra el contexto sintético.

- 1 El problema
- 2 Metodología
- 3 Resultados**
- 4 Conclusiones

Precisión puntual — ventana *cold-start*, 94 plantas (roll-out 7 días)


Config.	Tipo	NRMSE	rRMSE
XGBoost	Local	13,2 %	60 %
XGBoost	Global	17,1 %	75 %
N-HiTS	Local	17,6 %	85 %
Informer	Global	22,8 %	107 %
TFT	Global	23,6 %	113 %
LSTM	Local	23,9 %	129 %
LSTM	Global	24,8 %	109 %
N-HiTS	Global	30,7 %	148 %



NRMSE = RMSE / capacidad instalada. **94 plantas.**

El **XGBoost local** es el más preciso (13 % de la potencia nominal). Normalizar por **capacidad** hace los números interpretables —y cambia el orden del par LSTM respecto de rRMSE.

Sensibilidad estacional: el invierno es el gran desafío



rRMSE roll-out por estación

- XGBoost global: 52 % (verano) → **134 %** (invierno)
- XGBoost local: 40 % → **115 %**

Mayor variabilidad nubosa y menor irradiación invernal debilitan la señal determinista del perfil solar.

Implicación operativa: la incertidumbre de un parque nuevo depende fuertemente de la **estación de su puesta en marcha.**

Calidad probabilística: la calibración no se transfiere

Config.	Tipo	Cobertura diaria	Pinball P95 (MWh)
XGBoost	Local	0,86	0,035
XGBoost	Global	0,97 (sobre-cubre)	0,092
LSTM	Global	0,53	0,159
Informer	Global	0,64	0,115
TFT	Global	0,38	0,158
N-HiTS	Global	0,37	0,372

- Nominal = 0,90. **Ningún paradigma calibra idealmente**, con desvíos opuestos.
- Redes globales **subcalibradas** (bandas demasiado estrechas); XGBoost global **sobre-cubre**.
- **XGBoost local** es el más cercano al nominal y con menor pinball.

Contraste de la hipótesis — con test estadístico

La hipótesis se , y ahora con significancia

XGBoost local gana a **XGBoost global** en **77 de 94 plantas** ($p < 10^{-7}$, Wilcoxon pareado con corrección de Holm).


A igualdad de arquitectura: ningún global gana significativamente

- **N-HiTS local** supera a **N-HiTS global** en **88/94** ($p < 10^{-10}$).
- El par **LSTM** es un **empate estadístico**: 49/45 plantas, $p = 1,00$. El matiz que sugerían las medianas **no sobrevive** al test pareado.

El valor real: disponibilidad inmediata

En el arranque en frío puro (historia local nula) el modelo global **no tiene competidor local posible**.

Ejemplo de roll-out Cold-Start a 7 días



El modelo global, **sin haber visto jamás la planta**, reproduce el ciclo diario y la magnitud de los picos usando solo el clima entrante y la geografía estática.

- 1 El problema
- 2 Metodología
- 3 Resultados
- 4 Conclusiones**

Conclusiones

- ① **Resultado negativo riguroso:** bajo un protocolo estrictamente ciego, un XGBoost local maduro sigue siendo el estándar a batir. La hipótesis se rechaza.
- ② **El paradigma global conserva un régimen propio:** el arranque en frío puro, donde entrega pronósticos coherentes y accionables desde la hora cero.
- ③ Cuatro hallazgos metodológicos transferibles:
 - las rampas de puesta en marcha distorsionan las métricas (análisis Raw/Operacional);
 - el invierno es sistemáticamente la estación más difícil;
 - la calibración probabilística no se transfiere a las redes profundas;
 - la integridad del *target* (nunca imputar *y*) es esencial para la honestidad de las métricas.

Trabajo futuro

- **Fine-tuning en dos etapas:** pre-entrenar global → ajustar con los primeros días reales; cierra la brecha con el local a medida que crece la historia.
- **Máscaras de intermitencia** en la atención: excluir la noche determinista y concentrar capacidad en la señal productiva.
- **Recalibración conformal** de los intervalos bajo transferencia.
- **Más datos y cómputo:** ampliar el corpus y el presupuesto de pasos (posible sub-entrenamiento de TFT/Informer en 6 GB).
- **Máscara astronómica** para el forzamiento nocturno independiente de sensores.

Gracias

¿Preguntas?



César David Aular Muñoz
cesaraular02@gmail.com

Backup — Tests estadísticos (Friedman + Wilcoxon-Holm)

Diseño pareado y balanceado: 94 plantas $\times$ 8 configuraciones sobre la misma grilla horaria canónica $\rightarrow$ aplica la comparación por rangos de Demšar (2006).

- **Friedman (omnibus):** $\chi^2 = 260,7$, $p < 10^{-50}$ — las configuraciones no son equivalentes.
- **Ranking medio** (1 = mejor): XGB local 1,80 · N-HiTS local 3,32 · XGB global 3,34 · TFT 5,10 · Informer 5,15 · LSTM local 5,30 · LSTM global 5,41 · N-HiTS global 6,59.
- **Mejor por planta:** XGB local en 60/94, XGB global en 15, N-HiTS local en 10.

Por qué la mediana marginal engañaba

rRMSE mediano sugería **LSTM global** (118 %) mejor que **LSTM local** (147 %). Pero la **mediana de las diferencias por planta** es ≈ 0 y levemente a favor del local: la brecha la producían unas pocas plantas donde el local falla mucho, no una ventaja sistemática del global.

Backup — Causalidad temporal de los baselines locales

Qué se hizo exactamente

Los baselines locales se entrenan con la historia **completa** de la planta **menos todas las ventanas de evaluación** (Raw, Operacional y las 4 estacionales), con los *lags* hacia esas ventanas enmascarados.

- No hay fuga del *target*: ningún rezago apunta dentro de una ventana.
- Pero el entrenamiento **sí incluye horas posteriores** a la ventana predicha → **no es estrictamente causal**.
- Es una elección de diseño: representa el modelo maduro que el operador tendría *tras acumular historia* — el rival más fuerte posible.

Por qué esto refuerza la conclusión

El sesgo favorece al lado **local**, que **gana**; y el espejo (LOPO oculta la planta pero **no el calendario**) favorece al lado **global**, que **pierde igual**. Ambos sesgos empujan contra la conclusión reportada.

Fórmula

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- Eleva al **cuadrado** cada error antes de promediar → penaliza las desviaciones grandes de forma **cuadrática**, no lineal ni logarítmica.
- Ideal para el pronóstico FV: castiga con fuerza los errores en los **picos de inyección** de mediodía.
- Comparte unidades con la variable (MWh), a diferencia del MSE.
- **rRMSE** = RMSE normalizado por la generación media horaria de la ventana (ver backup siguiente).

Backup — ¿Por qué el rRMSE supera el 100 %?

$$\text{rRMSE} = \frac{\text{RMSE}}{\bar{y}_{\text{ventana}}} \times 100$$

- El denominador $\bar{y}$ incluye las **horas nocturnas de generación nula**.
- Esto **deprime la media** y por tanto **infla** sistemáticamente el indicador.
- Valores $> 100\%$ son **esperables** en pronóstico horario FV bajo esta normalización.
- Su valor no es la magnitud absoluta, sino la **comparación relativa** entre arquitecturas sobre **ventanas idénticas**.

Todas las configuraciones se comparan sobre la misma grilla horaria canónica → comparación estrictamente pareada.

Backup — Calibración de XGBoost (global vs. local)

XGBoost global: 0,97 (sobre-cubre)

- Regresión cuantílica sobre un contexto **heterogéneo** ($N - 1$ plantas).
- Bandas **demasiado anchas**: casi nunca fallan, pero pierden utilidad operativa.
- Un defecto **simétrico** al de las redes, no una virtud.

XGBoost local: 0,86 (casi nominal)

- Ajustado a la variabilidad **real** de la propia planta.
- Pinball P95 = **0,035** MWh vs. 0,092 del global.
- Intervalos más estrechos y **mejor centrados**.

¿Por qué las redes profundas subcalibran?

Su escalador local se ajusta sobre el **contexto sintético**, cuya varianza (perfil solar idealizado) es menor que la real $\rightarrow$ bandas estrechas. Los baselines locales profundos, con contexto real, mejoran (LSTM local 0,79).

- **Precisión fp32** completa: la mezcla fp16 introducía inestabilidad numérica en el entrenamiento.
- **GPU RTX 2060 (6 GB)**: la VRAM la gobierna $\text{batch_size} \times \text{windows_batch_size}$, no el tamaño del corpus $\rightarrow$ no se trunca la historia.
- **Presupuesto por época corregido**: cada paso consume $\text{batch} \times \text{windows_batch}$ ventanas; la fórmula ingenua $\text{filas}/\text{batch}$ sobreestimaba $\sim 250\times$.
- **Early stopping** sobre $\text{val_size}=168$; tuning cacheado una vez por modelo y reusado entre folds (fuga a nivel de hiperparámetro: despreciable y documentada).
- Toda predicción se fuerza a $\hat{y} \geq 0$ y a cero de noche (consistencia física).

Backup — Tabla completa (day1 y roll-out)

Config.	Tipo	NRMSE (% cap.)		rRMSE (%)		Cob.	Pinball
		day1	roll7d	day1	roll7d		
XGBoost	Local	9,5	13,2	45,6	59,9	0,86	0,035
XGBoost	Global	15,6	17,1	64,0	75,1	0,97	0,092
N-HiTS	Local	14,2	17,6	62,3	85,2	0,72	0,096
Informer	Global	21,0	22,8	96,6	106,5	0,64	0,115
TFT	Global	22,0	23,6	105,1	112,7	0,38	0,158
LSTM	Local	16,3	23,9	102,6	128,8	0,72	0,235
LSTM	Global	22,6	24,8	99,7	108,6	0,53	0,159
N-HiTS	Global	28,6	30,7	129,8	148,2	0,37	0,372

Ventana *cold-start*, mediana sobre las **94 plantas** (Operacional donde hay rampa >24 h; Raw en el resto).