



UNIVERSIDAD CATÓLICA DEL MAULE
FACULTAD DE CIENCIAS DE LA INGENIERÍA
ESCUELA INGENIERÍA CIVIL INFORMÁTICA

**Análisis comparativo de un enfoque multi-sitio
frente a modelos locales para la proyección a
corto plazo de generación fotovoltaica bajo
escasez de datos**

César David Aular Muñoz
Dr. Sergio Hernández Álvarez

Proyecto de título para optar al Título de Ingeniero Civil Informático

TALCA, Junio 2026



UNIVERSIDAD CATÓLICA DEL MAULE

**FACULTAD DE CIENCIAS DE LA INGENIERÍA
ESCUELA INGENIERÍA CIVIL INFORMÁTICA**

Proyecto de título para optar al Título de Ingeniero Civil Informático

**Análisis comparativo de un enfoque multi-sitio frente a modelos locales para la
proyección a corto plazo de generación fotovoltaica bajo escasez de datos**

César David Aular Muñoz

COMISIÓN EXAMINADORA

FIRMA

PROFESOR GUÍA

Dr. Sergio Hernández Álvarez

PROFESOR COMISIÓN

PROFESOR COMISIÓN

PROFESOR COMISIÓN

PROFESOR COMISIÓN

NOTA FINAL EXAMEN DE TÍTULO:

TALCA, Junio 2026

AGRADECIMIENTOS

En esta sección puede escribir libremente siguiendo el mismo formato del documento. Se escribe en 1ra persona. Puede escribir esta sección al finalizar el resto de este documento. **Borre el texto que no es suyo** y comience a escribir.

RESUMEN

La expansión acelerada de la generación fotovoltaica enfrenta una barrera crítica durante la puesta en marcha de nuevas instalaciones: la ausencia de historial operativo local impide que los modelos predictivos tradicionales, entrenados de manera aislada por planta, entreguen proyecciones confiables (problema de *Cold-Start*). Esta incertidumbre algorítmica se traduce en ineficiencias operativas y riesgo financiero para los operadores del sistema eléctrico y los pequeños medios de generación distribuida.

El presente proyecto de título aborda este problema mediante el diseño, implementación y validación de un marco de aprendizaje multi-sitio (*Cross-Site Learning*), en el cual arquitecturas de *Deep Learning* de estado del arte —*Temporal Fusion Transformer* (TFT), *Informer* y *N-HiTS*— se entrenan de forma global sobre un conglomerado de plantas solares chilenas consolidadas, integrando datos multimodales: series de generación horaria (2014–2024), variables meteorológicas exógenas y características estáticas geográficas agrupadas por Macrozona.

La evaluación se estructura bajo el protocolo *Leave-One-Plant-Out* (LOPO), que oculta íntegramente la planta objetivo durante el entrenamiento y simula su arranque en frío inicializando la ventana de contexto con valores puramente sintéticos, derivados de un coeficiente de eficiencia regional calculado exclusivamente sobre el conjunto de entrenamiento. El desempeño se contrasta frente a líneas base entrenadas localmente (XGBoost y LSTM) en horizontes de 24 horas y de 7 días con realimentación autorregresiva, empleando métricas puntuales (RMSE, MAE, sMAPE, rRMSE) y probabilísticas (cobertura del intervalo de 90 % y pérdida Pinball), estratificadas por estación del año.

Los resultados esperados permitirán cuantificar la capacidad del enfoque global para transferir patrones atmosféricos generalizados hacia instalaciones sin historia, dictaminando empíricamente si el aprendizaje multi-sitio constituye una alternativa viable al paradigma de entrenamiento local durante las etapas tempranas de operación de un parque solar.

ABSTRACT

The accelerated expansion of photovoltaic generation faces a critical barrier during the commissioning of new facilities: the absence of local operating history prevents traditional forecasting models, trained in isolation for each plant, from delivering reliable projections (the *Cold-Start* problem). This algorithmic uncertainty translates into operational inefficiencies and financial risk for power-system operators and small distributed-generation actors.

This undergraduate thesis project addresses the problem through the design, implementation and validation of a *Cross-Site Learning* framework, in which state-of-the-art Deep Learning architectures —the *Temporal Fusion Transformer* (TFT), *Informer* and *N-HiTS*— are trained globally over a set of consolidated Chilean solar plants, integrating

multimodal data: hourly generation series (2014–2024), exogenous meteorological variables and static geographic features grouped by macro-zone.

The evaluation follows a *Leave-One-Plant-Out* (LOPO) protocol, which completely hides the target plant during training and simulates its cold start by initializing the context window with purely synthetic values, derived from a regional efficiency coefficient computed strictly on the training set. Performance is contrasted against locally trained baselines (XGBoost and LSTM) over 24-hour and autoregressive 7-day horizons, using both point metrics (RMSE, MAE, sMAPE, rRMSE) and probabilistic metrics (90% interval coverage and Pinball loss), stratified by season of the year.

The expected results will quantify the ability of the global approach to transfer generalized atmospheric patterns to facilities without history, empirically determining whether multi-site learning constitutes a viable alternative to the local training paradigm during the early operational stages of a solar park.

ÍNDICE DE CONTENIDOS

Capítulo I	1
1. Introducción y Objetivos	2
1.1. Introducción	2
1.2. Problemática	3
1.3. Cliente y/o Público objetivo	4
1.4. Objetivo General	4
1.5. Hipótesis	4
1.6. Alcance del Proyecto	5
1.7. Carta de Compromiso	6
1.8. Planificación del Trabajo (Carta Gantt)	7
Capítulo II	8
2. Marco Teórico	9
2.1. Generación Fotovoltaica y Variables Meteorológicas	9
2.2. Series de Tiempo y Modelado Predictivo Tradicional	9
2.3. El Problema de Arranque en Frío (Cold-Start)	9
2.4. Arquitecturas basadas en Transformers y Enfoques Modernos (N-HiTS)	10
2.5. Transfer Learning y Aprendizaje Multi-Sitio	10
2.6. Conclusión acerca de las Herramientas Seleccionadas	11
Capítulo III	13
3. Estado del Arte / Benchmarking	14
3.1. Modelos Base y Pronóstico de Ámbito Local	14
3.2. Aplicación de Arquitecturas Transformer en Series Temporales	14
3.3. Transfer Learning y Aprendizajes Globales Multi-Sitio	15
3.4. Conclusión del Estado del Arte y Aporte del Proyecto	16
Capítulo IV	18
4. Metodología y Propuesta de Solución	19
4.1. Propuesta de Solución	19
4.2. Adaptación Metodológica (Pipeline de Trabajo)	20

4.3.	Estudio de Factibilidad	22
Capítulo V		25
5.	Desarrollo de la Propuesta y Resultados	26
5.1.	Fase 0: Construcción del Pipeline de Datos (ETL)	26
5.2.	Fase 1: Sintonización de Hiperparámetros	26
5.3.	Fase 2: Simulación Cold-Start (LOPO)	27
5.4.	Fase 3: Resultados y Análisis Comparativo	28
Capítulo VI		29
6.	Conclusiones y Trabajo Futuro	30
Bibliografía		31
Anexos		33
A.	Repositorio del Proyecto	34
B.	Tablas Completas de Métricas por Planta	34
C.	Registro de Imputación de Variables Exógenas	34
D.	Hallazgos de Calidad de Datos	34

LISTA DE FIGURAS

1.1. Distribución geográfica de las plantas fotovoltaicas pertenecientes a la muestra.	6
1.2. Planificación estructurada en 6 semanas, categorizada según los Objetivos Específicos del proyecto.	7
2.3. Arquitectura del Temporal Fusion Transformer, destacando sus compuertas Gated Residual Networks (GRN) y su bloque de atención multipunto. . .	11
2.4. Flujo conceptual de transferencia de conocimiento global inter-plantas versus el entrenamiento local y aislado.	11
4.5. Representación esquemática de la propuesta de solución predictiva.	19
4.6. Algoritmia del proceso de preparación de datos y control de calidad.	20
4.7. Visualización iterativa del aislamiento espacial para simulación de arranque en frío.	22
4.8. Esquema comparativo de métricas de precisión entre arquitecturas locales y globales.	23
4.9. Cronograma metodológico de actividades para la ejecución de la propuesta.	23
5.10. Flujo de datos implementado: Landing → Bronze → Silver → Gold.	27

LISTA DE TABLAS

1.1. Resumen del impacto operativo y financiero por incertidumbre predictiva.	4
3.2. Síntesis comparativa de las arquitecturas predictivas expuestas en el estado del arte.	16

Capítulo I

Introducción y Objetivos

1. Introducción y Objetivos

1.1. Introducción

En las últimas décadas, la energía solar ha cobrado una gran relevancia, llegando a representar una parte sustancial de la generación de energía renovable a nivel mundial gracias a los avances en las tecnologías fotovoltaicas y a la creciente demanda energética. La expansión de la infraestructura de energía solar es un pilar fundamental para la electrificación, la transición energética global y el cumplimiento de los compromisos de cero emisiones netas para mitigar los efectos del cambio climático. Sin embargo, la generación fotovoltaica está sujeta a una alta variabilidad e intermitencia, ya que depende directamente de factores meteorológicos dinámicos como la Irradiancia Horizontal Global (GHI), la temperatura, la nubosidad y la velocidad del viento. Por lo tanto, la estimación precisa de la productividad en plantas de energía renovable es un desafío crítico para la planificación, operación y optimización de los sistemas energéticos de la red.

Tradicionalmente, los modelos predictivos de generación solar se han abordado mediante técnicas estadísticas y algoritmos clásicos que se entrenan de manera local utilizando los datos históricos específicos de cada planta. Este enfoque presenta dos limitaciones fundamentales. En primer lugar, dependen fuertemente de la disponibilidad de un volumen considerable de datos históricos locales, lo cual dificulta enormemente su aplicación en escenarios de puesta en marcha de nuevas instalaciones (el problema de *cold-start* o arranque en frío). En segundo lugar, omiten el aprovechamiento de los patrones meteorológicos y operativos que son compartidos entre distintas plantas y regiones climáticas, los cuales poseen un alto valor para mejorar la capacidad predictiva y la generalización de los modelos.

Para superar estas barreras de disponibilidad de datos, la investigación reciente ha comenzado a integrar técnicas avanzadas de Deep Learning, donde arquitecturas como los Transformers (ej. Temporal Fusion Transformer, Informer o PatchTST) han demostrado una capacidad superior para procesar secuencias largas y extraer dependencias temporales complejas a partir de datos meteorológicos multivariados. Complementariamente, el uso de enfoques de *Transfer Learning* (aprendizaje por transferencia) permite que un modelo pre-entrenado a partir de bases de datos a gran escala y de múltiples regiones transfiera características y patrones climáticos generales hacia instalaciones locales con escasez de datos.

El presente proyecto busca abordar el problema del *cold-start* a través del desarrollo y validación de una arquitectura de "*Cross-Site Learning*" (aprendizaje multi-sitio). Mediante el uso de un modelo Transformer de estado del arte, el proceso de entrenamiento se adaptará para aprender simultáneamente de múltiples series temporales de distintas plantas solares, integrando variables exógenas dinámicas (clima) y características estáticas (ubicación geográfica).

El desarrollo de este proyecto aporta valor empírico y metodológico en dos frentes principales. En primer lugar, proporciona una herramienta validada para la industria,

permitiendo a los operadores estimar con mayor precisión la producción de nuevos parques solares desde sus etapas iniciales sin depender de recolecciones de datos locales prolongadas. En segundo lugar, aporta evidencia sólida sobre la eficacia de aplicar técnicas de *Transfer Learning* y arquitecturas Transformer en series de tiempo energéticas, estableciendo un marco de evaluación riguroso frente a modelos tradicionales de Machine Learning (como XGBoost o LSTM) entrenados de manera estrictamente local.

1.2. Problemática

La transición hacia una matriz energética sostenible ha impulsado una expansión acelerada de proyectos fotovoltaicos. Tal como indica la Comisión Nacional de Energía (2026), el 75 % de los 5.333 MW de nueva capacidad eléctrica actualmente en etapa de construcción en el país corresponde a parques solares. Sin embargo, esta inyección masiva de energía choca con una barrera crítica para la toma de decisiones: la escasez de datos meteorológicos y operativos durante las etapas iniciales de un proyecto. Para generar proyecciones confiables y superar el problema del Cold-Start, los algoritmos predictivos tradicionales —entrenados de manera aislada para cada instalación— requieren de un mínimo de un año ininterrumpido de registros locales (Zhaoyang Zhu, 2023). Esto fomenta un profundo aislamiento del aprendizaje técnico, impidiendo que el conocimiento atmosférico generalizado (enfoque Multi-Sitio) se transfiera, lo que condena a los nuevos actores del mercado a operar con altos niveles de incertidumbre algorítmica desde su puesta en marcha.

Esta falta de predictibilidad a corto plazo desencadena severas ineficiencias operativas y un alto riesgo financiero a lo largo de la red. A nivel sistémico, el Coordinador Eléctrico Nacional (2025) reporta que las imprecisiones en los pronósticos de inyección renovable han introducido un error financiero del 4,62 % sobre la estimación de los costos operativos totales del Sistema Eléctrico Nacional. Más grave aún, la incapacidad de anticipar con exactitud la generación exacerba los cuellos de botella en la transmisión, derivando en niveles críticos de vertimiento de energía limpia (curtailment). Durante 2025, el vertimiento físico alcanzó los 6.084 GWh (Asociación Chilena de Energías Renovables y Almacenamiento (ACERA), 2025), lo que se ha traducido en pérdidas de ingresos para las generadoras equivalentes a 562 millones de dólares acumulados en los últimos tres años (Ember, 2025). Finalmente, en el ecosistema a menor escala, esta incertidumbre algorítmica expone directamente a los Pequeños Medios de Generación Distribuida (PMGD) a un riesgo de mermas financieras estimado en hasta 7.400 millones de dólares anuales ante la falta de certeza horaria en sus esquemas de inyección (Energía Estratégica, 2025).

Variable / Métrica	Magnitud Estimada	Fuente de Referencia
Capacidad solar en construcción	75 % del total (MW)	Comisión Nacional de Energía (2026)
Error financiero sistémico	4,62 % de costos operativos	Coordinador Eléctrico Nacional (2025)
Vertimiento físico anual	6.084 GWh	ACERA (2025)
Pérdida por vertimiento (3 años)	562 Millones USD	Ember (2025)

Tabla 1.1: Resumen del impacto operativo y financiero por incertidumbre predictiva.

1.3. Cliente y/o Público objetivo

El público objetivo y los principales beneficiarios de esta solución abarcan un espectro amplio dentro del ecosistema de generación de energía renovable. En primer lugar, la herramienta se orienta a operadores, administradores de parques solares a gran escala y coordinadores de redes eléctricas, quienes requieren sistemas predictivos robustos para minimizar la incertidumbre en la toma de decisiones, optimizando la planificación energética y reduciendo el riesgo financiero ante desvíos en el despacho durante las etapas iniciales de una planta.

En segundo lugar, esta propuesta integra a los actores del segmento de Pequeños Medios de Generación Distribuida (PMGD) y a los desarrolladores de sistemas de autoconsumo fotovoltaico a pequeña y mediana escala (comercial e industrial). Para este nicho, donde la instalación de sensorica avanzada o la recopilación de años de datos locales resulta económicamente inviable, un modelo multi-sitio pre-entrenado les permitirá acceder a proyecciones a corto plazo continuas y confiables desde su puesta en marcha, permitiendo rentabilizar sus operaciones y gestionar su inyección a la red sin la barrera de entrada que supone el modelado de datos aislado y tradicional.

1.4. Objetivo General

Analizar y comparar el desempeño de un modelo global de aprendizaje multi-sitio frente a modelos locales entrenados con datos históricos, en la estimación de la productividad de plantas de energía renovable, considerando su capacidad de generalización y su rendimiento en escenarios de escasez de datos e intermitencia.

1.5. Hipótesis

La implementación de un modelo globalmente entrenado con información proveniente de centros meteorológicamente variados, es capaz de usar información generalizada respecto de las variaciones en las condiciones atmosféricas para obtener un mejor

resultado respecto de la producción de energía de una planta de producción desconocida, siendo más precisa que un modelo localmente entrenado solo con la información histórica del centro.

Objetivos Específicos

1. Seleccionar y configurar una arquitectura Transformer preexistente que sea adecuada para el pronóstico de series de tiempo. Posteriormente, adaptar su proceso de entrenamiento con el fin de que el modelo sea capaz de procesar y aprender de manera simultánea a partir de múltiples series temporales provenientes de diferentes plantas solares, reemplazando así el tradicional enfoque de entrenamiento aislado.
2. Evaluar la efectividad del modelo global pre-entrenado durante la puesta en marcha de una nueva planta renovable que cuente con una escasa cantidad de datos con respecto a modelos tradicionales (como XGBoost o LSTM) entrenados de manera estrictamente local.
3. Integrar datos multimodales para dotar al modelo de la capacidad de procesar diversas fuentes de información, integrando de manera conjunta tanto variables exógenas dinámicas, que representan las condiciones meteorológicas, como características estáticas referentes a la ubicación espacial y geográfica de cada estación.

1.6. Alcance del Proyecto

Con el propósito de analizar y comparar el desempeño predictivo de modelos globales frente a modelos locales, el alcance de este proyecto se focaliza en el dominio de la producción de energía solar mediante el estudio de un conjunto consolidado de instalaciones agrupadas bajo un criterio de Macrozona. Esta estrategia de agrupación responde a la necesidad de estabilizar las características climáticas compartidas y escalar el aprendizaje cruzado entre plantas. Esta configuración experimental permite integrar series de tiempo de producción y variables meteorológicas de alta fidelidad para evaluar la capacidad de generalización y la respuesta del modelo ante la escasez de datos. Técnicamente, el trabajo se concentra en la parametrización, el entrenamiento multi-sitio y la validación de arquitecturas de estado del arte (TFT, Informer, N-HiTS), empleando modelos XGBoost y LSTM como líneas base comparativas. Finalmente, para mantener el foco en la evaluación del rendimiento del modelado, se excluyen explícitamente el desarrollo de nuevas estrategias o metodologías desde cero, el despliegue en entornos de producción (MLOps), la integración con sistemas SCADA y cualquier análisis de viabilidad financiera o rentabilidad operativa sobre los activos estudiados. De manera que el proyecto se compone de la recopilación y preprocesado de datos, la configuración de la

estrategia de orquestación para el testeo, el entrenamiento de los modelos base, la ejecución y posterior comparación entre el modelo globalmente entrenado y las baseline en situaciones de “Cold-Start”. Todo circunscrito por un repositorio con los pipelines de datos, entrenamiento y posterior testeo.




Figura 1.1: Distribución geográfica de las plantas fotovoltaicas pertenecientes a la muestra.

1.7. Carta de Compromiso

Dada la naturaleza de la presente investigación, el desarrollo del modelo no se encuentra aunado a la intervención o patrocinio exclusivo de una entidad privada específica para su ejecución técnica. El acceso a los activos de datos necesarios para el cumplimiento de los objetivos planteados ha sido gestionado bajo protocolos internos, lo que garantiza la viabilidad y autonomía del estudio en sus etapas de entrenamiento y validación. No obstante, se mantiene la disposición para formalizar vínculos de colaboración técnica con organismos del sector en fases posteriores, con el fin de robustecer la transferencia tecnológica de los resultados obtenidos.

1.8. Planificación del Trabajo (Carta Gantt)

Para cumplir con los objetivos trazados de manera sistemática, se ha definido una carta Gantt de seis semanas de duración orientada a la ejecución técnica, evaluación del *Cold-Start* y consolidación de resultados (ver Figura 1.2).



Figura 1.2: Planificación estructurada en 6 semanas, categorizada según los Objetivos Específicos del proyecto.

Capítulo II

Marco Teórico

2. Marco Teórico

Este capítulo presenta los fundamentos teóricos necesarios para sustentar el desarrollo de la investigación. Se abordan los conceptos relacionados con la generación de energía fotovoltaica, el modelado de series de tiempo y las técnicas avanzadas de *Machine Learning* y *Deep Learning* empleadas para la predicción de energía bajo condiciones de escasez de datos.

2.1. Generación Fotovoltaica y Variables Meteorológicas

La generación de energía solar fotovoltaica corresponde al proceso de conversión directa de la radiación solar en electricidad. La potencia activa de salida de una planta fotovoltaica posee una dependencia estocástica respecto a múltiples variables atmosféricas dinámicas. La variable con mayor correlación directa es la Irradiancia Horizontal Global (GHI), definida como la cantidad total de radiación de onda corta recibida desde arriba por una superficie horizontal. Adicionalmente, factores térmicos y atmosféricos, tales como la temperatura ambiente, la velocidad del viento y la nubosidad, alteran la eficiencia de los paneles solares. En conjunto, la intermitencia de estas variables produce fluctuaciones severas en la inyección de energía a la red.

2.2. Series de Tiempo y Modelado Predictivo Tradicional

Una serie de tiempo se define como un conjunto ordenado de observaciones cuantitativas registradas en intervalos de tiempo regulares. El modelado predictivo consiste en analizar estas secuencias históricas para proyectar valores futuros. En el contexto del pronóstico energético, el modelado tradicional se fundamenta en un paradigma de aprendizaje local, donde los modelos operan sobre la premisa de contar con historiales de datos largos e ininterrumpidos pertenecientes a una sola estación.

Las arquitecturas clásicas incluyen tanto modelos estadísticos como métodos de aprendizaje automático (*Machine Learning*). Por un lado, algoritmos basados en ensambles de árboles de decisión, como *XGBoost*, han demostrado un alto desempeño predictivo al capturar interacciones no lineales de forma eficiente. Por otro lado, enfoques de aprendizaje profundo (*Deep Learning*) como las redes neuronales recurrentes *Long Short-Term Memory* (LSTM) [Hochreiter and Schmidhuber, 1997] introdujeron la capacidad de retener información de estados pasados mediante compuertas de memoria, permitiendo analizar la dinámica temporal y las dependencias a corto plazo en las lecturas de los sensores.

2.3. El Problema de Arranque en Frío (Cold-Start)

El concepto de *Cold-Start* (o arranque en frío) en el ámbito de las energías renovables se refiere a la incapacidad de un algoritmo predictivo para generar estimaciones confia-

bles debido a la falta parcial o total de datos históricos locales en una nueva instalación. Dado que los modelos locales estadísticos y de Machine Learning requieren extensos registros para modelar la estacionalidad climática anual y evitar el sobreajuste, la fase inicial de operación de un nuevo parque solar se caracteriza por una alta degradación predictiva, impactando la estabilidad de la red de transmisión.

2.4. Arquitecturas basadas en Transformers y Enfoques Modernos (N-HiTS)

La arquitectura Transformer [Vaswani et al., 2017] representa una disrupción en el procesamiento secuencial al eliminar la dependencia de recurrencia en favor del mecanismo de *Autoatención* (*Self-Attention*). A diferencia de las redes recurrentes como LSTM, los Transformers procesan secuencias completas en paralelo, reduciendo drásticamente la pérdida de gradientes a largo plazo.

Dentro del universo de arquitecturas basadas en atención para series de tiempo, el *Temporal Fusion Transformer* (TFT) destaca como una topología especialmente diseñada para escenarios multivariados. A diferencia de un Transformer convencional, el TFT integra módulos de selección de variables y redes neuronales especializadas para procesar de forma diferenciada atributos estáticos (como la ubicación geográfica de la planta) y atributos dinámicos (irradiancia, temperatura futura). Esta capacidad de segmentar los flujos de datos convierte al TFT en la arquitectura idónea para estructurar modelos espaciales robustos.

Paralelamente a los Transformers, han surgido redes profundas especializadas en análisis de series como el algoritmo *Neural Hierarchical Interpolation for Time Series Forecasting* (N-HiTS). Esta arquitectura se fundamenta en bloques de interpolación jerárquica y retropropagación de base polinomial, ofreciendo predicciones de altísima eficiencia a largo plazo y sirviendo como contraparte predictiva de última generación frente a los modelos puramente atencionales.

2.5. Transfer Learning y Aprendizaje Multi-Sitio

El aprendizaje por transferencia (*Transfer Learning*) es una técnica metodológica de redes neuronales donde el conocimiento extraído de la resolución de una tarea con abundancia de datos se transfiere y se ajusta para resolver un problema análogo en un dominio con escasez de datos.

En la predicción de generación solar, esta concepción se aplica bajo la técnica de aprendizaje multi-sitio (*Cross-Site Learning*). Consiste en el entrenamiento de un modelo de Deep Learning unificado (como el TFT) mediante la ingesta simultánea de datos correspondientes a un clúster de plantas fotovoltaicas distribuidas geográficamente. Al correlacionar atributos estáticos de las plantas junto con variables dinámicas globales, el modelo abstrae el comportamiento termodinámico fundamental subyacente. Poste-




Figura 2.3: Arquitectura del Temporal Fusion Transformer, destacando sus compuertas Gated Residual Networks (GRN) y su bloque de atención multipunto.

riormente, este modelo pre-entrenado es capaz de emitir pronósticos certeros para un nuevo dominio (nueva planta solar) reduciendo la exigencia inicial de poseer una base de datos local sustancial.




Figura 2.4: Flujo conceptual de transferencia de conocimiento global inter-plantas versus el entrenamiento local y aislado.

2.6. Conclusión acerca de las Herramientas Seleccionadas

A partir de la revisión de estos conceptos, queda sustentada la definición del arreglo metodológico final de este proyecto. El *Temporal Fusion Transformer* (TFT), la arquitectura atencional *Informer* y la red *N-HITS* han sido seleccionados como las arquitecturas

globales de *Deep Learning* predilectas para ejecutar el paradigma *Cross-Site Learning*. Contrastar estas potentes metodologías globalizadas en contraposición a las herramientas locales predictivas clásicas (*XGBoost* y *LSTM*) provee el marco analítico riguroso y necesario para cuantificar empíricamente cómo se mitiga el problema del *Cold-Start* en escenarios de escasez informativa extrema.

Capítulo III

Estado del Arte / Bechmarking

3. Estado del Arte / Benchmarking

Esta sección analiza críticamente los principales trabajos de la literatura científica reciente que abordan el pronóstico de generación fotovoltaica, la gestión de series temporales multivariadas bajo escasez de datos y el uso de técnicas de transferencia de conocimiento. La revisión clasifica los artículos bibliográficos según sus arquitecturas y metodologías, contrastando objetivamente las ventajas y limitaciones metodológicas expuestas por cada autor.

3.1. Modelos Base y Pronóstico de Ámbito Local

La investigación académica inicial del pronóstico fotovoltaico empleó predominantemente algoritmos ajustados con historiales climáticos de una sola ubicación. Zhao-yang Zhu et al. (2023) [Zhaoyang Zhu, 2023] exploraron la eficiencia algorítmica de distintos esquemas de regresión no lineal, demostrando la superioridad métrica del algoritmo *XGBoost* sobre técnicas de series puramente estadísticas.

- **Pros:** Alta eficiencia computacional y gran desempeño para identificar la importancia de características (*feature importance*) dentro de variables meteorológicas correlacionadas.
- **Contras:** La naturaleza basada en árboles sufre degradaciones severas y pérdida de la capacidad de extrapolación cuando los regímenes de datos de prueba (como los que suceden en un arranque en frío) carecen de historial de entrenamiento (*Cold-Start*).

Por su parte, Salinas et al. (2020) [Salinas et al., 2020] propusieron *DeepAR*, un modelo estructurado mediante redes recurrentes autorregresivas optimizadas para entregar densidades probabilísticas futuras en lugar de un estimador puntual.

- **Pros:** Permite cuantificar de forma analítica los intervalos de incertidumbre de la estimación solar diaria.
- **Contras:** El procesamiento secuencial característico del núcleo recurrente incrementa asintóticamente el tiempo de entrenamiento, limitando la habilidad práctica del algoritmo para ingerir largas secuencias climáticas de forma paralela.

3.2. Aplicación de Arquitecturas Transformer en Series Temporales

Para superar los obstáculos del procesamiento secuencial, los mecanismos de atención [Vaswani et al., 2017] fueron adaptados hacia ecosistemas temporales. Zhou et al. (2021) [Zhou et al., 2021] concibieron la arquitectura *Informer*, integrando una innovación de autoatención denominada *ProbSparse*.

- **Pros:** Al reducir el cálculo de atención de complejidad cuadrática a logarítmica, el modelo permite predecir eficientemente secuencias extremadamente extensas que antes colapsaban la memoria.
- **Contras:** El análisis puntual del mecanismo de atención tiende a fraccionar la contigüidad cronológica real de las fluctuaciones climáticas en la serie de tiempo.

A fin de retener dicho contexto, Nie et al. (2022) [Nie et al., 2022] publicaron *PatchTST*, un Transformer que preprocesa la señal temporal trozándola en ventanas sub-agrupadas (parches).

- **Pros:** Retiene satisfactoriamente la información semántica a nivel de vecindario temporal de la serie y se alza como líder sobre los índices de error de las líneas base recurrentes.
- **Contras:** Añade complejidad paramétrica al obligar a sintonizar heurísticamente la longitud del parche para cada frecuencia de resolución (horaria, diez-minutal) extraída de las plantas.

En un debate científico paralelo, Zeng et al. (2023) [Zeng et al., 2023] cuestionaron estadísticamente el predominio del Transformer, reportando escenarios en que combinaciones lineales de componentes simples batían consistentemente arquitecturas atencionales sobre-complejas.

3.3. Transfer Learning y Aprendizajes Globales Multi-Sitio

Finalmente, la discusión bibliográfica migra hacia la problemática del *Cold-Start*. Bak et al. (2025) [Bak et al., 2025] testearon empíricamente la efectividad de los esquemas de *Transfer Learning* agregando datos de gran escala desde diversas plantas operativas para el entrenamiento de bases preentrenadas.

- **Pros:** Demuestra empíricamente una atenuación de los márgenes de error durante las primeras semanas de operación en nuevos sitios geográficos.
- **Contras:** Todavía exige algoritmos de post-entrenamiento (ajuste fino) una vez logrados los primeros flujos de información local.

Alineado a ello, Damato et al. (2026) [Damato et al., 2026] ejecutaron un análisis paramétrico global versus local, resaltando que el aprendizaje cruzado inyecta un efecto estabilizador en conjuntos de datos propensos a cortes intermitentes en la transmisión de telemetría.

- **Pros:** Máxima tolerancia a registros ruidosos o fallas persistentes en los sensores, logrando proyecciones fiables por imputación contextual implícita.
- **Contras:** Impone requerimientos de infraestructura de *hardware* avanzados para soportar la fase de entrenamiento concurrente.

Arquitectura	Enfoque Paradigmático	Ventajas (Pros)	Limitaciones (Contras)
XGBoost	Machine Learning Local	Alta interpretabilidad de variables espaciales y rapidez computacional.	Degradación predictiva severa y sobreajuste ante escenarios de arranque en frío.
LSTM	Deep Learning Recurrente	Excelente modelado secuencial probabilístico a corto plazo.	Limitada capacidad para evaluar relaciones temporales lejanas; procesamiento lento.
Informer PatchTST /	Transformer Global	Mecanismos de atención eficientes para secuencias extendidas.	Complejidad paramétrica elevada para afinar el tamaño óptimo de los parches.
TFT	Transformer Multivariado	Arquitectura diseñada para segregar variables estáticas (planta) y dinámicas (clima).	Altos requerimientos de hardware para su entrenamiento inicial (Cross-Site).

Tabla 3.2: Síntesis comparativa de las arquitecturas predictivas expuestas en el estado del arte.

3.4. Conclusión del Estado del Arte y Aporte del Proyecto

La literatura académica indica que, si bien modelos predictivos locales basados en XGBoost o LSTM son altamente eficaces sobre bancos de datos de larga data, estos algoritmos son metodológicamente incapaces de operar solventemente frente al problema de escasez de datos tempranos (*Cold-Start*). Alternativamente, el *Cross-Site Learning* basado en arquitecturas avanzadas emerge como una solución robusta respaldada por investigaciones modernas.

Para abordar resolutivamente los desafíos expuestos en la literatura, este proyecto de título define como aporte metodológico central la implementación y evaluación de un marco predictivo *Cross-Site* (entrenamiento cruzado multi-sitio) soportado sobre el *Temporal Fusion Transformer* (TFT). La idoneidad del TFT se justifica científicamente por su capacidad intrínseca para fusionar variables temporales dinámicas y estáticas de forma asimétrica, característica vital para extrapolar conocimientos meteorológicos entre diferentes ubicaciones geográficas.

Para garantizar la rigurosidad del *benchmarking* y validar empíricamente la efectividad de la técnica frente a la escasez de datos, la investigación estipula un esquema de evaluación comparativo final cerrado, constituido por:

1. **Líneas Base Locales Tradicionales:** Utilización del algoritmo *XGBoost* y redes neuronales *LSTM*, ambos condicionados por su estricto entrenamiento aislado en plantas individuales.
2. **Arquitecturas Globales Profundas:** Despliegue de redes jerárquicas *N-HiTS* y las arquitecturas atencionales *Temporal Fusion Transformer* (TFT) e *Informer*, entrenadas bajo un paradigma de retención de una planta (*Leave-One-Plant-Out*) para medir escenarios de *Cold-Start* real.

Esta arquitectura de evaluación empírica permitirá dictaminar cuantitativamente si el *Temporal Fusion Transformer* es capaz de transferir el conocimiento climático generalizado de la flota operativa para mitigar los sesgos predictivos durante los arranques iniciales de los parques solares a nivel macrozonal.

Capítulo IV

Metodología y Propuesta de Solución

4. Metodología y Propuesta de Solución

4.1. Propuesta de Solución

La propuesta de solución consiste en el diseño e implementación de un modelo predictivo global basado en una arquitectura Transformer, el cual es pre-entrenado mediante un enfoque *Cross-Site Learning* sobre un conglomerado de plantas solares consolidadas. El propósito central es transferir este conocimiento climático hacia instalaciones nuevas que sufren de escasez de datos e intermitencias operativas (*Cold-Start*), logrando proyecciones estables desde sus primeros días de conexión a la red.

Con base en los requerimientos técnicos de integridad informativa, el alcance empírico abarca instalaciones solares consolidadas y agrupadas estratégicamente por Macrozona. En lugar de limitar la muestra a un número fijo de plantas en una única región, el enfoque *Cross-Site* capitaliza la diversidad geográfica y climática disponible, empleando algoritmos de imputación robustos para aquellos vacíos operativos manejables. Esta configuración garantiza que el modelo asimile una correlación termodinámica auténtica y representativa, permitiendo transferir el aprendizaje a nuevas instalaciones independientemente de su ubicación, siempre que compartan el perfil macrozonal. Desde la perspectiva algorítmica, el proyecto adopta la arquitectura *Temporal Fusion Transformer* (TFT) debido a su capacidad innata para procesar de forma asimétrica datos multimodales: asimilando variables dinámicas meteorológicas temporales en conjunto con características estáticas geográficas. Para dictaminar la efectividad de esta red frente a la problemática de arranque en frío, se contrastará su rendimiento de extrapolación (*Zero-Shot*) frente al algoritmo profundo *N-HITS* y contra las herramientas locales tradicionales (*XGBoost* y *LSTM*).



Figura 4.5: Representación esquemática de la propuesta de solución predictiva.

4.2. Adaptación Metodológica (Pipeline de Trabajo)

Para sistematizar la ejecución del proyecto y asegurar la replicabilidad de los experimentos, la investigación se apoya en un *pipeline* de *Machine Learning Operations* (MLOps) segmentado en cuatro fases metodológicas secuenciales implementadas en lenguaje Python.

Fase 0: Extracción, Transformación y Carga (ETL)

La fase fundacional del orquestador aborda el acondicionamiento integral de los datos estructurando el proceso en un modelo de capas secuenciales *Medallion* (Landing, Bronze, Silver y Gold). Para mitigar los cortes de sensores y evitar el *Data Leakage*, se definieron reglas estrictas:

1. **Variables Exógenas y Agrupación:** La imputación de variables meteorológicas se realiza escalonadamente (interpolación lineal y *ffill/bfill* por grupos temporales), y se incorpora una variable indicadora booleana (*dummy*) para señalar registros imputados. Además, se aplican características cíclicas (*seno/coseno*) para capturar estacionalidad y se impone un forzamiento a cero en la irradiancia global durante períodos nocturnos garantizados.
2. **Manejo Estricto del Target (Intocable):** A diferencia de las variables exógenas, la variable objetivo (generación de energía) no es sometida a ningún tipo de imputación ni se rellena con ceros lógicos. Si un registro horario está ausente, permanece como NaN en el vector final. Los modelos administran estas intermitencias mediante la reindexación de la grilla horaria, y las métricas penalizan exclusivamente sobre observaciones reales y existentes. Esta decisión asegura que el *Performance Ratio* no se distorsione sintéticamente.




Figura 4.6: Algoritmia del proceso de preparación de datos y control de calidad.

Fase 1: Sintonización de Hiperparámetros (Tuning)

Para garantizar una comparativa justa (*Benchmarking*) entre las redes profundas globales y los algoritmos tradicionales locales, es imperativo descubrir la configuración óptima de la topología de las redes. En esta etapa, el orquestador emplea heurísticas de búsqueda y validación cruzada para sintonizar los hiperparámetros críticos (tasa de aprendizaje, profundidad del codificador, número de cabezales de atención en el TFT y tamaño de la ventana temporal) maximizando el rendimiento predictivo inicial sobre el corpus histórico general antes de someter a los modelos al estrés del arranque en frío.

Fase 2: Simulación Cold-Start (Estrategia LOPO)

El núcleo de la experimentación reside en la aplicación de la metodología de retención espacial *Leave-One-Plant-Out* (LOPO). En lugar de dividir el set de datos cronológicamente, el orquestador aísla dinámicamente y oculta por completo el historial operativo de una de las plantas (capa *Gold* de validación). El modelo *Cross-Site* es entrenado exclusivamente con los años de experiencia del resto de la flota operativa. Para emular el arranque en frío (*Cold-Start*) de la planta seleccionada, el contexto histórico (*seed*) previo al horizonte de pronóstico se inicializa de forma 100% sintética ($y = \text{capacidad} \times \text{PR regional} \times \text{perfil solar}$), garantizando así que no exista *Data Leakage*. Dicho coeficiente de *Performance Ratio (PR) regional* se calcula como un agrupamiento histórico estratificado por Macrozona y Estación del Año, computado empleando única y estrictamente el conjunto de entrenamiento. Una vez consolidados los pesos sinápticos, la red es forzada a inferir el comportamiento energético futuro de la planta oculta utilizando únicamente sus coordenadas estáticas y el clima entrante. Este procedimiento se repite iterativamente rotando la instalación objetivo. Asimismo, la orquestación de esta fase admite la ejecución bajo distintas escalas (*Toy*, *Half* y *Total*) que modulan la fracción de la muestra analizada, agilizando el *benchmarking*.

Fase 3: Extracción de Resultados y Métricas de Rendimiento

La fase final consolida los vectores predictivos generados por cada una de las arquitecturas sometidas a prueba (TFT, Informer, N-HiTS, XGBoost Global/Local, LSTM) contrastándolos unificadamente contra la producción energética empírica de los parques solares aplicando 2 estrategias de testeo diferenciadas según la ventana temporal proyectada (*day1* para predicción a 24 horas y *rollout7d* para proyección expandida iterativa a una semana). Adicionalmente, los resultados y desvíos son evaluados de manera estratificada según la **Estación del Año**, lo que permite medir el impacto de la variabilidad meteorológica cíclica en las redes. El proyecto computa métricas clásicas de pronóstico, entre las cuales destacan:

- **Error Absoluto Medio (MAE):** Para cuantificar la magnitud promedio lineal del error en la escala energética real (MW).



Placeholder: Diagrama del esquema LOPO (Leave-One-Plant-Out)

Figura 4.7: Visualización iterativa del aislamiento espacial para simulación de arranque en frío.


- **Error Cuadrático Medio (RMSE):** Para penalizar logarítmicamente las desviaciones más grandes generadas por los sesgos del modelo durante picos de inyección.
- **Error Porcentual Absoluto Medio Simétrico (sMAPE):** Empleado como estándar de industria para dimensionar la falla en términos relativos porcentuales, independientemente de la capacidad instalada de la planta.
- **Pronóstico Probabilístico y MQLoss:** Las redes profundas evalúan también intervalos de confianza (90 % CI) para reportar la incertidumbre esperada y la cobertura del intervalo (*Pinball Loss*), sumando fiabilidad a la predicción puntual. Las predicciones finales son ajustadas para cumplir leyes físicas (mínimo de cero general y cero estricto de noche).

La consolidación de estas métricas se tabulará y graficará para facilitar el análisis comparativo financiero y operativo entre el modelo Transformer global y las líneas bases locales.

4.3. Estudio de Factibilidad

Factibilidad técnica

La factibilidad técnica de este proyecto está garantizada por la disponibilidad de herramientas de *software* de código abierto (*Open Source*) y librerías especializadas en *Machine Learning* y *Deep Learning*. Toda la orquestación del pipeline (ETL, entrenamiento y validación) se encuentra programada en *Python*, utilizando el ecosistema *Nixtla* (específicamente *NeuralForecast*) para la ejecución de los algoritmos atencionales de última generación (TFT y N-HiTS), así como *XGBoost* para las líneas base locales. Adicionalmente,



Placeholder: Gráficos de barra comparativos y proyecciones temporales de salida

Figura 4.8: Esquema comparativo de métricas de precisión entre arquitecturas locales y globales.



Placeholder: Carta Gantt del Proyecto (Capítulo 4)

Figura 4.9: Cronograma metodológico de actividades para la ejecución de la propuesta.

el procesamiento matricial intensivo requerido por el paradigma *Cross-Site Learning* se aborda mediante el uso de aceleración por hardware computacional (GPUs), recursos que son accesibles a través de entornos de desarrollo estándar.

Factibilidad operativa

No aplica.

Factibilidad económica

No aplica.

Factibilidad legal

No aplica.

Factibilidad Social

No aplica.

Factibilidad Ambiental

No aplica.

Capítulo V

Desarrollo de la Propuesta y Resultados

5. Desarrollo de la Propuesta y Resultados

Este capítulo documenta la ejecución de las cuatro fases metodológicas definidas en la Sección 4.2, junto a las evidencias y resultados obtenidos en cada una de ellas. Las evidencias complementarias (tablas completas de métricas por planta, registros de imputación y bitácoras de ejecución) se remiten a los Anexos.

5.1. Fase 0: Construcción del Pipeline de Datos (ETL)

La implementación del modelo de capas *Medallion* consolidó los registros horarios de generación del Coordinador Eléctrico Nacional (139 archivos mensuales, período 2014–2024) con las variables meteorológicas de la red CR2 (radiación global instantánea, temperatura del aire y humedad relativa), resultando en un corpus unificado de **94 plantas fotovoltaicas** y aproximadamente **4,37 millones de observaciones planta-hora** tras el proceso de depuración.

Durante la construcción de la capa *Bronze* se identificaron y resolvieron tres hallazgos relevantes de calidad de datos:

1. **Agregación multi-unidad:** centrales compuestas por múltiples unidades físicas de reporte (ej. PFV Jama, con dos unidades registradas bajo la misma central y una capacidad combinada de 51 MW) se consolidaron sumando la generación por hora, en coherencia con la capacidad declarada en el maestro de instalaciones.
2. **Transiciones de horario de verano (DST):** la hora repetida del primer domingo de abril se colapsó de forma segura (para generación solar corresponde a horas nocturnas de producción nula).
3. **Integridad del target:** en concordancia con la regla metodológica de no imputación de la variable objetivo, los vacíos de generación permanecen ausentes y las métricas se computan exclusivamente sobre observaciones reales.

La capa *Silver* incorporó las características cíclicas temporales (seno/coseno de hora, mes y estación), la asociación geográfica por Macrozona y la imputación trazable de exógenas (con variables indicadoras *is_imputed* y bitácora de imputación), mientras que la capa *Gold* materializó las particiones de validación LOPO por planta.

5.2. Fase 1: Sintonización de Hiperparámetros

La búsqueda de hiperparámetros se implementó mediante optimización bayesiana (*Optuna*), explorando la tasa de aprendizaje y la dimensión oculta de cada arquitectura global (mapeada al parámetro real de cada red: *encoder* en LSTM, unidades MLP por bloque en N-HiTS y dimensión del modelo en TFT e Informer). Para contener el costo computacional, la sintonización se ejecuta una única vez por arquitectura y estrategia



Figura 5.10: Flujo de datos implementado: Landing → Bronze → Silver → Gold.

de escala, reutilizando la configuración óptima en todos los pliegues LOPO; la fuga de información a nivel de hiperparámetros asociada a esta decisión se considera despreciable en la literatura de pronóstico global.

Adicionalmente, el entrenamiento incorpora detención temprana (*early stopping*) sobre una ventana de validación de 168 horas por serie, precisión mixta (fp16) en las arquitecturas numéricamente estables (TFT, N-HiTS) y precisión completa (fp32) en aquellas propensas a divergencia bajo aritmética reducida (LSTM, Informer).

5.3. Fase 2: Simulación Cold-Start (LOPO)

La evaluación *Leave-One-Plant-Out* se ejecutó conforme al diseño metodológico: para cada planta objetivo, los modelos globales se entrenan con las restantes $N - 1$ instalaciones y la inferencia se inicializa con un contexto histórico 100% sintético ($y = \text{capacidad} \times PR_{\text{regional}} \times \text{perfil solar}$), donde el *Performance Ratio* regional se computa estrictamente sobre el conjunto de entrenamiento, estratificado por Macrozona y estación del año.

Como refinamiento metodológico surgido durante el desarrollo, la evaluación incorpora un **análisis de sensibilidad sobre la definición de la ventana de evaluación**, motivado por la detección de *rampas de puesta en marcha*: períodos iniciales de las series (de días a semanas) con generación nula previa a la operación comercial sostenida. Se evalúan por planta:

- **Ventana Raw:** desde la primera hora registrada de la planta (fidel al registro histórico, incluye la rampa).
- **Ventana Operacional:** desde la primera hora de producción sostenida (definida como el primer instante productivo que inaugura al menos 10 horas con generación superior al 5% de la capacidad dentro de las 72 horas siguientes).

- **Ventanas Estacionales:** la primera ventana de producción sostenida cuyo inicio cae en cada una de las cuatro estaciones del año, permitiendo cuantificar el efecto de la variabilidad meteorológica cíclica sobre la transferencia *Cold-Start*.

Cada ventana se evalúa en los dos horizontes definidos (*day1* y *rollout7d*, este último con realimentación autorregresiva de la mediana predicha), y las ventanas de evaluación se excluyen íntegramente del entrenamiento del baseline local para prevenir contaminación *train-on-test*.

5.4. Fase 3: Resultados y Análisis Comparativo

Resultados Globales por Arquitectura

Análisis por Estación del Año

Análisis de Sensibilidad: Ventana Raw vs. Operacional

Calidad Probabilística de los Intervalos

Contraste de la Hipótesis

Capítulo VI

Conclusiones y Trabajo Futuro

6. Conclusiones y Trabajo Futuro

Conclusiones

Trabajos Futuros

Bibliografía

- Arslan, Z., Sahin, M. E., and Ulutas, H. (2025). Comparative evaluation of machine learning and transformer-based deep learning for solar energy forecasting on a real-world dataset. *Arabian Journal for Science and Engineering*, 51:6833–6863.
- Asociación Chilena de Energías Renovables y Almacenamiento (ACERA) (2025). Boletín estadístico acerca.
- Bai, S., Kolter, J. Z., and Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*.
- Bak, S., Choi, S., Yang, D., Kim, D., Rho, H., and Lee, K. (2025). Transfer learning for photovoltaic power forecasting across regions using large-scale datasets. *IEEE Access*.
- Benidis, K., Rangapuram, S. S., Flunkert, V., Wang, Y., Maddix, D., Turkmen, A. C., Gasthaus, J., Bohlke-Schneider, M., Salinas, D., and Stella, L. (2022). Deep learning for time series forecasting: Tutorial and literature survey. *ACM Computing Surveys*, 55(6):1–36.
- Comisión Nacional de Energía (2026). Reporte mensual sector energético. Technical report, Gobierno de Chile.
- Coordinador Eléctrico Nacional (2025). Informe del coordinador independiente del sistema eléctrico nacional. Technical report, CEN.
- Damato, S., Rubattu, N., Azzimonti, D., and Corani, G. (2026). Intermittent time series forecasting: local vs global models. *arXiv preprint arXiv:2601.14031*.
- El-Saieed, A. M. (2025). An adaptive transformer model for long-term time-series forecasting of temperature and radiation in photovoltaic energy generation. *Applied Computational Intelligence and Soft Computing*, 2025.
- Ember (2025). Reducing curtailment in chile: Key to unlocking the full potential of renewable energy.
- Energía Estratégica (2025). Alertan que los pmgd podrían enfrentar pérdidas por 7400 millones anuales si avanza la bolsa pyme en chile.
- Gu, A. and Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.

- Li, R., Wang, D., Wang, Z., Liang, S., Li, Z., Xie, Y., and He, J. (2024). Transformer approach to nowcasting solar energy using geostationary satellite data. *Applied Energy*, 353:122112.
- López Santos, M., García-Santiago, X., Echevarría Camarero, F., Blázquez Gil, G., and Carrasco Ortega, P. (2022). Application of temporal fusion transformer for day-ahead pv power forecasting. *Energies*, 15(14):5232.
- Mishra, A. et al. (2025). Spirit: Short-term prediction of solar irradiance for zero-shot transfer learning using foundation models. *arXiv preprint arXiv:2502.10307*.
- Nie, Y., Nguyen, N. H., Sinthong, P., and Kalagnanam, J. (2022). A time series is worth 64 words: Long-term forecasting with transformers. *arXiv preprint arXiv:2211.14730*.
- Oreshkin, B. N., Carpo, D., Chapados, N., and Bengio, Y. (2020). N-beats: Neural basis expansion analysis for interpretable time series forecasting. *arXiv preprint arXiv:1905.10437*.
- Salinas, D., Flunkert, V., Gasthaus, J., and Stella, L. (2020). Deepar: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3):1181–1191.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30.
- Zeng, A., Chen, M., Zhang, L., and Xu, Q. (2023). Are transformers effective for time series forecasting? In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 11121–11128.
- Zhaoyang Zhu, e. a. (2023). Energy forecasting with robust, flexible, and explainable machine learning algorithms. *AI Magazine*.
- Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., and Zhang, W. (2021). Informer: Beyond efficient transformer for long sequence time-series forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, pages 11106–11115.

Anexos

A. Repositorio del Proyecto

El código fuente completo del proyecto (pipelines de datos, entrenamiento, evaluación LOPO y generación de reportes), junto a su suite de pruebas automatizadas, se encuentra versionado en un repositorio Git.

B. Tablas Completas de Métricas por Planta

C. Registro de Imputación de Variables Exógenas

D. Hallazgos de Calidad de Datos