



UNIVERSIDAD CATÓLICA DEL MAULE
FACULTAD DE CIENCIAS DE LA INGENIERÍA
ESCUELA INGENIERÍA CIVIL INFORMÁTICA

**Análisis comparativo de un enfoque multi-sitio
frente a modelos locales para la proyección a
corto plazo de generación fotovoltaica bajo
escasez de datos**

César David Aular Muñoz
Dr. Sergio Hernández Álvarez

Proyecto de título para optar al Título de Ingeniero Civil Informático

TALCA, Junio 2026



UNIVERSIDAD CATÓLICA DEL MAULE

**FACULTAD DE CIENCIAS DE LA INGENIERÍA
ESCUELA INGENIERÍA CIVIL INFORMÁTICA**

Proyecto de título para optar al Título de Ingeniero Civil Informático

**Análisis comparativo de un enfoque multi-sitio frente a modelos locales para la
proyección a corto plazo de generación fotovoltaica bajo escasez de datos**

César David Aular Muñoz

COMISIÓN EXAMINADORA

FIRMA

PROFESOR GUÍA

Dr. Sergio Hernández Álvarez

PROFESOR COMISIÓN

PROFESOR COMISIÓN

PROFESOR COMISIÓN

PROFESOR COMISIÓN

NOTA FINAL EXAMEN DE TÍTULO:

TALCA, Junio 2026

AGRADECIMIENTOS

En esta sección puede escribir libremente siguiendo el mismo formato del documento. Se escribe en 1ra persona. Puede escribir esta sección al finalizar el resto de este documento. **Borre el texto que no es suyo** y comience a escribir.

RESUMEN

La expansión acelerada de la generación fotovoltaica enfrenta una barrera crítica durante la puesta en marcha de nuevas instalaciones: la ausencia de historial operativo local impide que los modelos predictivos tradicionales, entrenados de manera aislada por planta, entreguen proyecciones confiables (problema de *Cold-Start*). Esta incertidumbre algorítmica se traduce en ineficiencias operativas y riesgo financiero para los operadores del sistema eléctrico y los pequeños medios de generación distribuida.

El presente proyecto de título aborda este problema mediante el diseño, implementación y validación de un marco de aprendizaje multi-sitio (*Cross-Site Learning*), en el cual arquitecturas de *Deep Learning* de estado del arte —*Temporal Fusion Transformer* (TFT), *Informer* y *N-HiTS*— se entrenan de forma global sobre un conglomerado de plantas solares chilenas consolidadas, integrando datos multimodales: series de generación horaria (2014–2024), variables meteorológicas exógenas y características estáticas geográficas agrupadas por Macrozona.

La evaluación se estructura bajo el protocolo *Leave-One-Plant-Out* (LOPO), que oculta íntegramente la planta objetivo durante el entrenamiento y simula su arranque en frío inicializando la ventana de contexto con valores puramente sintéticos, derivados de un coeficiente de eficiencia regional calculado exclusivamente sobre el conjunto de entrenamiento. El desempeño se contrasta frente a líneas base entrenadas localmente (XGBoost y LSTM) en horizontes de 24 horas y de 7 días con realimentación autorregresiva, empleando métricas puntuales (RMSE, MAE, sMAPE, rRMSE) y probabilísticas (cobertura del intervalo de 90 % y pérdida Pinball), estratificadas por estación del año.

Los resultados sobre 47 plantas objetivo entregan un veredicto matizado: a igualdad de arquitectura profunda, la transferencia global supera al entrenamiento estrictamente local en el horizonte semanal pese a operar sin historia de la planta; no obstante, un modelo local maduro (XGBoost con un año de datos propios) conserva la mayor precisión absoluta. El valor del enfoque multi-sitio se confirma así en su dominio genuino —pronósticos utilizables desde la primera hora de conexión, donde el paradigma local es inviable—, identificándose además la mayor dificultad invernal y la subcalibración de los intervalos probabilísticos bajo transferencia como hallazgos relevantes para el uso operativo.

ABSTRACT

The accelerated expansion of photovoltaic generation faces a critical barrier during the commissioning of new facilities: the absence of local operating history prevents traditional forecasting models, trained in isolation for each plant, from delivering reliable projections (the *Cold-Start* problem). This algorithmic uncertainty translates into operational inefficiencies and financial risk for power-system operators and small distributed-generation actors.

This undergraduate thesis project addresses the problem through the design, implementation and validation of a *Cross-Site Learning* framework, in which state-of-the-art Deep Learning architectures—the *Temporal Fusion Transformer* (TFT), *Informer* and *N-HiTS*—are trained globally over a set of consolidated Chilean solar plants, integrating multimodal data: hourly generation series (2014–2024), exogenous meteorological variables and static geographic features grouped by macro-zone.

The evaluation follows a *Leave-One-Plant-Out* (LOPO) protocol, which completely hides the target plant during training and simulates its cold start by initializing the context window with purely synthetic values, derived from a regional efficiency coefficient computed strictly on the training set. Performance is contrasted against locally trained baselines (XGBoost and LSTM) over 24-hour and autoregressive 7-day horizons, using both point metrics (RMSE, MAE, sMAPE, rRMSE) and probabilistic metrics (90% interval coverage and Pinball loss), stratified by season of the year.

Results over 47 target plants deliver a nuanced verdict: at matched deep-learning architecture, global transfer outperforms strictly local training on the weekly horizon despite never observing the target plant, whereas a mature local model (XGBoost with one year of own history) retains the best absolute accuracy. The value of the multi-site approach is thus confirmed in its genuine domain—usable forecasts from the very first hour of grid connection, where the local paradigm is unfeasible—while winter emerges as the hardest season and the miscalibration of probabilistic intervals under transfer is identified as a key finding for operational use.

ÍNDICE DE CONTENIDOS

Capítulo I	1
1. Introducción y Objetivos	2
1.1. Introducción	2
1.2. Problemática	3
1.3. Cliente y/o Público objetivo	4
1.4. Objetivo General	4
1.5. Hipótesis	4
1.6. Alcance del Proyecto	5
1.7. Carta de Compromiso	6
1.8. Planificación del Trabajo (Carta Gantt)	7
Capítulo II	8
2. Marco Teórico	9
2.1. Generación Fotovoltaica y Variables Meteorológicas	9
2.2. Series de Tiempo y Modelado Predictivo Tradicional	9
2.3. El Problema de Arranque en Frío (Cold-Start)	9
2.4. Arquitecturas basadas en Transformers y Enfoques Modernos (N-HITS)	10
2.5. Transfer Learning y Aprendizaje Multi-Sitio	10
2.6. Conclusión acerca de las Herramientas Seleccionadas	12
Capítulo III	13
3. Estado del Arte / Benchmarking	14
3.1. Modelos Base y Pronóstico de Ámbito Local	14
3.2. Aplicación de Arquitecturas Transformer en Series Temporales	14
3.3. Transfer Learning y Aprendizajes Globales Multi-Sitio	15
3.4. Conclusión del Estado del Arte y Aporte del Proyecto	16
Capítulo IV	18
4. Metodología y Propuesta de Solución	19
4.1. Propuesta de Solución	19
4.2. Adaptación Metodológica (Pipeline de Trabajo)	19

4.3.	Estudio de Factibilidad	23
Capítulo V		25
5.	Desarrollo de la Propuesta y Resultados	26
5.1.	Fase 0: Construcción del Pipeline de Datos (ETL)	26
5.2.	Fase 1: Sintonización de Hiperparámetros	26
5.3.	Fase 2: Simulación Cold-Start (LOPO)	28
5.4.	Fase 3: Resultados y Análisis Comparativo	29
Capítulo VI		35
6.	Conclusiones y Trabajo Futuro	36
Bibliografía		38
Anexos		40
A.	Repositorio del Proyecto	41
B.	Métricas por Planta	41
C.	Registro de Imputación de Variables Exógenas	42
D.	Hallazgos de Calidad de Datos	43

LISTA DE FIGURAS

1.1. Distribución de las plantas fotovoltaicas de la muestra por macrozona (94 instalaciones; 1.876 MW de capacidad agregada).	6
1.2. Planificación estructurada en 6 semanas, categorizada según los Objetivos Específicos del proyecto.	7
2.3. Arquitectura del Temporal Fusion Transformer, destacando sus compuertas Gated Residual Networks (GRN) y su bloque de atención multipunto. . .	11
2.4. Flujo conceptual de transferencia de conocimiento global inter-plantas versus el entrenamiento local y aislado.	11
4.5. Representación esquemática de la propuesta de solución predictiva.	20
4.6. Algoritmia del proceso de preparación de datos y control de calidad.	21
4.7. Visualización iterativa del aislamiento espacial para simulación de arranque en frío.	22
4.8. Protocolo de evaluación Cold-Start: contexto sintético, horizontes de pronóstico y ventanas del análisis de sensibilidad sobre las cuales se computan las métricas comparativas.	23
5.9. Flujo de datos implementado: Landing → Bronze → Silver → Gold, con los volúmenes reales tras la depuración.	27
5.10. Error relativo mediano por arquitectura y horizonte en la ventana operacional.	30
5.11. Sensibilidad estacional del Cold-Start para cuatro arquitecturas representativas.	31
5.12. Ejemplo de roll-out Cold-Start de 7 días (LSTM global): el modelo, sin haber visto jamás la planta, reproduce el ciclo diario y la magnitud de los picos a partir del clima y la geografía. Se aprecia también el piso nocturno residual: el forzamiento físico a cero depende de la radiación observada en la estación meteorológica asociada, cuya imputación en huecos prolongados puede impedir su activación.	33

LISTA DE TABLAS

1.1. Resumen del impacto operativo y financiero por incertidumbre predictiva.	4
3.2. Síntesis comparativa de las arquitecturas predictivas expuestas en el estado del arte.	16
5.3. Composición del corpus unificado (capa Silver) por macrozona.	27
5.4. Hiperparámetros óptimos por arquitectura global (búsqueda bayesiana con Optuna, estrategia <i>half</i>), y precisión numérica de entrenamiento.	28
5.5. Métricas medianas por arquitectura y horizonte — ventana <i>Raw</i> (desde la primera hora registrada; 47 plantas).	29
5.6. Métricas medianas por arquitectura y horizonte — ventana <i>Operacional</i> (desde la primera producción sostenida; subconjunto de 15 plantas con rampa de puesta en marcha distinguible).	30
5.7. rRMSE mediano (%) del roll-out de 7 días por estación del año en que inicia la ventana de evaluación.	31
5.8. Calidad probabilística de los intervalos de 90 % (roll-out 7 días, ventana operacional): cobertura empírica y pérdidas Pinball medianas.	32
C.10. Horas-planta imputadas en la capa Silver por variable exógena y macrozona.	42

Capítulo I

Introducción y Objetivos

1. Introducción y Objetivos

1.1. Introducción

En las últimas décadas, la energía solar ha cobrado una gran relevancia, llegando a representar una parte sustancial de la generación de energía renovable a nivel mundial gracias a los avances en las tecnologías fotovoltaicas y a la creciente demanda energética. La expansión de la infraestructura de energía solar es un pilar fundamental para la electrificación, la transición energética global y el cumplimiento de los compromisos de cero emisiones netas para mitigar los efectos del cambio climático. Sin embargo, la generación fotovoltaica está sujeta a una alta variabilidad e intermitencia, ya que depende directamente de factores meteorológicos dinámicos como la Irradiancia Horizontal Global (GHI), la temperatura, la nubosidad y la velocidad del viento. Por lo tanto, la estimación precisa de la productividad en plantas de energía renovable es un desafío crítico para la planificación, operación y optimización de los sistemas energéticos de la red.

Tradicionalmente, los modelos predictivos de generación solar se han abordado mediante técnicas estadísticas y algoritmos clásicos que se entrenan de manera local utilizando los datos históricos específicos de cada planta. Este enfoque presenta dos limitaciones fundamentales. En primer lugar, dependen fuertemente de la disponibilidad de un volumen considerable de datos históricos locales, lo cual dificulta enormemente su aplicación en escenarios de puesta en marcha de nuevas instalaciones (el problema de *cold-start* o arranque en frío). En segundo lugar, omiten el aprovechamiento de los patrones meteorológicos y operativos que son compartidos entre distintas plantas y regiones climáticas, los cuales poseen un alto valor para mejorar la capacidad predictiva y la generalización de los modelos.

Para superar estas barreras de disponibilidad de datos, la investigación reciente ha comenzado a integrar técnicas avanzadas de Deep Learning, donde arquitecturas como los Transformers (ej. Temporal Fusion Transformer, Informer o PatchTST) han demostrado una capacidad superior para procesar secuencias largas y extraer dependencias temporales complejas a partir de datos meteorológicos multivariados. Complementariamente, el uso de enfoques de *Transfer Learning* (aprendizaje por transferencia) permite que un modelo pre-entrenado a partir de bases de datos a gran escala y de múltiples regiones transfiera características y patrones climáticos generales hacia instalaciones locales con escasez de datos.

El presente proyecto busca abordar el problema del *cold-start* a través del desarrollo y validación de una arquitectura de "*Cross-Site Learning*" (aprendizaje multi-sitio). Mediante el uso de un modelo Transformer de estado del arte, el proceso de entrenamiento se adaptará para aprender simultáneamente de múltiples series temporales de distintas plantas solares, integrando variables exógenas dinámicas (clima) y características estáticas (ubicación geográfica).

El desarrollo de este proyecto aporta valor empírico y metodológico en dos frentes principales. En primer lugar, proporciona una herramienta validada para la industria,

permitiendo a los operadores estimar con mayor precisión la producción de nuevos parques solares desde sus etapas iniciales sin depender de recolecciones de datos locales prolongadas. En segundo lugar, aporta evidencia sólida sobre la eficacia de aplicar técnicas de *Transfer Learning* y arquitecturas Transformer en series de tiempo energéticas, estableciendo un marco de evaluación riguroso frente a modelos tradicionales de Machine Learning (como XGBoost o LSTM) entrenados de manera estrictamente local.

1.2. Problemática

La transición hacia una matriz energética sostenible ha impulsado una expansión acelerada de proyectos fotovoltaicos. Tal como indica la Comisión Nacional de Energía (2026), el 75 % de los 5.333 MW de nueva capacidad eléctrica actualmente en etapa de construcción en el país corresponde a parques solares. Sin embargo, esta inyección masiva de energía choca con una barrera crítica para la toma de decisiones: la escasez de datos meteorológicos y operativos durante las etapas iniciales de un proyecto. Para generar proyecciones confiables y superar el problema del Cold-Start, los algoritmos predictivos tradicionales —entrenados de manera aislada para cada instalación— requieren de un mínimo de un año ininterrumpido de registros locales (Zhaoyang Zhu, 2023). Esto fomenta un profundo aislamiento del aprendizaje técnico, impidiendo que el conocimiento atmosférico generalizado (enfoque Multi-Sitio) se transfiera, lo que condena a los nuevos actores del mercado a operar con altos niveles de incertidumbre algorítmica desde su puesta en marcha.

Esta falta de predictibilidad a corto plazo desencadena severas ineficiencias operativas y un alto riesgo financiero a lo largo de la red. A nivel sistémico, el Coordinador Eléctrico Nacional (2025) reporta que las imprecisiones en los pronósticos de inyección renovable han introducido un error financiero del 4,62 % sobre la estimación de los costos operativos totales del Sistema Eléctrico Nacional. Más grave aún, la incapacidad de anticipar con exactitud la generación exacerba los cuellos de botella en la transmisión, derivando en niveles críticos de vertimiento de energía limpia (curtailment). Durante 2025, el vertimiento físico alcanzó los 6.084 GWh (Asociación Chilena de Energías Renovables y Almacenamiento (ACERA), 2025), lo que se ha traducido en pérdidas de ingresos para las generadoras equivalentes a 562 millones de dólares acumulados en los últimos tres años (Ember, 2025). Finalmente, en el ecosistema a menor escala, esta incertidumbre algorítmica expone directamente a los Pequeños Medios de Generación Distribuida (PMGD) a un riesgo de mermas financieras estimado en hasta 7.400 millones de dólares anuales ante la falta de certeza horaria en sus esquemas de inyección (Energía Estratégica, 2025).

Variable / Métrica	Magnitud Estimada	Fuente de Referencia
Capacidad solar en construcción	75 % del total (MW)	Comisión Nacional de Energía (2026)
Error financiero sistémico	4,62 % de costos operativos	Coordinador Eléctrico Nacional (2025)
Vertimiento físico anual	6.084 GWh	ACERA (2025)
Pérdida por vertimiento (3 años)	562 Millones USD	Ember (2025)

Tabla 1.1: Resumen del impacto operativo y financiero por incertidumbre predictiva.

1.3. Cliente y/o Público objetivo

El público objetivo y los principales beneficiarios de esta solución abarcan un espectro amplio dentro del ecosistema de generación de energía renovable. En primer lugar, la herramienta se orienta a operadores, administradores de parques solares a gran escala y coordinadores de redes eléctricas, quienes requieren sistemas predictivos robustos para minimizar la incertidumbre en la toma de decisiones, optimizando la planificación energética y reduciendo el riesgo financiero ante desvíos en el despacho durante las etapas iniciales de una planta.

En segundo lugar, esta propuesta integra a los actores del segmento de Pequeños Medios de Generación Distribuida (PMGD) y a los desarrolladores de sistemas de autoconsumo fotovoltaico a pequeña y mediana escala (comercial e industrial). Para este nicho, donde la instalación de sensorica avanzada o la recopilación de años de datos locales resulta económicamente inviable, un modelo multi-sitio pre-entrenado les permitirá acceder a proyecciones a corto plazo continuas y confiables desde su puesta en marcha, permitiendo rentabilizar sus operaciones y gestionar su inyección a la red sin la barrera de entrada que supone el modelado de datos aislado y tradicional.

1.4. Objetivo General

Analizar y comparar el desempeño de un modelo global de aprendizaje multi-sitio frente a modelos locales entrenados con datos históricos, en la estimación de la productividad de plantas de energía renovable, considerando su capacidad de generalización y su rendimiento en escenarios de escasez de datos e intermitencia.

1.5. Hipótesis

La implementación de un modelo globalmente entrenado con información proveniente de centros meteorológicamente variados, es capaz de usar información generalizada respecto de las variaciones en las condiciones atmosféricas para obtener un mejor

resultado respecto de la producción de energía de una planta de producción desconocida, siendo más precisa que un modelo localmente entrenado solo con la información histórica del centro.

Objetivos Específicos

1. Seleccionar y configurar una arquitectura Transformer preexistente que sea adecuada para el pronóstico de series de tiempo. Posteriormente, adaptar su proceso de entrenamiento con el fin de que el modelo sea capaz de procesar y aprender de manera simultánea a partir de múltiples series temporales provenientes de diferentes plantas solares, reemplazando así el tradicional enfoque de entrenamiento aislado.
2. Evaluar la efectividad del modelo global pre-entrenado durante la puesta en marcha de una nueva planta renovable que cuente con una escasa cantidad de datos con respecto a modelos tradicionales (como XGBoost o LSTM) entrenados de manera estrictamente local.
3. Integrar datos multimodales para dotar al modelo de la capacidad de procesar diversas fuentes de información, integrando de manera conjunta tanto variables exógenas dinámicas, que representan las condiciones meteorológicas, como características estáticas referentes a la ubicación espacial y geográfica de cada estación.

1.6. Alcance del Proyecto

Con el propósito de analizar y comparar el desempeño predictivo de modelos globales frente a modelos locales, el alcance de este proyecto se focaliza en el dominio de la producción de energía solar mediante el estudio de un conjunto consolidado de instalaciones agrupadas bajo un criterio de Macrozona. Esta estrategia de agrupación responde a la necesidad de estabilizar las características climáticas compartidas y escalar el aprendizaje cruzado entre plantas. Esta configuración experimental permite integrar series de tiempo de producción y variables meteorológicas de alta fidelidad para evaluar la capacidad de generalización y la respuesta del modelo ante la escasez de datos. Técnicamente, el trabajo se concentra en la parametrización, el entrenamiento multi-sitio y la validación de arquitecturas de estado del arte (TFT, Informer, N-HiTS), empleando modelos XGBoost y LSTM como líneas base comparativas. Finalmente, para mantener el foco en la evaluación del rendimiento del modelado, se excluyen explícitamente el desarrollo de nuevas estrategias o metodologías desde cero, el despliegue en entornos de producción (MLOps), la integración con sistemas SCADA y cualquier análisis de viabilidad financiera o rentabilidad operativa sobre los activos estudiados. De manera que el proyecto se compone de la recopilación y preprocesado de datos, la configuración de la

estrategia de orquestación para el testeo, el entrenamiento de los modelos base, la ejecución y posterior comparación entre el modelo globalmente entrenado y las baseline en situaciones de “Cold-Start”. Todo circunscrito por un repositorio con los pipelines de datos, entrenamiento y posterior testeo.




Figura 1.1: Distribución de las plantas fotovoltaicas de la muestra por macrozona (94 instalaciones; 1.876 MW de capacidad agregada).

1.7. Carta de Compromiso

Dada la naturaleza de la presente investigación, el desarrollo del modelo no se encuentra aunado a la intervención o patrocinio exclusivo de una entidad privada específica para su ejecución técnica. El acceso a los activos de datos necesarios para el cumplimiento de los objetivos planteados ha sido gestionado bajo protocolos internos, lo que garantiza la viabilidad y autonomía del estudio en sus etapas de entrenamiento y validación. No obstante, se mantiene la disposición para formalizar vínculos de colaboración técnica con organismos del sector en fases posteriores, con el fin de robustecer la transferencia tecnológica de los resultados obtenidos.

1.8. Planificación del Trabajo (Carta Gantt)

Para cumplir con los objetivos trazados de manera sistemática, se ha definido una carta Gantt de seis semanas de duración orientada a la ejecución técnica, evaluación del *Cold-Start* y consolidación de resultados (ver Figura 1.2).




Figura 1.2: Planificación estructurada en 6 semanas, categorizada según los Objetivos Específicos del proyecto.

Capítulo II

Marco Teórico

2. Marco Teórico

Este capítulo presenta los fundamentos teóricos necesarios para sustentar el desarrollo de la investigación. Se abordan los conceptos relacionados con la generación de energía fotovoltaica, el modelado de series de tiempo y las técnicas avanzadas de *Machine Learning* y *Deep Learning* empleadas para la predicción de energía bajo condiciones de escasez de datos.

2.1. Generación Fotovoltaica y Variables Meteorológicas

La generación de energía solar fotovoltaica corresponde al proceso de conversión directa de la radiación solar en electricidad. La potencia activa de salida de una planta fotovoltaica posee una dependencia estocástica respecto a múltiples variables atmosféricas dinámicas. La variable con mayor correlación directa es la Irradiancia Horizontal Global (GHI), definida como la cantidad total de radiación de onda corta recibida desde arriba por una superficie horizontal. Adicionalmente, factores térmicos y atmosféricos, tales como la temperatura ambiente, la velocidad del viento y la nubosidad, alteran la eficiencia de los paneles solares. En conjunto, la intermitencia de estas variables produce fluctuaciones severas en la inyección de energía a la red.

2.2. Series de Tiempo y Modelado Predictivo Tradicional

Una serie de tiempo se define como un conjunto ordenado de observaciones cuantitativas registradas en intervalos de tiempo regulares. El modelado predictivo consiste en analizar estas secuencias históricas para proyectar valores futuros. En el contexto del pronóstico energético, el modelado tradicional se fundamenta en un paradigma de aprendizaje local, donde los modelos operan sobre la premisa de contar con historiales de datos largos e ininterrumpidos pertenecientes a una sola estación.

Las arquitecturas clásicas incluyen tanto modelos estadísticos como métodos de aprendizaje automático (*Machine Learning*). Por un lado, algoritmos basados en ensambles de árboles de decisión, como *XGBoost*, han demostrado un alto desempeño predictivo al capturar interacciones no lineales de forma eficiente. Por otro lado, enfoques de aprendizaje profundo (*Deep Learning*) como las redes neuronales recurrentes *Long Short-Term Memory* (LSTM) [Hochreiter and Schmidhuber, 1997] introdujeron la capacidad de retener información de estados pasados mediante compuertas de memoria, permitiendo analizar la dinámica temporal y las dependencias a corto plazo en las lecturas de los sensores.

2.3. El Problema de Arranque en Frío (Cold-Start)

El concepto de *Cold-Start* (o arranque en frío) en el ámbito de las energías renovables se refiere a la incapacidad de un algoritmo predictivo para generar estimaciones confia-

bles debido a la falta parcial o total de datos históricos locales en una nueva instalación. Dado que los modelos locales estadísticos y de Machine Learning requieren extensos registros para modelar la estacionalidad climática anual y evitar el sobreajuste, la fase inicial de operación de un nuevo parque solar se caracteriza por una alta degradación predictiva, impactando la estabilidad de la red de transmisión.

2.4. Arquitecturas basadas en Transformers y Enfoques Modernos (N-HiTS)

La arquitectura Transformer [Vaswani et al., 2017] representa una disrupción en el procesamiento secuencial al eliminar la dependencia de recurrencia en favor del mecanismo de *Autoatención* (*Self-Attention*). A diferencia de las redes recurrentes como LSTM, los Transformers procesan secuencias completas en paralelo, reduciendo drásticamente la pérdida de gradientes a largo plazo.

Dentro del universo de arquitecturas basadas en atención para series de tiempo, el *Temporal Fusion Transformer* (TFT) destaca como una topología especialmente diseñada para escenarios multivariados. A diferencia de un Transformer convencional, el TFT integra módulos de selección de variables y redes neuronales especializadas para procesar de forma diferenciada atributos estáticos (como la ubicación geográfica de la planta) y atributos dinámicos (irradiancia, temperatura futura). Esta capacidad de segmentar los flujos de datos convierte al TFT en la arquitectura idónea para estructurar modelos espaciales robustos.

Paralelamente a los Transformers, han surgido redes profundas especializadas en análisis de series como el algoritmo *Neural Hierarchical Interpolation for Time Series Forecasting* (N-HiTS). Esta arquitectura se fundamenta en bloques de interpolación jerárquica y retropropagación de base polinomial, ofreciendo predicciones de altísima eficiencia a largo plazo y sirviendo como contraparte predictiva de última generación frente a los modelos puramente atencionales.

2.5. Transfer Learning y Aprendizaje Multi-Sitio

El aprendizaje por transferencia (*Transfer Learning*) es una técnica metodológica de redes neuronales donde el conocimiento extraído de la resolución de una tarea con abundancia de datos se transfiere y se ajusta para resolver un problema análogo en un dominio con escasez de datos.

En la predicción de generación solar, esta concepción se aplica bajo la técnica de aprendizaje multi-sitio (*Cross-Site Learning*). Consiste en el entrenamiento de un modelo de Deep Learning unificado (como el TFT) mediante la ingesta simultánea de datos correspondientes a un clúster de plantas fotovoltaicas distribuidas geográficamente. Al correlacionar atributos estáticos de las plantas junto con variables dinámicas globales, el modelo abstrae el comportamiento termodinámico fundamental subyacente. Poste-

Arquitectura del Temporal Fusion Transformer (Lim et al., 2021)




Figura 2.3: Arquitectura del Temporal Fusion Transformer, destacando sus compuertas Gated Residual Networks (GRN) y su bloque de atención multipunto.

riormente, este modelo pre-entrenado es capaz de emitir pronósticos certeros para un nuevo dominio (nueva planta solar) reduciendo la exigencia inicial de poseer una base de datos local sustancial.

2.6. Conclusión acerca de las Herramientas Seleccionadas

A partir de la revisión de estos conceptos, queda sustentada la definición del arreglo metodológico final de este proyecto. El *Temporal Fusion Transformer* (TFT), la arquitectura atencional *Informer* y la red *N-HITS* han sido seleccionados como las arquitecturas globales de *Deep Learning* predilectas para ejecutar el paradigma *Cross-Site Learning*. Contrastar estas potentes metodologías globalizadas en contraposición a las herramientas locales predictivas clásicas (*XGBoost* y *LSTM*) provee el marco analítico riguroso y necesario para cuantificar empíricamente cómo se mitiga el problema del *Cold-Start* en escenarios de escasez informativa extrema.




Figura 2.4: Flujo conceptual de transferencia de conocimiento global inter-plantas versus el entrenamiento local y aislado.

Capítulo III

Estado del Arte / Bechmarking

3. Estado del Arte / Benchmarking

Esta sección analiza críticamente los principales trabajos de la literatura científica reciente que abordan el pronóstico de generación fotovoltaica, la gestión de series temporales multivariadas bajo escasez de datos y el uso de técnicas de transferencia de conocimiento. La revisión clasifica los artículos bibliográficos según sus arquitecturas y metodologías, contrastando objetivamente las ventajas y limitaciones metodológicas expuestas por cada autor.

3.1. Modelos Base y Pronóstico de Ámbito Local

La investigación académica inicial del pronóstico fotovoltaico empleó predominantemente algoritmos ajustados con historiales climáticos de una sola ubicación. Zhao-yang Zhu et al. (2023) [Zhaoyang Zhu, 2023] exploraron la eficiencia algorítmica de distintos esquemas de regresión no lineal, demostrando la superioridad métrica del algoritmo *XGBoost* sobre técnicas de series puramente estadísticas.

- **Pros:** Alta eficiencia computacional y gran desempeño para identificar la importancia de características (*feature importance*) dentro de variables meteorológicas correlacionadas.
- **Contras:** La naturaleza basada en árboles sufre degradaciones severas y pérdida de la capacidad de extrapolación cuando los regímenes de datos de prueba (como los que suceden en un arranque en frío) carecen de historial de entrenamiento (*Cold-Start*).

Por su parte, Salinas et al. (2020) [Salinas et al., 2020] propusieron *DeepAR*, un modelo estructurado mediante redes recurrentes autorregresivas optimizadas para entregar densidades probabilísticas futuras en lugar de un estimador puntual.

- **Pros:** Permite cuantificar de forma analítica los intervalos de incertidumbre de la estimación solar diaria.
- **Contras:** El procesamiento secuencial característico del núcleo recurrente incrementa asintóticamente el tiempo de entrenamiento, limitando la habilidad práctica del algoritmo para ingerir largas secuencias climáticas de forma paralela.

3.2. Aplicación de Arquitecturas Transformer en Series Temporales

Para superar los obstáculos del procesamiento secuencial, los mecanismos de atención [Vaswani et al., 2017] fueron adaptados hacia ecosistemas temporales. Zhou et al. (2021) [Zhou et al., 2021] concibieron la arquitectura *Informer*, integrando una innovación de autoatención denominada *ProbSparse*.

- **Pros:** Al reducir el cálculo de atención de complejidad cuadrática a logarítmica, el modelo permite predecir eficientemente secuencias extremadamente extensas que antes colapsaban la memoria.
- **Contras:** El análisis puntual del mecanismo de atención tiende a fraccionar la contigüidad cronológica real de las fluctuaciones climáticas en la serie de tiempo.

A fin de retener dicho contexto, Nie et al. (2022) [Nie et al., 2022] publicaron *PatchTST*, un Transformer que preprocesa la señal temporal trozándola en ventanas sub-agrupadas (parches).

- **Pros:** Retiene satisfactoriamente la información semántica a nivel de vecindario temporal de la serie y se alza como líder sobre los índices de error de las líneas base recurrentes.
- **Contras:** Añade complejidad paramétrica al obligar a sintonizar heurísticamente la longitud del parche para cada frecuencia de resolución (horaria, diez-minutal) extraída de las plantas.

En un debate científico paralelo, Zeng et al. (2023) [Zeng et al., 2023] cuestionaron estadísticamente el predominio del Transformer, reportando escenarios en que combinaciones lineales de componentes simples batían consistentemente arquitecturas atencionales sobre-complejas.

3.3. Transfer Learning y Aprendizajes Globales Multi-Sitio

Finalmente, la discusión bibliográfica migra hacia la problemática del *Cold-Start*. Bak et al. (2025) [Bak et al., 2025] testearon empíricamente la efectividad de los esquemas de *Transfer Learning* agregando datos de gran escala desde diversas plantas operativas para el entrenamiento de bases preentrenadas.

- **Pros:** Demuestra empíricamente una atenuación de los márgenes de error durante las primeras semanas de operación en nuevos sitios geográficos.
- **Contras:** Todavía exige algoritmos de post-entrenamiento (ajuste fino) una vez logrados los primeros flujos de información local.

Alineado a ello, Damato et al. (2026) [Damato et al., 2026] ejecutaron un análisis paramétrico global versus local, resaltando que el aprendizaje cruzado inyecta un efecto estabilizador en conjuntos de datos propensos a cortes intermitentes en la transmisión de telemetría.

- **Pros:** Máxima tolerancia a registros ruidosos o fallas persistentes en los sensores, logrando proyecciones fiables por imputación contextual implícita.
- **Contras:** Impone requerimientos de infraestructura de *hardware* avanzados para soportar la fase de entrenamiento concurrente.

Arquitectura	Enfoque Paradigmático	Ventajas (Pros)	Limitaciones (Contras)
XGBoost	Machine Learning Local	Alta interpretabilidad de variables espaciales y rapidez computacional.	Degradación predictiva severa y sobreajuste ante escenarios de arranque en frío.
LSTM	Deep Learning Recurrente	Excelente modelado secuencial probabilístico a corto plazo.	Limitada capacidad para evaluar relaciones temporales lejanas; procesamiento lento.
Informer / PatchTST	Transformer Global	Mecanismos de atención eficientes para secuencias extendidas.	Complejidad paramétrica elevada para afinar el tamaño óptimo de los parches.
TFT	Transformer Multivariado	Arquitectura diseñada para segregar variables estáticas (planta) y dinámicas (clima).	Altos requerimientos de hardware para su entrenamiento inicial (Cross-Site).

Tabla 3.2: Síntesis comparativa de las arquitecturas predictivas expuestas en el estado del arte.

3.4. Conclusión del Estado del Arte y Aporte del Proyecto

La literatura académica indica que, si bien modelos predictivos locales basados en XGBoost o LSTM son altamente eficaces sobre bancos de datos de larga data, estos algoritmos son metodológicamente incapaces de operar solventemente frente al problema de escasez de datos tempranos (*Cold-Start*). Alternativamente, el *Cross-Site Learning* basado en arquitecturas avanzadas emerge como una solución robusta respaldada por investigaciones modernas.

Para abordar resolutivamente los desafíos expuestos en la literatura, este proyecto de título define como aporte metodológico central la implementación y evaluación de un marco predictivo *Cross-Site* (entrenamiento cruzado multi-sitio) soportado sobre el *Temporal Fusion Transformer* (TFT). La idoneidad del TFT se justifica científicamente por su capacidad intrínseca para fusionar variables temporales dinámicas y estáticas de forma asimétrica, característica vital para extrapolar conocimientos meteorológicos entre diferentes ubicaciones geográficas.

Para garantizar la rigurosidad del *benchmarking* y validar empíricamente la efectividad de la técnica frente a la escasez de datos, la investigación estipula un esquema de evaluación comparativo final cerrado, constituido por:

1. **Líneas Base Locales Tradicionales:** Utilización del algoritmo *XGBoost* y redes neuronales *LSTM*, ambos condicionados por su estricto entrenamiento aislado en plantas individuales.
2. **Arquitecturas Globales Profundas:** Despliegue de redes jerárquicas *N-HiTS* y las arquitecturas atencionales *Temporal Fusion Transformer* (TFT) e *Informer*, entrenadas bajo un paradigma de retención de una planta (*Leave-One-Plant-Out*) para medir escenarios de *Cold-Start* real.

Esta arquitectura de evaluación empírica permitirá dictaminar cuantitativamente si el *Temporal Fusion Transformer* es capaz de transferir el conocimiento climático generalizado de la flota operativa para mitigar los sesgos predictivos durante los arranques iniciales de los parques solares a nivel macrozonal.

Capítulo IV

Metodología y Propuesta de Solución

4. Metodología y Propuesta de Solución

4.1. Propuesta de Solución

La propuesta de solución consiste en el diseño e implementación de un modelo predictivo global basado en una arquitectura Transformer, el cual es pre-entrenado mediante un enfoque *Cross-Site Learning* sobre un conglomerado de plantas solares consolidadas. El propósito central es transferir este conocimiento climático hacia instalaciones nuevas que sufren de escasez de datos e intermitencias operativas (*Cold-Start*), logrando proyecciones estables desde sus primeros días de conexión a la red.

Con base en los requerimientos técnicos de integridad informativa, el alcance empírico abarca instalaciones solares consolidadas y agrupadas estratégicamente por Macrozona. En lugar de limitar la muestra a un número fijo de plantas en una única región, el enfoque *Cross-Site* capitaliza la diversidad geográfica y climática disponible, empleando algoritmos de imputación robustos para aquellos vacíos operativos manejables. Esta configuración garantiza que el modelo asimile una correlación termodinámica auténtica y representativa, permitiendo transferir el aprendizaje a nuevas instalaciones independientemente de su ubicación, siempre que compartan el perfil macrozonal. Desde la perspectiva algorítmica, el proyecto adopta la arquitectura *Temporal Fusion Transformer* (TFT) debido a su capacidad innata para procesar de forma asimétrica datos multimodales: asimilando variables dinámicas meteorológicas temporales en conjunto con características estáticas geográficas. Para dictaminar la efectividad de esta red frente a la problemática de arranque en frío, se contrastará su rendimiento de extrapolación (*Zero-Shot*) frente al algoritmo profundo *N-HiTS* y contra las herramientas locales tradicionales (*XGBoost* y *LSTM*).

4.2. Adaptación Metodológica (Pipeline de Trabajo)

Para sistematizar la ejecución del proyecto y asegurar la replicabilidad de los experimentos, la investigación se apoya en un *pipeline* de *Machine Learning Operations* (MLOps) segmentado en cuatro fases metodológicas secuenciales implementadas en lenguaje Python.

Fase 0: Extracción, Transformación y Carga (ETL)

La fase fundacional del orquestador aborda el acondicionamiento integral de los datos estructurando el proceso en un modelo de capas secuenciales *Medallion* (Landing, Bronze, Silver y Gold). Para mitigar los cortes de sensores y evitar el *Data Leakage*, se definieron reglas estrictas:

1. **Variables Exógenas y Agrupación:** La imputación de variables meteorológicas se realiza escalonadamente (interpolación lineal y *ffill/bfill* por grupos temporales),

Transferencia Cross-Site: pre-entrenamiento multi-planta e inferencia sobre una planta sin historia




Figura 4.5: Representación esquemática de la propuesta de solución predictiva.

y se incorpora una variable indicadora booleana (*dummy*) para señalar registros imputados. Además, se aplican características cíclicas (*seno/coseno*) para capturar estacionalidad y se impone un forzamiento a cero en la irradiancia global durante períodos nocturnos garantizados.

2. **Manejo Estricto del Target (Intocable):** A diferencia de las variables exógenas, la variable objetivo (generación de energía) no es sometida a ningún tipo de imputación ni se rellena con ceros lógicos. Si un registro horario está ausente, permanece como NaN en el vector final. Los modelos administran estas intermitencias mediante la reindexación de la grilla horaria, y las métricas penalizan exclusivamente sobre observaciones reales y existentes. Esta decisión asegura que el *Performance Ratio* no se distorsione sintéticamente.

Fase 1: Sintonización de Hiperparámetros (Tuning)

Para garantizar una comparativa justa (*Benchmarking*) entre las redes profundas globales y los algoritmos tradicionales locales, es imperativo descubrir la configuración óptima de la topología de las redes. En esta etapa, el orquestador emplea heurísticas de búsqueda y validación cruzada para sintonizar los hiperparámetros críticos (tasa de aprendizaje, profundidad del codificador, número de cabezales de atención en el TFT y tamaño




Figura 4.6: Algoritmia del proceso de preparación de datos y control de calidad.

de la ventana temporal) maximizando el rendimiento predictivo inicial sobre el corpus histórico general antes de someter a los modelos al estrés del arranque en frío.

Fase 2: Simulación Cold-Start (Estrategia LPO)

El núcleo de la experimentación reside en la aplicación de la metodología de retención espacial *Leave-One-Plant-Out* (LPO). En lugar de dividir el set de datos cronológicamente, el orquestador aísla dinámicamente y oculta por completo el historial operativo de una de las plantas (capa *Gold* de validación). El modelo *Cross-Site* es entrenado exclusivamente con los años de experiencia del resto de la flota operativa. Para emular el arranque en frío (*Cold-Start*) de la planta seleccionada, el contexto histórico (*seed*) previo al horizonte de pronóstico se inicializa de forma 100% sintética ($y = \text{capacidad} \times \text{PR regional} \times \text{perfil solar}$), garantizando así que no exista *Data Leakage*. Dicho coeficiente de *Performance Ratio (PR) regional* se calcula como un agrupamiento histórico estratificado por Macrozona y Estación del Año, computado empleando única y estrictamente el conjunto de entrenamiento. Una vez consolidados los pesos sinápticos, la red es forzada a inferir el comportamiento energético futuro de la planta oculta utilizando únicamente sus coordenadas estáticas y el clima entrante. Este procedimiento se repite iterativamente rotando la instalación objetivo. Asimismo, la orquestación de esta fase admite la ejecución bajo distintas escalas (*Toy*, *Half* y *Total*) que modulan la fracción de la muestra analizada, agilizando el *benchmarking*.




Figura 4.7: Visualización iterativa del aislamiento espacial para simulación de arranque en frío.

Fase 3: Extracción de Resultados y Métricas de Rendimiento

La fase final consolida los vectores predictivos generados por cada una de las arquitecturas sometidas a prueba —modelos globales *Cross-Site* (TFT, Informer, N-HiTS, LSTM y XGBoost Global) y líneas base estrictamente locales entrenadas con la historia propia de cada planta (XGBoost, LSTM y N-HiTS locales)— contrastándolos unificadamente contra la producción energética empírica de los parques solares aplicando 2 estrategias de testeo diferenciadas según la ventana temporal proyectada (*day1* para predicción a 24 horas y *rollout7d* para proyección expandida iterativa a una semana). Adicionalmente, los resultados y desvíos son evaluados de manera estratificada según la **Estación del Año**, lo que permite medir el impacto de la variabilidad meteorológica cíclica en las redes. El proyecto computa métricas clásicas de pronóstico, entre las cuales destacan:

- **Error Absoluto Medio (MAE):** Para cuantificar la magnitud promedio lineal del error en la escala energética real (MW).
- **Error Cuadrático Medio (RMSE):** Para penalizar logarítmicamente las desviaciones más grandes generadas por los sesgos del modelo durante picos de inyección.
- **Error Porcentual Absoluto Medio Simétrico (sMAPE):** Empleado como estándar de industria para dimensionar la falla en términos relativos porcentuales, independientemente de la capacidad instalada de la planta.
- **Pronóstico Probabilístico y MQLoss:** Las redes profundas evalúan también intervalos de confianza (90 % CI) para reportar la incertidumbre esperada y la cobertura del intervalo (*Pinball Loss*), sumando fiabilidad a la predicción puntual. Las predicciones finales son ajustadas para cumplir leyes físicas (mínimo de cero general y cero estricto de noche).

La consolidación de estas métricas se tabulará y graficará para facilitar el análisis comparativo financiero y operativo entre el modelo Transformer global y las líneas bases locales.

Protocolo de evaluación Cold-Start: contexto sintético, horizontes y ventanas de sensibilidad




Figura 4.8: Protocolo de evaluación Cold-Start: contexto sintético, horizontes de pronóstico y ventanas del análisis de sensibilidad sobre las cuales se computan las métricas comparativas.

El cronograma temporal que ordena la ejecución de estas cuatro fases corresponde a la carta Gantt de seis semanas presentada en la Figura 1.2 del Capítulo I, cuyas actividades se encuentran categorizadas según el objetivo específico al que tributan.

4.3. Estudio de Factibilidad

Factibilidad técnica

La factibilidad técnica de este proyecto está garantizada por la disponibilidad de herramientas de *software* de código abierto (*Open Source*) y librerías especializadas en *Machine Learning* y *Deep Learning*. Toda la orquestación del pipeline (ETL, entrenamiento y validación) se encuentra programada en *Python*, utilizando el ecosistema *Nixtla* (específicamente *NeuralForecast*) para la ejecución de los algoritmos atencionales de última generación (TFT y N-HiTS), así como *XGBoost* para las líneas base locales. Adicionalmente, el procesamiento matricial intensivo requerido por el paradigma *Cross-Site Learning* se aborda mediante el uso de aceleración por hardware computacional (GPUs), recursos que son accesibles a través de entornos de desarrollo estándar.

Factibilidad operativa

La operación del estudio es autónoma y reproducible: el pipeline completo se ejecuta desde un único punto de entrada con validación automatizada previa (gate de pruebas),

control de idempotencia para reanudar corridas interrumpidas y generación automática de reportes. La extensión del análisis a nuevas plantas o períodos no requiere infraestructura ni personal adicional.

Factibilidad económica

El costo marginal del proyecto es prácticamente nulo: las fuentes de datos son públicas (Coordinador Eléctrico Nacional y red climatológica CR2), la totalidad del software empleado es de código abierto y el cómputo se resuelve en hardware de consumo (una única GPU de gama media), sin requerir financiamiento externo ni servicios de nube de pago.

Factibilidad legal

Los datos empleados provienen de repositorios públicos de organismos oficiales chilenos y no contienen datos personales ni información sujeta a confidencialidad. Las licencias de las librerías utilizadas (ecosistema Python de código abierto) son compatibles con el uso académico e investigativo del presente trabajo.

Factibilidad Social

El proyecto no genera impactos sociales adversos. Indirectamente, la mejora del pronóstico de generación en plantas recién conectadas contribuye a la estabilidad del suministro eléctrico y reduce las barreras de entrada para nuevos actores renovables de menor escala.

Factibilidad Ambiental

La investigación tributa a la descarbonización de la matriz energética al facilitar la integración temprana de nueva capacidad solar. La huella de cómputo del estudio es acotada: los entrenamientos completos se resuelven en horas sobre una única GPU, sin infraestructura de centros de datos dedicada.

Capítulo V

Desarrollo de la Propuesta y Resultados

5. Desarrollo de la Propuesta y Resultados

Este capítulo documenta la ejecución de las cuatro fases metodológicas definidas en la Sección 4.2, junto a las evidencias y resultados obtenidos en cada una de ellas. Las evidencias complementarias (tablas completas de métricas por planta, registros de imputación y bitácoras de ejecución) se remiten a los Anexos.

5.1. Fase 0: Construcción del Pipeline de Datos (ETL)

La implementación del modelo de capas *Medallion* consolidó los registros horarios de generación del Coordinador Eléctrico Nacional (139 archivos mensuales, período 2014–2024) con las variables meteorológicas de la red CR2 (radiación global instantánea, temperatura del aire y humedad relativa), resultando en un corpus unificado de **94 plantas fotovoltaicas** y aproximadamente **4,37 millones de observaciones planta-hora** tras el proceso de depuración.

Durante la construcción de la capa *Bronze* se identificaron y resolvieron tres hallazgos relevantes de calidad de datos:

1. **Agregación multi-unidad:** centrales compuestas por múltiples unidades físicas de reporte (ej. PFV Jama, con dos unidades registradas bajo la misma central y una capacidad combinada de 51 MW) se consolidaron sumando la generación por hora, en coherencia con la capacidad declarada en el maestro de instalaciones.
2. **Transiciones de horario de verano (DST):** la hora repetida del primer domingo de abril se colapsó de forma segura (para generación solar corresponde a horas nocturnas de producción nula).
3. **Integridad del target:** en concordancia con la regla metodológica de no imputación de la variable objetivo, los vacíos de generación permanecen ausentes y las métricas se computan exclusivamente sobre observaciones reales.

La capa *Silver* incorporó las características cíclicas temporales (seno/coseno de hora, mes y estación), la asociación geográfica por Macrozona y la imputación trazable de exógenas (con variables indicadoras *is_imputed* y bitácora de imputación), mientras que la capa *Gold* materializó las particiones de validación LOPO por planta.

La Tabla 5.3 resume la composición del corpus resultante por macrozona. La cobertura se concentra en el Norte Chico y la Zona Central, en coherencia con la distribución real del parque fotovoltaico conectado al Sistema Eléctrico Nacional.

5.2. Fase 1: Sintonización de Hiperparámetros

La búsqueda de hiperparámetros se implementó mediante optimización bayesiana (*Optuna*), explorando la tasa de aprendizaje y la dimensión oculta de cada arquitectura global (mapeada al parámetro real de cada red: *encoder* en LSTM, unidades MLP por




Figura 5.9: Flujo de datos implementado: Landing → Bronze → Silver → Gold, con los volúmenes reales tras la depuración.

Macrozona	Plantas	Capacidad (MW)	Obs. (millones)	Desde	Hasta
Norte Chico	35	750	1.57	2014-01-01	2025-01-01
Norte Grande	12	732	0.58	2014-02-01	2025-01-01
Zona Central	46	390	2.17	2014-01-01	2025-01-01
Zona Sur	1	3	0.05	2019-08-01	2025-01-01
Total	94	1,876	4.37	2014-01-01	2025-01-01

Tabla 5.3: Composición del corpus unificado (capa Silver) por macrozona.

bloque en N-HiTS y dimensión del modelo en TFT e Informer). Para contener el costo computacional, la sintonización se ejecuta una única vez por arquitectura y estrategia de escala, reutilizando la configuración óptima en todos los pliegues LOPO; la fuga de información a nivel de hiperparámetros asociada a esta decisión se considera despreciable en la literatura de pronóstico global.

Adicionalmente, el entrenamiento incorpora detención temprana (*early stopping*) sobre una ventana de validación de 168 horas por serie, precisión mixta (fp16) en las arquitecturas numéricamente estables (TFT, N-HiTS) y precisión completa (fp32) en aquellas propensas a divergencia bajo aritmética reducida (LSTM, Informer).

La Tabla 5.4 presenta la configuración óptima seleccionada para cada arquitectura global en la estrategia de escala *half*. Durante la ejecución a escala se detectó que la precisión reducida provoca divergencia numérica (predicciones NaN) en ciertas combinaciones arquitectura-planta; el hallazgo motivó la incorporación de un mecanismo automático de reintento en precisión completa, y la fijación de fp32 para todos los modelos de una sola serie (baselines locales profundos), cuyo escalador robusto se degenera con

las horas nocturnas de producción nula.

Arquitectura	Ventana entrada (h)	Parám. de dimensión	Valor	Tasa aprendizaje	Precisión
LSTM	168	encoder_hidden_size	64	2.76e-03	fp32
N-HiTS	168	mlp_units	128	5.77e-04	fp16
TFT	168	hidden_size	64	1.27e-03	fp16
Informer	168	hidden_size	32	7.37e-04	fp32

Tabla 5.4: Hiperparámetros óptimos por arquitectura global (búsqueda bayesiana con Optuna, estrategia *half*), y precisión numérica de entrenamiento.

5.3. Fase 2: Simulación Cold-Start (LOPO)

La evaluación *Leave-One-Plant-Out* se ejecutó conforme al diseño metodológico: para cada planta objetivo, los modelos globales se entrenan con las restantes $N - 1$ instalaciones y la inferencia se inicializa con un contexto histórico 100% sintético ($y = \text{capacidad} \times PR_{\text{regional}} \times \text{perfil solar}$), donde el *Performance Ratio* regional se computa estrictamente sobre el conjunto de entrenamiento, estratificado por Macrozona y estación del año.

Como refinamiento metodológico surgido durante el desarrollo, la evaluación incorpora un **análisis de sensibilidad sobre la definición de la ventana de evaluación**, motivado por la detección de *rampas de puesta en marcha*: períodos iniciales de las series (de días a semanas) con generación nula previa a la operación comercial sostenida. Se evalúan por planta:

- **Ventana Raw:** desde la primera hora registrada de la planta (fidel al registro histórico, incluye la rampa).
- **Ventana Operacional:** desde la primera hora de producción sostenida (definida como el primer instante productivo que inaugura al menos 10 horas con generación superior al 5% de la capacidad dentro de las 72 horas siguientes).
- **Ventanas Estacionales:** la primera ventana de producción sostenida cuyo inicio cae en cada una de las cuatro estaciones del año, permitiendo cuantificar el efecto de la variabilidad meteorológica cíclica sobre la transferencia *Cold-Start*.

Cada ventana se evalúa en los dos horizontes definidos (*day1* y *rollout7d*, este último con realimentación autorregresiva de la mediana predicha), y las ventanas de evaluación se excluyen íntegramente del entrenamiento del baseline local para prevenir contaminación *train-on-test*.

5.4. Fase 3: Resultados y Análisis Comparativo

Los resultados que se presentan corresponden a la ejecución de la estrategia de escala *half*: evaluación LOPO sobre **47 plantas objetivo**, con los modelos globales entrenados sobre el último año de historia de las restantes $N - 1$ instalaciones. Cada celda reportada corresponde a la **mediana** sobre las plantas evaluadas (robusta frente a casos extremos); n indica el número de plantas con evaluación válida para cada modelo. Para la lectura de las magnitudes debe considerarse que el rRMSE normaliza por la generación media horaria de la ventana, la cual incluye las horas nocturnas de producción nula: esto infla sistemáticamente el indicador (valores sobre 100 % son esperables en pronóstico horario fotovoltaico bajo esta normalización) y su valor reside en la **comparación relativa** entre arquitecturas evaluadas sobre ventanas idénticas.

Resultados Globales por Arquitectura

Las Tablas 5.5 y 5.6 resumen el desempeño de las ocho configuraciones evaluadas en ambas definiciones de ventana; la Figura 5.10 sintetiza la comparación en la ventana operacional.

Modelo	Day 1 (24 h)			Roll-out 7 días			n
	RMSE (MWh)	sMAPE (%)	rRMSE (%)	RMSE (MWh)	sMAPE (%)	rRMSE (%)	
XGBoost local	0.69	122.6	49.3	0.57	113.6	64.2	47
LSTM local	0.87	111.3	112.7	0.94	120.9	130.2	47
N-HiTS local	1.06	122.7	156.2	1.37	136.3	157.2	42
XGBoost global	0.93	95.2	67.1	1.08	96.8	80.5	47
LSTM global	0.91	144.2	109.0	1.03	145.7	117.7	47
N-HiTS global	1.04	120.9	156.1	1.37	135.5	157.3	45
TFT global	1.16	162.6	142.2	1.27	159.0	137.7	45
Informer global	1.07	164.9	142.3	1.24	163.8	143.0	47

Tabla 5.5: Métricas medianas por arquitectura y horizonte — ventana *Raw* (desde la primera hora registrada; 47 plantas).

Tres lecturas emergen con claridad. Primero, **XGBoost local** —entrenado con la historia propia de cada planta— es la configuración más precisa en todos los horizontes (rRMSE mediano de 64–69 % en roll-out semanal). Segundo, entre los modelos globales *Cross-Site*, **XGBoost global** obtiene el mejor desempeño (80–86 % en roll-out), seguido por **LSTM global** (116–118 %); las arquitecturas atencionales (TFT, Informer) y N-HiTS quedan sistemáticamente por detrás bajo el protocolo Cold-Start estricto. Tercero, la degradación entre *day1* y el roll-out semanal es moderada en todas las familias, lo que indica que la realimentación autorregresiva de la mediana predicha no desestabiliza los

Modelo	Day 1 (24 h)			Roll-out 7 días			<i>n</i>
	RMSE (MWh)	sMAPE (%)	rRMSE (%)	RMSE (MWh)	sMAPE (%)	rRMSE (%)	
XGBoost local	0.41	108.5	38.8	0.48	109.1	68.7	15
LSTM local	0.98	87.0	86.1	1.43	125.4	132.5	15
N-HiTS local	2.38	176.9	160.6	2.25	164.8	170.2	13
XGBoost global	0.83	101.0	62.6	1.02	107.4	86.2	15
LSTM global	1.35	137.7	101.2	1.48	141.3	115.8	15
N-HiTS global	2.06	147.2	143.4	1.88	150.7	163.7	14
TFT global	2.13	164.7	144.5	1.97	156.3	150.5	14
Informer global	1.80	166.1	142.7	1.96	165.3	153.2	15

Tabla 5.6: Métricas medianas por arquitectura y horizonte — ventana *Operacional* (desde la primera producción sostenida; subconjunto de 15 plantas con rampa de puesta en marcha distinguible).




Figura 5.10: Error relativo mediano por arquitectura y horizonte en la ventana operacional.

pronósticos.

Análisis por Estación del Año

La Tabla 5.7 y la Figura 5.11 presentan la sensibilidad estacional del roll-out semanal, evaluando para cada planta ventanas que inician en cada una de las cuatro estaciones (tomadas de su propia historia posterior a la puesta en marcha). Cabe precisar que estas ventanas estacionales son **simulaciones del arranque en frío en distintas épocas del año** y son independientes de la estación en que la planta se conectó realmente: una planta conectada en verano también aporta una ventana invernal.

Modelo	Verano	Otoño	Invierno	Primavera
XGBoost local	37.3	34.3	113.8	88.0
LSTM local	104.7	147.1	173.3	169.9
N-HiTS local	148.9	158.2	209.7	182.1
XGBoost global	65.3	61.1	173.0	111.6
LSTM global	105.6	109.2	154.1	133.4
N-HiTS global	134.3	132.6	216.4	158.9
TFT global	134.5	140.4	192.4	157.3
Informer global	137.6	144.3	177.5	158.0

Tabla 5.7: rRMSE mediano (%) del roll-out de 7 días por estación del año en que inicia la ventana de evaluación.




Figura 5.11: Sensibilidad estacional del Cold-Start para cuatro arquitecturas representativas.

El **invierno es la estación de mayor dificultad predictiva para todas las arquitecturas**, confirmando lo anticipado por el piloto de verificación: XGBoost global pasa de

65 % (verano) a 173 % (invierno) y XGBoost local de 37 % a 114 %. La brecha se explica por la mayor variabilidad nubosa y la menor irradiación media, que reducen la señal determinista del perfil solar y amplifican el peso relativo de los errores.

Análisis de Sensibilidad: Ventana Raw vs. Operacional

Solo 15 de las 47 plantas presentan una rampa de puesta en marcha superior a 24 horas; para el resto, ambas definiciones de ventana coinciden. En la mediana agregada las diferencias son moderadas (Tablas 5.5 y 5.6), pero el promedio de la ventana *Raw* queda distorsionado en las plantas con rampa: al iniciar la evaluación sobre semanas de generación nula, la media de la ventana tiende a cero y el rRMSE se degenera (indefinido o artificialmente extremo). El análisis confirma la decisión metodológica de **reportar ambas definiciones**: la ventana *Raw* es fiel al registro histórico, mientras que la *Operacional* produce métricas interpretables del desempeño sobre una planta que ya opera comercialmente.

Calidad Probabilística de los Intervalos

Modelo	Cobertura 90 % (ideal $\approx 0,90$)	Pinball P05 (MWh)	Pinball P95 (MWh)
LSTM local	0.595	0.062	0.385
N-HiTS local	0.042	0.165	1.028
LSTM global	0.381	0.122	0.259
N-HiTS global	0.006	0.850	0.701
TFT global	0.000	0.464	0.984
Informer global	0.125	0.148	0.738

Tabla 5.8: Calidad probabilística de los intervalos de 90 % (roll-out 7 días, ventana operacional): cobertura empírica y pérdidas Pinball medianas.

La Tabla 5.8 revela un hallazgo relevante: bajo el protocolo Cold-Start estricto, **los intervalos de las arquitecturas globales están severamente subcalibrados** (cobertura empírica de 0,00–0,38 frente al 0,90 nominal). La causa es coherente con el diseño experimental: el escalador local de cada serie se ajusta sobre el contexto sintético, cuya varianza (un perfil solar idealizado) es muy inferior a la variabilidad real de la planta, produciendo bandas demasiado estrechas. El baseline LSTM local —que dispone de contexto real— duplica la cobertura de su contraparte global (0,60 frente a 0,38), lo que confirma esta explicación. La calibración de intervalos bajo transferencia Zero-Shot (por ejemplo, mediante predicción conformal) se identifica como línea de trabajo futuro.

Contraste de la Hipótesis

La hipótesis del Capítulo I postula que el modelo global multi-sitio es capaz de superar en precisión a un modelo entrenado localmente con la información histórica del centro. Los resultados permiten un veredicto matizado en tres planos:

1. **A igualdad de arquitectura, la transferencia global es competitiva o superior en el horizonte extendido:** en el roll-out semanal, LSTM global supera a LSTM local (115,8 % frente a 132,5 %) y N-HiTS global a N-HiTS local (163,7 % frente a 170,2 %), pese a que el modelo local dispone de un año de historia propia que el global jamás observó. En el horizonte *day1*, en cambio, el acceso a contexto real favorece al paradigma local (LSTM local 86,1 % frente a 101,2 % global).
2. **Frente al mejor baseline local maduro, la hipótesis no se sostiene:** XGBoost local con un año de historia propia (68,7 %) supera al mejor modelo global (XGBoost global, 86,2 %). Cuando la planta ya acumuló historia suficiente, el modelo local especializado sigue siendo la opción más precisa.
3. **El valor operativo del modelo global reside en la disponibilidad inmediata:** el paradigma local exige meses de espera para acumular datos de entrenamiento, mientras que el modelo global emite pronósticos utilizables desde la primera hora de conexión — el escenario exacto que motiva esta investigación. En ese régimen (historia local nula), el modelo global no tiene competidor local posible.




Figura 5.12: Ejemplo de roll-out Cold-Start de 7 días (LSTM global): el modelo, sin haber visto jamás la planta, reproduce el ciclo diario y la magnitud de los picos a partir del clima y la geografía. Se aprecia también el piso nocturno residual: el forzamiento físico a cero depende de la radiación observada en la estación meteorológica asociada, cuya imputación en huecos prolongados puede impedir su activación.

En síntesis, la evidencia respalda la transferencia *Cross-Site* como solución al problema del arranque en frío —pronósticos coherentes desde el día uno y superioridad sobre los baselines profundos locales en el horizonte semanal—, al tiempo que delimita honestamente su alcance: una vez que la planta acumula historia operativa suficiente, un modelo local basado en gradiente extremo con rezagos autorregresivos vuelve a ser el estándar a batir.

Capítulo VI

Conclusiones y Trabajo Futuro

6. Conclusiones y Trabajo Futuro

Este capítulo cierra la investigación contrastando los resultados obtenidos con los objetivos y la hipótesis planteados en el Capítulo I, y proyecta las líneas de continuidad que la evidencia empírica sugiere.

Conclusiones

En relación con el **Objetivo Específico 1** (adaptación de una arquitectura Transformer al entrenamiento multi-serie), se implementó y sintonizó un conjunto de arquitecturas globales de última generación (TFT, Informer, N-HiTS y LSTM) sobre el ecosistema NeuralForecast, entrenadas simultáneamente sobre las series de hasta 93 plantas mediante un pipeline reproducible con validación automatizada. La adaptación exigió resolver desafíos de ingeniería no triviales documentados en el Capítulo V: estabilidad numérica en precisión mixta, presupuesto de cómputo por época corregido y gestión de memoria en GPU de gama media, demostrando la viabilidad técnica del enfoque con recursos computacionales accesibles.

En relación con el **Objetivo Específico 2** (evaluación del modelo global durante la puesta en marcha frente a modelos locales), la metodología *Leave-One-Plant-Out* sobre 47 plantas objetivo entregó un veredicto matizado de la hipótesis. A igualdad de arquitectura profunda, la transferencia *Cross-Site* supera al entrenamiento estrictamente local en el horizonte semanal (LSTM global 115,8 % frente a LSTM local 132,5 % de rRMSE mediano), pese a operar con contexto 100 % sintético. Sin embargo, frente al baseline local más fuerte —XGBoost con un año de historia propia y rezagos autorregresivos (68,7 %)— el mejor modelo global (XGBoost global, 86,2 %) no alcanza la paridad. La hipótesis se sostiene, por tanto, en su dominio de validez genuino: el régimen de escasez de datos extrema, donde el paradigma local simplemente no puede existir y el modelo global entrega pronósticos coherentes desde la primera hora de conexión.

En relación con el **Objetivo Específico 3** (integración de datos multimodales), el pipeline consolidó exitosamente variables exógenas dinámicas (radiación, temperatura y humedad de la red CR2), características estáticas geográficas (macrozona, capacidad instalada) y atributos cíclicos deterministas, verificando mediante pruebas automatizadas que ninguna característica derivada de la generación del objetivo contaminara el entrenamiento. El prior de eficiencia regional —calculado exclusivamente sobre las plantas de entrenamiento de cada partición— demostró ser un mecanismo eficaz para sembrar el contexto sintético sin fuga de información.

Del desarrollo emergen además cuatro hallazgos metodológicos transferibles. Primero, las **rampas de puesta en marcha** (semanas iniciales de generación nula) distorsionan las métricas relativas si la ventana de evaluación se define ingenuamente desde el primer registro, lo que motivó el análisis de sensibilidad Raw/Operacional. Segundo, el **invierno es sistemáticamente la estación más difícil** para el arranque en frío en todas las arquitecturas, con errores que duplican o triplican los estivales. Tercero, la **calibración proba-**

bilística no se transfiere: los intervalos de 90 % de los modelos globales cubren entre el 0 % y el 38 % de las observaciones bajo contexto sintético, un aspecto crítico para el uso operativo de estas predicciones en mercados eléctricos. Cuarto, la **integridad del target** —no imputar jamás la generación ausente— resultó esencial para la honestidad de las métricas, en contraste con la práctica habitual de rellenar con ceros.

Trabajos Futuros

Los resultados fundamentan cuatro extensiones directas:

- **Ajuste fino en dos etapas:** los primeros días de datos reales de la planta nueva podrían emplearse para un *fine-tuning* ligero del modelo global pre-entrenado, cerrando gradualmente la brecha con el baseline local maduro a medida que la historia propia crece. La evidencia obtenida (el paradigma local domina con un año de datos) acota el período donde esta transición aporta valor.
- **Calibración de intervalos bajo transferencia:** la subcobertura severa detectada sugiere incorporar predicción conformal u otro mecanismo de recalibración post-hoc que ensanche los intervalos sintéticos hacia la variabilidad real observada en plantas análogas de la misma macrozona.
- **Consistencia física independiente de sensores:** el forzamiento nocturno a cero depende de la radiación observada, vulnerable a huecos de imputación; una máscara astronómica (elevación solar calculada desde coordenadas y calendario) eliminaría el piso nocturno residual observado en los roll-outs.
- **Ampliación arquitectónica y territorial:** incorporar PatchTST cuando el ecosistema NeuralForecast soporte variables exógenas para dicha arquitectura; refinar el prior regional con clustering climático más fino que la macrozona; y escalar la evaluación a las 94 plantas del corpus (estrategia *total*). El despliegue operacional (MLOps) permanece explícitamente fuera del alcance, conforme a la delimitación del proyecto.

Bibliografía

- Arslan, Z., Sahin, M. E., and Ulutas, H. (2025). Comparative evaluation of machine learning and transformer-based deep learning for solar energy forecasting on a real-world dataset. *Arabian Journal for Science and Engineering*, 51:6833–6863.
- Asociación Chilena de Energías Renovables y Almacenamiento (ACERA) (2025). Boletín estadístico acera. <https://cdn.acera.cl/wp-content/uploads/2026/01/2025-12-Boletin-Estadisticas-ACERA.pdf>.
- Bai, S., Kolter, J. Z., and Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*.
- Bak, S., Choi, S., Yang, D., Kim, D., Rho, H., and Lee, K. (2025). Transfer learning for photovoltaic power forecasting across regions using large-scale datasets. *IEEE Access*.
- Benidis, K., Rangapuram, S. S., Flunkert, V., Wang, Y., Maddix, D., Turkmen, A. C., Gasthaus, J., Bohlke-Schneider, M., Salinas, D., and Stella, L. (2022). Deep learning for time series forecasting: Tutorial and literature survey. *ACM Computing Surveys*, 55(6):1–36.
- Comisión Nacional de Energía (2026). Reporte mensual sector energético. Technical report, Gobierno de Chile.
- Coordinador Eléctrico Nacional (2025). Informe del coordinador independiente del sistema eléctrico nacional. Technical report, CEN.
- Damato, S., Rubattu, N., Azzimonti, D., and Corani, G. (2026). Intermittent time series forecasting: local vs global models. *arXiv preprint arXiv:2601.14031*.
- El-Saieed, A. M. (2025). An adaptive transformer model for long-term time-series forecasting of temperature and radiation in photovoltaic energy generation. *Applied Computational Intelligence and Soft Computing*, 2025.
- Ember (2025). Reducing curtailment in chile: Key to unlocking the full potential of renewable energy. <https://ember-energy.org/app/uploads/2025/09/EN-Report-Reducing-curtailment-in-Chile-key-to-unlocking-the-full-potential-of-renewable-energy.pdf>.
- Energía Estratégica (2025). Alertan que los pmgd podrían enfrentar pérdidas por 7400 millones anuales si avanza la bolsa pyme en chile. <https://www.energiaestrategica.com/alertan-que-los-pmgd-podrian-enfrentar-perdidas-por-7400-millones-anuales-si-avanza-la-bolsa-pyme-en-chile>.

- Gu, A. and Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Li, R., Wang, D., Wang, Z., Liang, S., Li, Z., Xie, Y., and He, J. (2024). Transformer approach to nowcasting solar energy using geostationary satellite data. *Applied Energy*, 353:122112.
- López Santos, M., García-Santiago, X., Echevarría Camarero, F., Blázquez Gil, G., and Carrasco Ortega, P. (2022). Application of temporal fusion transformer for day-ahead pv power forecasting. *Energies*, 15(14):5232.
- Mishra, A. et al. (2025). Spirit: Short-term prediction of solar irradiance for zero-shot transfer learning using foundation models. *arXiv preprint arXiv:2502.10307*.
- Nie, Y., Nguyen, N. H., Sinthong, P., and Kalagnanam, J. (2022). A time series is worth 64 words: Long-term forecasting with transformers. *arXiv preprint arXiv:2211.14730*.
- Oreshkin, B. N., Carpow, D., Chapados, N., and Bengio, Y. (2020). N-beats: Neural basis expansion analysis for interpretable time series forecasting. *arXiv preprint arXiv:1905.10437*.
- Salinas, D., Flunkert, V., Gasthaus, J., and Stella, L. (2020). Deepar: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3):1181–1191.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30.
- Zeng, A., Chen, M., Zhang, L., and Xu, Q. (2023). Are transformers effective for time series forecasting? In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 11121–11128.
- Zhaoyang Zhu, e. a. (2023). Energy forecasting with robust, flexible, and explainable machine learning algorithms. *AI Magazine*.
- Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., and Zhang, W. (2021). Informer: Beyond efficient transformer for long sequence time-series forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, pages 11106–11115.

Anexos

A. Repositorio del Proyecto

El código fuente completo del proyecto (pipelines de datos, entrenamiento, evaluación LOPO y generación de reportes), junto a su suite de pruebas automatizadas anti-fuga de información, se encuentra versionado en un repositorio Git.

B. Métricas por Planta

La tabla siguiente reporta el rRMSE mediano (%) del roll-out de 7 días en la ventana *Raw* para las cuatro configuraciones principales, desglosado por planta evaluada en la estrategia *half*. El archivo `all_metrics_summary.csv` del repositorio contiene el detalle completo (ocho modelos, todas las ventanas, ambos horizontes y las métricas probabilísticas).

Macrozona	Planta	XGB local	XGB global	LSTM	TFT
Norte Chico	amparo_del_sol	36.3	55.2	124.9	135.4
Norte Chico	cachiyuyo_solar_2	69.3	80.5	117.4	149.0
Norte Chico	canesa_solar_i	137.3	160.2	184.0	–
Norte Chico	chalinga_solar	28.6	60.9	142.9	154.5
Norte Chico	illapel_5x	30.4	62.1	146.8	156.7
Norte Chico	luna_del_norte	19.1	56.6	133.0	147.0
Norte Chico	norte_chico_i	117.5	139.9	73.1	120.4
Norte Chico	parque_solar_fotovoltaico_maranon	33.9	463.7	56.4	125.1
Norte Chico	pfv_malgarida	124.5	111.4	175.6	182.0
Norte Grande	andes_solar	40.5	43.7	128.2	140.7
Norte Grande	conejo_solar	19.0	42.6	119.5	134.2
Norte Grande	fv_bolero	154.2	599.8	124.9	157.7
Norte Grande	lalachama	14.0	18.6	114.9	131.6
Norte Grande	lalachama_2	14.7	92.3	97.4	132.6
Norte Grande	pampa_solar_norte	15.4	54.6	117.7	134.3
Norte Grande	parque_solar_finis_terrae	663.1	4393.3	706.8	654.6
Norte Grande	parque_solar_pampa_camarones	118.5	150.7	160.1	175.2
Norte Grande	pfv_andes_solar_ii	74.0	150.3	100.8	163.3
Zona Central	alto_solar	0.0	0.0	0.0	0.0
Zona Central	altos_de_til_til	156.9	895.5	146.3	190.2
Zona Central	chancon	43.9	50.9	67.5	129.4
Zona Central	chimbarongo	63.8	70.1	105.3	134.4
Zona Central	crucero	0.0	0.0	0.0	0.0
Zona Central	don_eugenio	43.9	58.1	105.5	131.1
Zona Central	donihue	155.0	183.6	131.1	175.9
Zona Central	el_pilpen	34.5	60.2	111.0	130.0
Zona Central	el_roble	64.2	84.8	87.6	140.3

Macrozona	Planta	XGB local	XGB global	LSTM	TFT
Zona Central	el_sauce	68.3	67.8	119.1	137.7
Zona Central	fotovolt_solar_i	86.1	878.5	236.8	201.3
Zona Central	gr_santa_rosa	85.8	89.6	121.6	156.5
Zona Central	la_acacia	0.0	0.0	0.0	0.0
Zona Central	la_blanquina	152.7	196.7	144.0	177.9
Zona Central	la_frontera	53.8	71.4	89.9	139.7
Zona Central	la_lajuela	90.9	86.9	85.3	–
Zona Central	la_manga_i	26.8	59.2	99.2	132.3
Zona Central	las_perdices	119.3	162.6	169.0	193.5
Zona Central	laurel	142.9	182.5	262.8	248.9
Zona Central	lipangue	94.3	77.0	70.6	124.8
Zona Central	los_libertadores	13.7	44.5	107.4	136.1
Zona Central	los_patos	0.0	0.0	0.0	0.0
Zona Central	luna	103.4	138.2	221.1	97.1
Zona Central	peralillo	51.9	57.5	110.1	134.3
Zona Central	pfv_jose_soler_mallafre	88.9	126.6	137.3	164.3
Zona Central	pfv_marchigue_ii	82.7	104.8	117.1	136.5
Zona Central	pfv_santa_adriana	146.9	190.9	209.4	198.0
Zona Central	pfv_villa_seca	58.7	58.6	105.7	132.4
Zona Sur	las_codornices	67.2	172.9	121.7	157.0

C. Registro de Imputación de Variables Exógenas

Resumen del registro de imputación de la capa Silver (`imputation_log.csv`): horas-planta imputadas por variable meteorológica y macrozona. Cada imputación queda además señalizada al modelo mediante la variable indicadora `_is_imputed` correspondiente. La generación (variable objetivo) no aparece en este registro porque jamás se imputa.

Variable imputada	Norte Chico	Norte Grande	Zona Central	Zona Sur	Total
humedad-relativa	36,183	6,495	57,156	1,299	101,133
radiacion-global-instantanea	38,917	7,227	57,182	1,358	104,684
temp-aire-seco	36,183	6,495	57,156	1,299	101,133
Total	111,283	20,217	171,494	3,956	306,950

Tabla C.10: Horas-planta imputadas en la capa Silver por variable exógena y macrozona.

D. Hallazgos de Calidad de Datos

Durante la construcción del corpus se documentaron los siguientes hallazgos, resueltos en la capa Bronze del pipeline:

- **Agregación multi-unidad:** centrales con múltiples unidades físicas reportando bajo el mismo identificador (ej. PFV Jama: dos unidades, 51 MW combinados) se consolidaron sumando la generación por hora. Sin esta corrección, la serie subcontaba aproximadamente la mitad de la producción real de la central.
- **Duplicación por reejecución:** el modo de escritura incremental de la capa Bronze podía duplicar el dataset completo en reejecuciones forzadas (factor de hasta $3,17\times$ detectado); se corrigió limpiando las salidas previas y añadiendo deduplicación defensiva aguas abajo.
- **Transiciones de horario de verano (DST):** la hora repetida del primer domingo de abril se colapsa de forma segura (en generación solar corresponde a horas nocturnas de producción nula).
- **Rampas de puesta en marcha:** 15 de las 47 plantas evaluadas presentan períodos iniciales de generación nula superiores a 24 horas (hasta semanas), motivando el análisis de sensibilidad Raw/Operacional del Capítulo V.
- **Sentinelas y fechas fuera de rango:** los registros meteorológicos con valor -9999 se descartan y las fechas se restringen al período 2014–2024 antes del parseo.