



UNIVERSIDAD CATÓLICA DEL MAULE
FACULTAD DE CIENCIAS DE LA INGENIERÍA
ESCUELA INGENIERÍA CIVIL INFORMÁTICA

**Análisis comparativo de un enfoque multi-sitio
frente a modelos locales para la proyección a
corto plazo de generación fotovoltaica bajo
escasez de datos**

César David Aular Muñoz
Dr. Sergio Hernández Álvarez

Proyecto de título para optar al Título de Ingeniero Civil Informático

TALCA, Junio 2026



UNIVERSIDAD CATÓLICA DEL MAULE

**FACULTAD DE CIENCIAS DE LA INGENIERÍA
ESCUELA INGENIERÍA CIVIL INFORMÁTICA**

Proyecto de título para optar al Título de Ingeniero Civil Informático

**Análisis comparativo de un enfoque multi-sitio frente a modelos locales para la
proyección a corto plazo de generación fotovoltaica bajo escasez de datos**

César David Aular Muñoz

COMISIÓN EXAMINADORA

FIRMA

PROFESOR GUÍA

Dr. Sergio Hernández Álvarez

PROFESOR COMISIÓN

Dra. Xaviera Lopez Cortés

PROFESOR COMISIÓN

Dr. Juan Luis López Díaz

NOTA FINAL EXAMEN DE TÍTULO:

TALCA, Junio 2026

AGRADECIMIENTOS

Al mirar en retrospectiva, la nostalgia se mezcla con una profunda gratitud. Este proceso, forjado entre cumbres y valles, ha sido un viaje hermoso que me ha transformado por completo.

A mi familia, mi agradecimiento más profundo: sin ustedes simplemente no estaría aquí. Tras sobrepasar tifones y cruzar incesantes tormentas, han sido la base inquebrantable de luz que me permitió mantenerme en pie y seguir adelante.

A mis amigos, testigos de mi crecimiento y compañeros de trinchera en cada batalla, victoria y derrota. Ha sido un privilegio verlos convertirse en personas maravillosas que, estoy seguro, lograrán cosas asombrosas.

A mis compañeros, por demostrarme en la práctica que la competencia y el trabajo en equipo son fuerzas perfectamente complementarias.

A la Universidad Católica del Maule, por enseñarme que la excelencia no es un destino, sino un camino; y es la convicción inquebrantable de recorrerlo la que nos propulsa hacia cosas mejores.

A mis profesores, por brindarme la guía y las herramientas para avanzar; su rigor y conocimiento han sido los cimientos sobre los cuales he podido construir este logro. Un reconocimiento especial a mi profesor guía: ha sido un verdadero honor trabajar a su lado. Su vasta experiencia, sus agudas críticas y su excelente disposición y buena voluntad fueron el catalizador de este trabajo.

Mi gratitud también se extiende al Estado de Chile, por abrirme sus puertas y acogermelo de forma plena, permitiéndome echar raíces en su cultura y su sociedad.

En un acto de justicia con este proceso, también me agradezco a mí mismo. Por la perseverancia, el sacrificio y la valentía de no rendirme ante la exigencia. Por creer en mí antes que nadie, mantener la humildad para ayudar y ser ayudado, y por la determinación de aprender de todo para caminar hacia adelante, persiguiendo incansablemente la convicción de ser mejor.

Finalmente, este documento es la culminación de una etapa, pero no el final del viaje. Es apenas el génesis de un camino nuevo, mucho más desafiante y ambicioso. Que este logro no sea un punto de llegada, sino el impulso definitivo para conquistar metas cada vez mayores.

RESUMEN

La expansión acelerada de la generación fotovoltaica enfrenta una barrera crítica durante la puesta en marcha de nuevas instalaciones: la ausencia de historial operativo local impide que los modelos predictivos tradicionales, entrenados de manera aislada por planta, entreguen proyecciones confiables (problema de *Cold-Start*). Esta incertidumbre algorítmica se traduce en ineficiencias operativas y riesgo financiero para los operadores del sistema eléctrico y los pequeños medios de generación distribuida.

El presente proyecto de título aborda este problema mediante el diseño, implementación y validación de un marco de aprendizaje multi-sitio (*Cross-Site Learning*), en el cual arquitecturas de *Deep Learning* de estado del arte —*Temporal Fusion Transformer* (TFT), *Informer* y *N-HiTS*— se entrenan de forma global sobre un conglomerado de plantas solares chilenas consolidadas, integrando datos multimodales: series de generación horaria (2014–2024), variables meteorológicas exógenas y características estáticas geográficas agrupadas por Macrozona.

La evaluación se estructura bajo el protocolo *Leave-One-Plant-Out* (LOPO), que oculta íntegramente la planta objetivo durante el entrenamiento y simula su arranque en frío inicializando la ventana de contexto con valores puramente sintéticos, derivados de un coeficiente de eficiencia regional calculado exclusivamente sobre el conjunto de entrenamiento. El desempeño se contrasta frente a líneas base entrenadas localmente (XGBoost y LSTM) en horizontes de 24 horas y de 7 días con realimentación autorregresiva, empleando métricas puntuales (RMSE, MAE, sMAPE, rRMSE) y probabilísticas (cobertura del intervalo de 90 % y pérdida Pinball), estratificadas por estación del año.

Los resultados sobre las 94 plantas objetivo conducen al **rechazo de la hipótesis**: ningún modelo global iguala la precisión absoluta del mejor modelo local (XGBoost con historia propia). El balance es, no obstante, matizado —a igualdad de arquitectura profunda la transferencia global resulta competitiva, y la LSTM global supera a su contraparte local en el horizonte semanal pese a operar sin historia de la planta—, y el enfoque multi-sitio conserva un valor operativo indiscutible en su dominio genuino: es la única alternativa capaz de emitir pronósticos utilizables y calibrados desde la primera hora de conexión, cuando el paradigma local aún no puede entrenarse. Se identifican además la mayor dificultad invernal y la subcalibración de los intervalos de las redes profundas bajo transferencia como hallazgos relevantes, y se derivan de ellos líneas de mejora concretas (ajuste fino, máscaras de intermitencia, mayor volumen de datos y cómputo).

ABSTRACT

The accelerated expansion of photovoltaic generation faces a critical barrier during the commissioning of new facilities: the absence of local operating history prevents traditional forecasting models, trained in isolation for each plant, from delivering reliable projections (the *Cold-Start* problem). This algorithmic uncertainty translates into operational inefficiencies and financial risk for power-system operators and small distributed-generation actors.

This undergraduate thesis project addresses the problem through the design, implementation and validation of a *Cross-Site Learning* framework, in which state-of-the-art Deep Learning architectures—the *Temporal Fusion Transformer* (TFT), *Informer* and *N-HiTS*—are trained globally over a set of consolidated Chilean solar plants, integrating multimodal data: hourly generation series (2014–2024), exogenous meteorological variables and static geographic features grouped by macro-zone.

The evaluation follows a *Leave-One-Plant-Out* (LOPO) protocol, which completely hides the target plant during training and simulates its cold start by initializing the context window with purely synthetic values, derived from a regional efficiency coefficient computed strictly on the training set. Performance is contrasted against locally trained baselines (XGBoost and LSTM) over 24-hour and autoregressive 7-day horizons, using both point metrics (RMSE, MAE, sMAPE, rRMSE) and probabilistic metrics (90% interval coverage and Pinball loss), stratified by season of the year.

Results over the 94 target plants deliver a nuanced verdict: at matched deep-learning architecture global transfer is competitive—the global LSTM outperforms its strictly local counterpart on the weekly horizon despite never observing the target plant—, whereas a mature local model (XGBoost with own history) retains the best absolute accuracy. The value of the multi-site approach is thus confirmed in its genuine domain—usable, probabilistically calibrated forecasts from the very first hour of grid connection, where the local paradigm is unfeasible— while winter emerges as the hardest season and the miscalibration of the deep networks' probabilistic intervals under transfer is identified as a key finding for operational use.

ÍNDICE DE CONTENIDOS

Capítulo I	1
1. Introducción y Objetivos	2
1.1. Introducción	2
1.2. Problemática	3
1.3. Cliente y/o Público objetivo	3
1.4. Objetivo General	4
1.5. Hipótesis	4
1.6. Alcance del Proyecto	5
1.7. Carta de Compromiso	6
1.8. Planificación del Trabajo (Carta Gantt)	7
Capítulo II	8
2. Marco Teórico	9
2.1. Generación Fotovoltaica y el Recurso Solar	9
2.2. Series de Tiempo y el Problema de Pronóstico	9
2.3. Modelos Estadísticos Clásicos	9
2.4. Aprendizaje Automático: Ensamblajes de Árboles de Decisión	10
2.5. Aprendizaje Profundo para Series Temporales	10
2.6. El Mecanismo de Atención y las Arquitecturas Transformer	11
2.7. Del Paradigma Local al Global: Aprendizaje Multi-Sitio	12
2.8. El Problema del Arranque en Frío (Cold-Start)	13
2.9. Conclusión acerca de las Herramientas Seleccionadas	14
Capítulo III	15
3. Estado del Arte / Benchmarking	16
3.1. Enfoques de Machine Learning y Aprendizaje Profundo en el Pronóstico Fotovoltaico	16
3.2. Arquitecturas Atencionales Aplicadas a la Energía Solar	17
3.3. Transferencia de Conocimiento y Escasez de Datos en Sistemas Fotovoltaicos	17
3.4. Síntesis Comparativa y Brecha Identificada	18

Capítulo IV	20
4. Metodología y Propuesta de Solución	21
4.1. Propuesta de Solución	21
4.2. Adaptación Metodológica (Pipeline de Trabajo)	21
4.3. Estudio de Factibilidad	25
Capítulo V	27
5. Desarrollo de la Propuesta y Resultados	28
5.1. Fase 0: Construcción del Pipeline de Datos (ETL)	28
5.2. Fase 1: Sintonización de Hiperparámetros	30
5.3. Fase 2: Simulación Cold-Start (LOPO)	32
5.4. Fase 3: Resultados y Análisis Comparativo	32
Capítulo VI	39
6. Conclusiones y Trabajo Futuro	40
Bibliografía	44
Anexos	47
A. Repositorio del Proyecto	48
B. Métricas por Planta	48
C. Registro de Imputación de Variables Exógenas	50
D. Hallazgos de Calidad de Datos	50

LISTA DE FIGURAS

1.1. Distribución de las plantas fotovoltaicas de la muestra por macrozona (94 instalaciones; 1.876 MW de capacidad agregada).	6
1.2. Planificación estructurada en 6 semanas, categorizada según los Objetivos Específicos del proyecto.	7
2.3. Arquitectura del Temporal Fusion Transformer, destacando sus compuertas Gated Residual Networks (GRN) y su bloque de atención multipunto. . .	12
2.4. Flujo conceptual de transferencia de conocimiento global inter-plantas versus el entrenamiento local y aislado.	13
4.5. Representación esquemática de la propuesta de solución predictiva.	22
4.6. Algoritmia del proceso de preparación de datos y control de calidad.	23
4.7. Visualización iterativa del aislamiento espacial para simulación de arranque en frío.	24
4.8. Protocolo de evaluación Cold-Start: contexto sintético, horizontes de pronóstico y ventanas del análisis de sensibilidad sobre las cuales se computan las métricas comparativas.	25
5.9. Flujo de datos implementado: Landing → Bronze → Silver → Gold, con los volúmenes reales tras la depuración.	29
5.10. Complejidad del modelo (escala logarítmica) frente al error de pronóstico Cold-Start.	31
5.11. Error relativo mediano por arquitectura y horizonte en la ventana operacional.	34
5.12. Sensibilidad estacional del Cold-Start para cuatro arquitecturas representativas.	36
5.13. Ejemplo de roll-out Cold-Start de 7 días: el modelo global, sin haber visto jamás la planta objetivo, reproduce el ciclo diario y la magnitud de los picos de generación a partir únicamente del clima entrante y de las características geográficas estáticas, con el forzamiento físico a cero durante la noche astronómica.	38

LISTA DE TABLAS

1.1. Resumen del impacto operativo y financiero por incertidumbre predictiva.	4
3.2. Síntesis comparativa de los estudios de pronóstico fotovoltaico aplicado revisados.	19
5.3. Composición del corpus unificado (capa Silver) por macrozona.	29
5.4. Hiperparámetros óptimos por arquitectura global (búsqueda bayesiana con Optuna) y precisión numérica de entrenamiento.	30
5.5. Complejidad de cada modelo (número de parámetros) frente a su error mediano de pronóstico.	31
5.6. Métricas medianas por arquitectura y horizonte — ventana <i>Raw</i> (desde la primera hora registrada; 94 plantas).	33
5.7. Métricas medianas por arquitectura y horizonte — ventana <i>Operacional</i> (desde la primera producción sostenida; subconjunto de 33 plantas con rampa de puesta en marcha distinguible).	33
5.8. rRMSE mediano (%) del horizonte <i>day1</i> por estación del año en que inicia la ventana de evaluación.	35
5.9. rRMSE mediano (%) del roll-out de 7 días por estación del año en que inicia la ventana de evaluación.	35
5.10. Calidad probabilística de los intervalos de 90 % (roll-out 7 días, ventana operacional). La <i>cobertura con noche</i> incluye las horas nocturnas, donde el forzamiento físico a cero garantiza un acierto trivial; la <i>cobertura diurna</i> (solo horas con $y > 0$) es la medida honesta del mérito probabilístico.	37
C.12. Horas-planta imputadas en la capa Silver por variable exógena y macrozona.	50

Capítulo I

Introducción y Objetivos

1. Introducción y Objetivos

1.1. Introducción

En las últimas décadas, la energía solar ha cobrado una gran relevancia, llegando a representar una parte sustancial de la generación de energía renovable a nivel mundial gracias a los avances en las tecnologías fotovoltaicas y a la creciente demanda energética [International Energy Agency, 2023]. La expansión de la infraestructura de energía solar es un pilar fundamental para la electrificación, la transición energética global y el cumplimiento de los compromisos de cero emisiones netas para mitigar los efectos del cambio climático. Sin embargo, la generación fotovoltaica está sujeta a una alta variabilidad e intermitencia, ya que depende directamente de factores meteorológicos dinámicos como la Irradiancia Horizontal Global (GHI), la temperatura, la nubosidad y la velocidad del viento [Antonanzas et al., 2016]. Por lo tanto, la estimación precisa de la productividad en plantas de energía renovable es un desafío crítico para la planificación, operación y optimización de los sistemas energéticos de la red [Coordinador Eléctrico Nacional, 2025].

Tradicionalmente, los modelos predictivos de generación solar se han abordado mediante técnicas estadísticas y algoritmos clásicos que se entrenan de manera local utilizando los datos históricos específicos de cada planta. Este enfoque presenta dos limitaciones fundamentales. En primer lugar, dependen fuertemente de la disponibilidad de un volumen considerable de datos históricos locales, lo cual dificulta enormemente su aplicación en escenarios de puesta en marcha de nuevas instalaciones (el problema de *cold-start* o arranque en frío). En segundo lugar, omiten el aprovechamiento de los patrones meteorológicos y operativos que son compartidos entre distintas plantas y regiones climáticas, los cuales poseen un alto valor para mejorar la capacidad predictiva y la generalización de los modelos.

Para superar estas barreras de disponibilidad de datos, la investigación reciente ha comenzado a integrar técnicas avanzadas de Deep Learning, donde arquitecturas como los Transformers (ej. Temporal Fusion Transformer, Informer [Zhou et al., 2021] o PatchTST [Nie et al., 2023]) han demostrado una capacidad superior para procesar secuencias largas y extraer dependencias temporales complejas a partir de datos meteorológicos multivariados [Arslan et al., 2025]. Complementariamente, el uso de enfoques de *Transfer Learning* (aprendizaje por transferencia) permite que un modelo pre-entrenado a partir de bases de datos a gran escala y de múltiples regiones transfiera características y patrones climáticos generales hacia instalaciones locales con escasez de datos [Bak et al., 2025].

El presente proyecto busca abordar el problema del *cold-start* a través del desarrollo y validación de una arquitectura de "*Cross-Site Learning*" (aprendizaje multi-sitio). Mediante el uso de un modelo Transformer de estado del arte, el proceso de entrenamiento se adaptará para aprender simultáneamente de múltiples series temporales de distintas plantas solares, integrando variables exógenas dinámicas (clima) y características estáticas (ubicación geográfica).

El desarrollo de este proyecto aporta valor empírico y metodológico en dos frentes principales. En primer lugar, proporciona una herramienta validada para la industria, permitiendo a los operadores estimar con mayor precisión la producción de nuevos parques solares desde sus etapas iniciales sin depender de recolecciones de datos locales prolongadas. En segundo lugar, aporta evidencia sólida sobre la eficacia de aplicar técnicas de *Transfer Learning* y arquitecturas Transformer en series de tiempo energéticas, estableciendo un marco de evaluación riguroso frente a modelos tradicionales de Machine Learning (como XGBoost o LSTM) entrenados de manera estrictamente local.

1.2. Problemática

La transición hacia una matriz energética sostenible ha impulsado una expansión acelerada de proyectos fotovoltaicos. Tal como indica la Comisión Nacional de Energía, el 75 % de los 5.333 MW de nueva capacidad eléctrica actualmente en etapa de construcción en el país corresponde a parques solares [Comisión Nacional de Energía, 2026]. Sin embargo, esta inyección masiva de energía choca con una barrera crítica para la toma de decisiones: la escasez de datos meteorológicos y operativos durante las etapas iniciales de un proyecto. Para generar proyecciones confiables y superar el problema del Cold-Start, los algoritmos predictivos tradicionales —entrenados de manera aislada para cada instalación— requieren de un mínimo de un año ininterrumpido de registros locales [Zhu et al., 2023]. Esto fomenta un profundo aislamiento del aprendizaje técnico, impidiendo que el conocimiento atmosférico generalizado (enfoque Multi-Sitio) se transfiera, lo que condena a los nuevos actores del mercado a operar con altos niveles de incertidumbre algorítmica desde su puesta en marcha.

Esta falta de predictibilidad a corto plazo desencadena severas ineficiencias operativas y un alto riesgo financiero a lo largo de la red. A nivel sistémico, el Coordinador Eléctrico Nacional (2025) reporta que las imprecisiones en los pronósticos de inyección renovable han introducido un error financiero del 4,62 % sobre la estimación de los costos operativos totales del Sistema Eléctrico Nacional. Más grave aún, la incapacidad de anticipar con exactitud la generación exacerba los cuellos de botella en la transmisión, derivando en niveles críticos de vertimiento de energía limpia (curtailment). Durante 2025, el vertimiento físico alcanzó los 6.084 GWh [ACERA, 2025], lo que se ha traducido en pérdidas de ingresos para las generadoras equivalentes a 562 millones de dólares acumulados en los últimos tres años [Ember, 2025]. Finalmente, en el ecosistema a menor escala, esta incertidumbre algorítmica expone directamente a los Pequeños Medios de Generación Distribuida (PMGD) a un riesgo de mermas financieras estimado en hasta 7.400 millones de dólares anuales ante la falta de certeza horaria en sus esquemas de inyección [Energía Estratégica, 2025].

Variable / Métrica	Magnitud Estimada	Fuente de Referencia
Capacidad solar en construcción	75 % del total (MW)	Comisión Nacional de Energía (2026)
Error financiero sistémico	4,62 % de costos operativos	Coordinador Eléctrico Nacional (2025)
Vertimiento físico anual	6.084 GWh	ACERA (2025)
Pérdida por vertimiento (3 años)	562 Millones USD	Ember (2025)

Tabla 1.1: Resumen del impacto operativo y financiero por incertidumbre predictiva.

1.3. Cliente y/o Público objetivo

El público objetivo y los principales beneficiarios de esta solución abarcan un espectro amplio dentro del ecosistema de generación de energía renovable. En primer lugar, la herramienta se orienta a operadores, administradores de parques solares a gran escala y coordinadores de redes eléctricas, quienes requieren sistemas predictivos robustos para minimizar la incertidumbre en la toma de decisiones, optimizando la planificación energética y reduciendo el riesgo financiero ante desvíos en el despacho durante las etapas iniciales de una planta.

En segundo lugar, esta propuesta integra a los actores del segmento de Pequeños Medios de Generación Distribuida (PMGD) y a los desarrolladores de sistemas de autoconsumo fotovoltaico a pequeña y mediana escala (comercial e industrial). Para este nicho, donde la instalación de sensorica avanzada o la recopilación de años de datos locales resulta económicamente inviable, un modelo multi-sitio pre-entrenado les permitirá acceder a proyecciones a corto plazo continuas y confiables desde su puesta en marcha, permitiendo rentabilizar sus operaciones y gestionar su inyección a la red sin la barrera de entrada que supone el modelado de datos aislado y tradicional.

1.4. Objetivo General

Analizar y comparar el desempeño de un modelo global de aprendizaje multi-sitio frente a modelos locales entrenados con datos históricos, en la estimación de la productividad de plantas de energía renovable, considerando su capacidad de generalización y su rendimiento en escenarios de escasez de datos e intermitencia.

1.5. Hipótesis

La implementación de un modelo globalmente entrenado con información proveniente de centros meteorológicamente variados, es capaz de usar información generalizada respecto de las variaciones en las condiciones atmosféricas para obtener un mejor

resultado respecto de la producción de energía de una planta de producción desconocida, siendo más precisa que un modelo localmente entrenado solo con la información histórica del centro.

Objetivos Específicos

1. Seleccionar y configurar una arquitectura Transformer preexistente que sea adecuada para el pronóstico de series de tiempo. Posteriormente, adaptar su proceso de entrenamiento con el fin de que el modelo sea capaz de procesar y aprender de manera simultánea a partir de múltiples series temporales provenientes de diferentes plantas solares, reemplazando así el tradicional enfoque de entrenamiento aislado.
2. Evaluar la efectividad del modelo global pre-entrenado durante la puesta en marcha de una nueva planta renovable que cuente con una escasa cantidad de datos con respecto a modelos tradicionales (como XGBoost o LSTM) entrenados de manera estrictamente local.
3. Integrar datos multimodales para dotar al modelo de la capacidad de procesar diversas fuentes de información, integrando de manera conjunta tanto variables exógenas dinámicas, que representan las condiciones meteorológicas, como características estáticas referentes a la ubicación espacial y geográfica de cada estación.

1.6. Alcance del Proyecto

Con el propósito de analizar y comparar el desempeño predictivo de modelos globales frente a modelos locales, el alcance de este proyecto se focaliza en el dominio de la producción de energía solar mediante el estudio de un conjunto consolidado de instalaciones agrupadas bajo un criterio de Macrozona. Esta estrategia de agrupación responde a la necesidad de estabilizar las características climáticas compartidas y escalar el aprendizaje cruzado entre plantas. Esta configuración experimental permite integrar series de tiempo de producción y variables meteorológicas de alta fidelidad para evaluar la capacidad de generalización y la respuesta del modelo ante la escasez de datos. Técnicamente, el trabajo se concentra en la parametrización, el entrenamiento multi-sitio y la validación de arquitecturas de estado del arte (TFT, Informer, N-HiTS), empleando modelos XGBoost y LSTM como líneas base comparativas. Finalmente, para mantener el foco en la evaluación del rendimiento del modelado, se excluyen explícitamente el desarrollo de nuevas estrategias o metodologías desde cero, el despliegue en entornos de producción (MLOps), la integración con sistemas SCADA y cualquier análisis de viabilidad financiera o rentabilidad operativa sobre los activos estudiados. De manera que el proyecto se compone de la recopilación y preprocesado de datos, la configuración de la

estrategia de orquestación para el testeo, el entrenamiento de los modelos base, la ejecución y posterior comparación entre el modelo globalmente entrenado y las baseline en situaciones de “Cold-Start”. Todo circunscrito por un repositorio con los pipelines de datos, entrenamiento y posterior testeo.




Figura 1.1: Distribución de las plantas fotovoltaicas de la muestra por macrozona (94 instalaciones; 1.876 MW de capacidad agregada).

1.7. Carta de Compromiso

Dada la naturaleza de la presente investigación, el desarrollo del modelo no se encuentra aunado a la intervención o patrocinio exclusivo de una entidad privada específica para su ejecución técnica. El acceso a los activos de datos necesarios para el cumplimiento de los objetivos planteados ha sido gestionado bajo protocolos internos, lo que garantiza la viabilidad y autonomía del estudio en sus etapas de entrenamiento y validación. No obstante, se mantiene la disposición para formalizar vínculos de colaboración técnica con organismos del sector en fases posteriores, con el fin de robustecer la transferencia tecnológica de los resultados obtenidos.

1.8. Planificación del Trabajo (Carta Gantt)

Para cumplir con los objetivos trazados de manera sistemática, se ha definido una carta Gantt de seis semanas de duración orientada a la ejecución técnica, evaluación del *Cold-Start* y consolidación de resultados (ver Figura 1.2).




Figura 1.2: Planificación estructurada en 6 semanas, categorizada según los Objetivos Específicos del proyecto.

Capítulo II

Marco Teórico

2. Marco Teórico

Este capítulo construye los fundamentos teóricos de la investigación siguiendo una progresión de lo general a lo específico: parte de la naturaleza física del recurso solar y del problema de pronóstico de series de tiempo, recorre la evolución de las técnicas predictivas —desde los modelos estadísticos clásicos hasta las arquitecturas de aprendizaje profundo basadas en atención— y culmina en el tránsito del paradigma de entrenamiento local (*one-site*) al global (*multi-site*), que es el eje conceptual sobre el que se articula la solución propuesta para el problema del arranque en frío.

2.1. Generación Fotovoltaica y el Recurso Solar

La generación de energía solar fotovoltaica corresponde al proceso de conversión directa de la radiación solar en electricidad mediante el efecto fotovoltaico. La potencia activa de salida de una planta posee una dependencia estocástica respecto a múltiples variables atmosféricas dinámicas [Duffie and Beckman, 2013]. La variable con mayor correlación directa es la Irradiancia Horizontal Global (GHI), definida como la cantidad total de radiación de onda corta recibida por una superficie horizontal, que integra las componentes directa y difusa [Duffie and Beckman, 2013]. De forma secundaria, factores térmicos y atmosféricos como la temperatura ambiente, la humedad relativa, la velocidad del viento y, sobre todo, la nubosidad, modulan la eficiencia de conversión de los paneles [Duffie and Beckman, 2013]. En conjunto, la intermitencia de estas variables produce fluctuaciones severas en la inyección de energía a la red, lo que convierte al pronóstico preciso de generación en un insumo crítico para la operación de los sistemas eléctricos con alta penetración renovable [Coordinador Eléctrico Nacional, 2025].

2.2. Series de Tiempo y el Problema de Pronóstico

Una serie de tiempo se define como un conjunto ordenado de observaciones cuantitativas registradas en intervalos de tiempo regulares [Peixeiro, 2022]. El pronóstico consiste en analizar estas secuencias históricas para proyectar valores futuros, tarea que se apoya en propiedades estructurales de la señal —tendencia, estacionalidad y autocorrelación— y en supuestos como la estacionariedad [Peixeiro, 2022]. En el dominio energético, el pronóstico fotovoltaico presenta una estacionalidad múltiple y anidada (ciclo diario e interanual) y una fuerte intermitencia inducida por el clima, lo que ha motivado una progresión metodológica desde los modelos lineales clásicos hacia arquitecturas capaces de capturar dependencias no lineales de largo alcance [Benidis et al., 2022].

2.3. Modelos Estadísticos Clásicos

La familia de modelos estadísticos constituye el punto de partida histórico del pronóstico de series de tiempo y opera bajo un paradigma estrictamente **local**: cada modelo

se ajusta a los datos históricos de una única serie, sobre la premisa de disponer de un historial largo e ininterrumpido.

El **suavizado exponencial** (*exponential smoothing*) proyecta el futuro como un promedio ponderado de las observaciones pasadas, asignando pesos que decaen geométricamente hacia atrás en el tiempo; sus variantes de Holt y Holt-Winters extienden la formulación para capturar explícitamente componentes de tendencia y estacionalidad [Peixeiro, 2022]. Por su parte, la metodología de Box-Jenkins formaliza los modelos **autorregresivos de media móvil** (ARMA) y su extensión integrada **ARIMA**, que combina términos autorregresivos, de media móvil y de diferenciación para modelar series no estacionarias [Peixeiro, 2022]. Las variantes **SARIMA** y **SARIMAX** incorporan, respectivamente, la estacionalidad periódica y la influencia de variables exógenas (como las meteorológicas), lo que las hace teóricamente aplicables al pronóstico solar [Peixeiro, 2022].

La limitación fundamental de esta familia es triple: asume relaciones predominantemente lineales entre las variables, exige la satisfacción de supuestos estadísticos estrictos (estacionariedad, homocedasticidad) y, por su naturaleza local, requiere un historial extenso de la propia serie para estimar sus parámetros —condición precisamente ausente en el escenario de arranque en frío.

2.4. Aprendizaje Automático: Ensamblados de Árboles de Decisión

La incorporación del *Machine Learning* al pronóstico permitió relajar los supuestos de linealidad. Los algoritmos basados en ensambles de árboles de decisión mediante potenciación del gradiente (*gradient boosting*), y en particular **XGBoost**, construyen de forma aditiva una secuencia de árboles donde cada uno corrige los errores residuales del ensamble previo, capturando interacciones no lineales entre las variables de forma eficiente y regularizada [Chen and Guestrin, 2016]. En el dominio energético, estos algoritmos han demostrado un desempeño competitivo y una alta interpretabilidad al cuantificar la importancia relativa de cada variable meteorológica [Zhu et al., 2023]. No obstante, al ser modelos tabulares que aprenden por particionamiento del espacio de características, carecen de capacidad de extrapolación fuera del rango observado en entrenamiento, lo que degrada severamente su desempeño cuando la serie objetivo carece de historial —nuevamente, el problema del arranque en frío.

2.5. Aprendizaje Profundo para Series Temporales

El aprendizaje profundo (*Deep Learning*) introdujo la capacidad de aprender representaciones jerárquicas directamente de los datos, superando la necesidad de ingeniería manual de características. Las redes neuronales recurrentes, y en particular la arquitectura **Long Short-Term Memory** (LSTM) [Hochreiter and Schmidhuber, 1997], incorporaron compuertas de memoria que permiten retener información de estados pasados y mitigar el desvanecimiento del gradiente, habilitando el modelado de dependencias

temporales de corto y mediano plazo. Como alternativa a la recurrencia, las redes convolucionales temporales demostraron que arquitecturas puramente convolucionales pueden igualar o superar a las recurrentes en tareas secuenciales, con la ventaja del procesamiento paralelo [Bai et al., 2018].

Un avance conceptual relevante fue el paso del pronóstico puntual al **pronóstico probabilístico**. El modelo **DeepAR** [Salinas et al., 2020] estructura una red recurrente autorregresiva que, en lugar de un único valor, estima los parámetros de una distribución de probabilidad futura, permitiendo cuantificar analíticamente la incertidumbre de la predicción —una capacidad esencial para la gestión de riesgo en la operación energética. En paralelo, las arquitecturas de expansión en bases, como **N-BEATS** [Oreshkin et al., 2020], propusieron bloques de proyección sobre bases funcionales interpretables (tendencia y estacionalidad) que alcanzaron desempeño de estado del arte sin recurrencia. Su sucesor, **N-HiTS**, refina esta idea mediante interpolación jerárquica y muestreo multi-tasa, lo que reduce drásticamente el costo computacional en horizontes largos y lo posiciona como una contraparte moderna y eficiente frente a los modelos atencionales [Challu et al., 2023]. Una revisión sistemática del campo documenta esta transición y consolida al aprendizaje profundo como el paradigma dominante en el pronóstico de series de tiempo a gran escala [Benidis et al., 2022].

2.6. El Mecanismo de Atención y las Arquitecturas Transformer

La arquitectura **Transformer** [Vaswani et al., 2017] representó una disrupción en el procesamiento secuencial al eliminar la recurrencia en favor del mecanismo de **auto-atención** (*self-attention*), que pondera dinámicamente la relevancia de cada instante de la secuencia respecto a los demás. Al procesar la secuencia completa en paralelo, los Transformers reducen la pérdida de información a largo plazo y escalan eficientemente en el entrenamiento.

Su adaptación al pronóstico de series de tiempo dio lugar a una familia de arquitecturas especializadas. El **Informer** [Zhou et al., 2021] introdujo la autoatención *ProbSparse*, que reduce la complejidad computacional de cuadrática a logarítmica y habilita el pronóstico de secuencias extremadamente largas que antes desbordaban la memoria. El **PatchTST** [Nie et al., 2023] propuso segmentar la señal en parches (sub-ventanas) antes de aplicar la atención, reteniendo la información semántica a nivel de vecindario temporal. El **Temporal Fusion Transformer** (TFT) se distingue por su diseño explícitamente multivariado: integra redes de selección de variables y codificadores especializados que procesan de forma diferenciada las covariables estáticas (como la ubicación geográfica de la planta) y las dinámicas (irradiancia y temperatura), además de emitir pronósticos por cuantiles [Lim et al., 2021]. Esta capacidad de fusionar información heterogénea de manera asimétrica lo convierte en la arquitectura idónea para la transferencia de conocimiento entre plantas.

La supremacía de los Transformers no está exenta de debate: trabajos posteriores

mostraron que modelos lineales simples pueden igualar o superar a arquitecturas atencionales sobre-complejas en ciertos escenarios de pronóstico de largo plazo [Zeng et al., 2023], lo que subraya la necesidad de un *benchmarking* riguroso frente a líneas base sólidas. Más recientemente, los modelos de espacio de estados con selección, como Mamba [Gu and Dao, 2023], han emergido como una alternativa de complejidad lineal a la atención, delineando la frontera actual de la investigación.

Arquitectura del Temporal Fusion Transformer (Lim et al., 2021)




Figura 2.3: Arquitectura del Temporal Fusion Transformer, destacando sus compuertas Gated Residual Networks (GRN) y su bloque de atención multipunto.

2.7. Del Paradigma Local al Global: Aprendizaje Multi-Sitio

Todas las técnicas anteriores pueden desplegarse bajo dos paradigmas de entrenamiento fundamentalmente distintos. En el enfoque **local** (*one-site*), se ajusta un modelo independiente por cada serie temporal, utilizando exclusivamente su propio historial; es el supuesto operativo tradicional de los modelos estadísticos. En el enfoque **global** (*multi-site*), un único modelo se entrena de forma simultánea sobre un conjunto de múltiples series, aprendiendo patrones compartidos y regularidades transversales al conjunto [Montero-Manso and Hyndman, 2021]. La evidencia empírica reciente indica que, en conjuntos de series relacionadas y especialmente bajo condiciones de intermitencia o cortes de telemetría, el paradigma global aporta un efecto estabilizador y una mejor generalización que su contraparte local [Damato et al., 2026].

Este paradigma global se materializa a través del **aprendizaje por transferencia** (*Transfer Learning*), técnica en la que el conocimiento extraído de la resolución de una tarea con abundancia de datos se reutiliza para resolver un problema análogo en un dominio con escasez de datos [Pan and Yang, 2010]. Aplicado al pronóstico solar, esta concepción adopta la forma de **aprendizaje multi-sitio** (*Cross-Site Learning*): un modelo de Deep Learning se entrena con la ingesta simultánea de datos de un clúster de plantas fotovoltaicas geográficamente distribuidas y, al correlacionar sus atributos estáticos con las variables dinámicas globales, abstrae el comportamiento atmosférico fundamental subyacente. El modelo resultante puede así emitir pronósticos para una planta nueva reduciendo o eliminando la exigencia de un historial local sustancial.




Figura 2.4: Flujo conceptual de transferencia de conocimiento global inter-plantas versus el entrenamiento local y aislado.

2.8. El Problema del Arranque en Frío (Cold-Start)

El concepto de *Cold-Start* (arranque en frío), originado en los sistemas de recomendación y trasladado al ámbito de las energías renovables, se refiere a la incapacidad de un algoritmo predictivo para generar estimaciones confiables debido a la ausencia parcial o total de datos históricos locales en una instalación recién puesta en marcha [Schein et al., 2002, Bak et al., 2025]. Dado que los modelos locales —estadísticos, de *Machine Learning* y de *Deep Learning*— requieren extensos registros para modelar la estacionalidad climática anual y evitar el sobreajuste, la fase inicial de operación de un nuevo parque solar se caracteriza por una alta degradación predictiva que impacta la estabilidad de la red de transmisión. El aprendizaje multi-sitio se postula, precisamente, como la vía para transferir el conocimiento climático generalizado de la flota operativa hacia estas instalaciones sin historia.

2.9. Conclusión acerca de las Herramientas Seleccionadas

A partir de la revisión precedente queda sustentado el arreglo metodológico del proyecto. Como arquitecturas globales de *Deep Learning* para ejecutar el paradigma *Cross-Site* se seleccionan el **Temporal Fusion Transformer** (TFT), la arquitectura atencional **Informer** y la red jerárquica **N-HITS**, complementadas por una **LSTM** global. Como líneas base del paradigma local tradicional se emplean **XGBoost** y las mismas arquitecturas profundas entrenadas de forma estrictamente aislada por planta. Este contraste —modelos globales frente a modelos locales, sobre un protocolo de evaluación idéntico— provee el marco analítico riguroso necesario para cuantificar empíricamente en qué medida el aprendizaje multi-sitio mitiga el problema del *Cold-Start* bajo escasez informativa extrema.

Capítulo III

Estado del Arte / Benchmarking

3. Estado del Arte / Benchmarking

Este capítulo revisa la literatura científica reciente centrada específicamente en la **aplicación** de técnicas de aprendizaje al pronóstico de generación fotovoltaica. A diferencia del marco teórico —que expuso la genealogía de los métodos—, aquí el interés recae en cómo esos métodos se han instrumentado sobre datos solares reales, qué desempeño empírico han reportado y qué limitaciones persisten. La revisión avanza de lo general a lo específico: parte de los enfoques de *Machine Learning* y aprendizaje profundo aplicados al pronóstico solar, transita hacia las arquitecturas atencionales, y converge en la frontera que motiva esta investigación: la transferencia de conocimiento entre plantas bajo escasez de datos.

3.1. Enfoques de Machine Learning y Aprendizaje Profundo en el Pronóstico Fotovoltaico

La investigación aplicada inicial del pronóstico fotovoltaico se apoyó predominantemente en algoritmos ajustados con el historial climático de una sola ubicación. En una evaluación comparativa sobre un conjunto de datos solar real, Arslan et al. (2025) contrastaron algoritmos clásicos de *Machine Learning* frente a modelos de aprendizaje profundo basados en Transformers, documentando la superioridad de estos últimos para capturar la dinámica no lineal de la irradiancia, aunque a costa de un mayor requerimiento computacional y de datos [Arslan et al., 2025]. En la misma línea, los estudios centrados en algoritmos de potenciación del gradiente han consolidado a XGBoost como una línea base robusta y explicable para el pronóstico energético, destacando su eficiencia y su capacidad para jerarquizar la importancia de las variables meteorológicas, si bien evidencian su fragilidad ante regímenes de datos no observados en entrenamiento [Zhu et al., 2023]. Estos trabajos establecen el punto de partida empírico: los modelos locales son eficaces sobre bancos de datos extensos, pero su desempeño se degrada precisamente en las condiciones de escasez que caracterizan la puesta en marcha de una planta.

El giro hacia el aprendizaje profundo consolidó una nueva generación de modelos aplicados específicamente al pronóstico fotovoltaico. Mellit et al. (2021) demostraron que las redes neuronales profundas superan a los métodos estadísticos clásicos en el pronóstico de potencia FV de corto plazo, capturando con mayor fidelidad la dinámica no lineal de la generación [Mellit et al., 2021]. Khan et al. (2022) llevaron esta idea a esquemas de ensamble apilado (*stacking*) de modelos profundos, reportando una mejora en la robustez de la predicción frente a las arquitecturas individuales, a costa de una mayor complejidad de entrenamiento [Khan et al., 2022]. Revisiones sistemáticas del área, como la de Kumari y Toshniwal (2021), confirman la preeminencia del aprendizaje profundo para el pronóstico de irradiancia y potencia solar, al tiempo que señalan como limitación transversal la dependencia de historiales locales extensos para el entrenamiento

[Kumari and Toshniwal, 2021]. Esta constatación —modelos cada vez más potentes pero aún atados al dato local— es la que motiva el giro hacia los paradigmas de transferencia que se revisan más adelante.

3.2. Arquitecturas Atencionales Aplicadas a la Energía Solar

La adopción de arquitecturas Transformer en el dominio solar ha producido resultados consistentemente favorables. López Santos et al. (2022) aplicaron el *Temporal Fusion Transformer* al pronóstico fotovoltaico a un día vista (*day-ahead*), aprovechando su capacidad para fusionar covariables estáticas y dinámicas y para emitir predicciones por cuantiles, y reportaron mejoras significativas frente a las líneas base recurrentes [López Santos et al., 2022]. El-Saieed (2025) propuso un Transformer adaptativo para el pronóstico de largo plazo de temperatura y radiación en el contexto de la generación fotovoltaica, mostrando la idoneidad del mecanismo de atención para modelar las dependencias meteorológicas de largo alcance que gobiernan la producción [El-Saieed, 2025]. Ampliando el espectro de fuentes de datos, Li et al. (2024) abordaron el *nowcasting* solar mediante un Transformer que ingiere imágenes de satélite geoestacionario, evidenciando que la atención puede explotar información espacial exógena para anticipar la variabilidad inducida por la nubosidad [Li et al., 2024]. En conjunto, esta línea confirma que las arquitecturas atencionales constituyen el estado del arte metodológico en el pronóstico fotovoltaico aplicado, pero la mayoría de estos trabajos opera todavía bajo el supuesto de disponer de historial local suficiente para el entrenamiento.

3.3. Transferencia de Conocimiento y Escasez de Datos en Sistemas Fotovoltaicos

La frontera de la disciplina, y el núcleo de esta investigación, es la aplicación de la transferencia de conocimiento para resolver la escasez de datos. Bak et al. (2025) testearon empíricamente esquemas de *Transfer Learning* para el pronóstico de potencia fotovoltaica **entre regiones**, agregando datos de gran escala de múltiples plantas operativas para pre-entrenar un modelo base; sus resultados demuestran una atenuación de los márgenes de error durante las primeras semanas de operación en sitios geográficos nuevos, aunque el esquema aún requiere una fase de ajuste fino (*fine-tuning*) una vez disponibles los primeros registros locales [Bak et al., 2025]. Llevando esta idea a su expresión más extrema, Mishra et al. (2025) exploraron el pronóstico de irradiancia solar de corto plazo mediante modelos fundacionales en un régimen de **transferencia zero-shot**, es decir, sin ajuste alguno sobre la planta objetivo, anticipando el potencial de los modelos pre-entrenados a gran escala para operar desde el primer instante [Mishra et al., 2025]. Estos trabajos validan la dirección del aprendizaje multi-sitio, pero dejan abierta la pregunta de cuánto de esa ganancia se sostiene bajo un protocolo de evaluación estrictamente ciego a la planta objetivo y contrastado de forma justa contra líneas base locales

maduras.

3.4. Síntesis Comparativa y Brecha Identificada

La Tabla 3.2 sintetiza los estudios revisados según su enfoque, aporte principal y limitación metodológica.

De la revisión emerge una brecha clara. Si bien la literatura valida tanto la eficacia de las arquitecturas atencionales sobre datos solares como la promesa del aprendizaje por transferencia para mitigar la escasez de datos, los trabajos existentes rara vez combinan tres condiciones simultáneamente: **(i)** una evaluación estrictamente ciega a la planta objetivo (*zero-shot* real, sin ajuste ni contexto local), **(ii)** un contraste directo y justo contra líneas base locales maduras bajo un protocolo idéntico, y **(iii)** una caracterización de la incertidumbre mediante intervalos probabilísticos y un análisis de sensibilidad estacional. La mayoría, además, opera sobre pocas plantas o requiere fases de ajuste fino que difuminan la condición de arranque en frío puro.

Para abordar esta brecha, el presente proyecto de título implementa y evalúa un marco predictivo *Cross-Site* soportado sobre el *Temporal Fusion Transformer*, el *Informer* y N-HiTS, bajo un protocolo de retención de una planta (*Leave-One-Plant-Out*) que garantiza la integridad *zero-shot*. La evaluación se estructura como un *benchmarking* cerrado que contrasta estas arquitecturas globales contra líneas base estrictamente locales (XGBoost y las mismas redes profundas entrenadas de forma aislada), reporta métricas puntuales y probabilísticas, y estratifica los resultados por estación del año sobre un conjunto de **94 plantas fotovoltaicas** del Sistema Eléctrico Nacional chileno. Esta configuración permite dictaminar cuantitativamente en qué medida el conocimiento climático generalizado de la flota operativa mitiga los sesgos predictivos durante el arranque en frío de nuevos parques solares.

Estudio	Enfoque	Aporte principal	Limitación metodológica
Arslan et al. (2025)	ML vs. Transformer (local)	Comparación empírica sobre datos solares reales; superioridad de la atención.	Entrenamiento local; no aborda el arranque en frío.
Zhu et al. (XG-Boost)	Machine Learning local	Línea base robusta y explicable para pronóstico energético.	Degradación severa fuera del rango histórico observado.
Mellit et al. (2021)	DL para potencia FV (corto plazo)	Superioridad del aprendizaje profundo sobre los métodos estadísticos clásicos.	Requiere historial local extenso para el entrenamiento.
Khan et al. (2022)	Ensamble profundo (<i>stacking</i>)	Mayor robustez de la predicción frente a arquitecturas individuales.	Complejidad de entrenamiento del ensamble.
Kumari & Toshniwal (2021)	Revisión DL irradiancia/FV	Consolida el DL como estado del arte del pronóstico solar.	Dependencia del dato local; sin foco en transferencia.
López Santos et al. (2022)	TFT para FV (<i>day-ahead</i>)	Fusión de covariables estáticas/dinámicas y pronóstico por cuantiles.	Requiere historial local del sitio evaluado.
El-Saieed (2025)	Transformer adaptativo FV	Modelado de dependencias meteorológicas de largo plazo.	Enfocado en variables meteorológicas, no en transferencia inter-sitio.
Li et al. (2024)	Transformer + satélite	Explotación de información espacial exógena (nubosidad).	Dependencia de infraestructura de datos satelitales.
Bak et al. (2025)	Transfer Learning inter-regional	Atenuación del error en las primeras semanas en sitios nuevos.	Exige <i>fine-tuning</i> con datos locales iniciales.
Mishra et al. (2025)	Zero-shot / modelo fundacional	Pronóstico de irradiancia sin ajuste sobre el sitio objetivo.	Foco en irradiancia; sin <i>benchmarking</i> contra locales maduros.

Tabla 3.2: Síntesis comparativa de los estudios de pronóstico fotovoltaico aplicado revisados.

Capítulo IV

Metodología y Propuesta de Solución

4. Metodología y Propuesta de Solución

4.1. Propuesta de Solución

La propuesta de solución consiste en el diseño e implementación de un modelo predictivo global basado en una arquitectura Transformer, el cual es pre-entrenado mediante un enfoque *Cross-Site Learning* sobre un conglomerado de plantas solares consolidadas. El propósito central es transferir este conocimiento climático hacia instalaciones nuevas que sufren de escasez de datos e intermitencias operativas (*Cold-Start*), logrando proyecciones estables desde sus primeros días de conexión a la red.

Con base en los requerimientos técnicos de integridad informativa, el alcance empírico abarca instalaciones solares consolidadas y agrupadas estratégicamente por Macrozona. En lugar de limitar la muestra a un número fijo de plantas en una única región, el enfoque *Cross-Site* capitaliza la diversidad geográfica y climática disponible, empleando algoritmos de imputación robustos para aquellos vacíos operativos manejables. Esta configuración garantiza que el modelo asimile una correlación termodinámica auténtica y representativa, permitiendo transferir el aprendizaje a nuevas instalaciones independientemente de su ubicación, siempre que compartan el perfil macrozonal. Desde la perspectiva algorítmica, el proyecto adopta la arquitectura *Temporal Fusion Transformer* (TFT) debido a su capacidad innata para procesar de forma asimétrica datos multimodales: asimilando variables dinámicas meteorológicas temporales en conjunto con características estáticas geográficas. Para dictaminar la efectividad de esta red frente a la problemática de arranque en frío, se contrastará su rendimiento de extrapolación (*Zero-Shot*) frente al algoritmo profundo *N-HiTS* y contra las herramientas locales tradicionales (*XGBoost* y *LSTM*).

4.2. Adaptación Metodológica (Pipeline de Trabajo)

Para sistematizar la ejecución del proyecto y asegurar la replicabilidad de los experimentos, la investigación se apoya en un *pipeline* de *Machine Learning Operations* (MLOps) segmentado en cuatro fases metodológicas secuenciales implementadas en lenguaje Python.

Fase 0: Extracción, Transformación y Carga (ETL)

La fase fundacional del orquestador aborda el acondicionamiento integral de los datos estructurando el proceso en un modelo de capas secuenciales *Medallion* (Landing, Bronze, Silver y Gold). Para mitigar los cortes de sensores y evitar el *Data Leakage*, se definieron reglas estrictas:

1. **Variables Exógenas y Agrupación:** La imputación de variables meteorológicas se realiza escalonadamente (interpolación lineal y *ffill/bfill* por grupos temporales),

Transferencia Cross-Site: pre-entrenamiento multi-planta e inferencia sobre una planta sin historia




Figura 4.5: Representación esquemática de la propuesta de solución predictiva.

y se incorpora una variable indicadora booleana (*dummy*) para señalar registros imputados. Además, se aplican características cíclicas (*seno/coseno*) para capturar estacionalidad y se impone un forzamiento a cero en la irradiancia global durante períodos nocturnos garantizados.

2. **Manejo Estricto del Target (Intocable):** A diferencia de las variables exógenas, la variable objetivo (generación de energía) no es sometida a ningún tipo de imputación ni se rellena con ceros lógicos. Si un registro horario está ausente, permanece como NaN en el vector final. Los modelos administran estas intermitencias mediante la reindexación de la grilla horaria, y las métricas penalizan exclusivamente sobre observaciones reales y existentes. Esta decisión asegura que el *Performance Ratio* no se distorsione sintéticamente.

Fase 1: Sintonización de Hiperparámetros (Tuning)

Para garantizar una comparativa justa (*Benchmarking*) entre las redes profundas globales y los algoritmos tradicionales locales, es imperativo descubrir la configuración óptima de la topología de las redes. En esta etapa, el orquestador emplea heurísticas de búsqueda y validación cruzada para sintonizar los hiperparámetros críticos (tasa de aprendizaje, profundidad del codificador, número de cabezales de atención en el TFT y tamaño




Figura 4.6: Algoritmia del proceso de preparación de datos y control de calidad.

de la ventana temporal) maximizando el rendimiento predictivo inicial sobre el corpus histórico general antes de someter a los modelos al estrés del arranque en frío.

Fase 2: Simulación Cold-Start (Estrategia LOPO)

El núcleo de la experimentación reside en la aplicación de la metodología de retención espacial *Leave-One-Plant-Out* (LOPO). En lugar de dividir el set de datos cronológicamente, el orquestador aísla dinámicamente y oculta por completo el historial operativo de una de las plantas (capa *Gold* de validación). El modelo *Cross-Site* es entrenado exclusivamente con los años de experiencia del resto de la flota operativa. Para emular el arranque en frío (*Cold-Start*) de la planta seleccionada, el contexto histórico (*seed*) previo al horizonte de pronóstico se inicializa de forma 100% sintética ($y = \text{capacidad} \times \text{PR regional} \times \text{perfil solar}$), garantizando así que no exista *Data Leakage*. Dicho coeficiente de *Performance Ratio (PR) regional* se calcula como un agrupamiento histórico estratificado por Macrozona y Estación del Año, computado empleando única y estrictamente el conjunto de entrenamiento. Una vez consolidados los pesos sinápticos, la red es forzada a inferir el comportamiento energético futuro de la planta oculta utilizando únicamente sus coordenadas estáticas y el clima entrante. Este procedimiento se repite iterativamente rotando la instalación objetivo. Asimismo, la orquestación de esta fase admite la ejecución bajo distintas escalas (*Toy*, *Half* y *Total*) que modulan la fracción de la muestra analizada, agilizando el *benchmarking*.




Figura 4.7: Visualización iterativa del aislamiento espacial para simulación de arranque en frío.

Fase 3: Extracción de Resultados y Métricas de Rendimiento

La fase final consolida los vectores predictivos generados por cada una de las arquitecturas sometidas a prueba —modelos globales *Cross-Site* (TFT, Informer, N-HiTS, LSTM y XGBoost Global) y líneas base estrictamente locales entrenadas con la historia propia de cada planta (XGBoost, LSTM y N-HiTS locales)— contrastándolos unificadamente contra la producción energética empírica de los parques solares aplicando 2 estrategias de testeo diferenciadas según la ventana temporal proyectada (*day1* para predicción a 24 horas y *rollout7d* para proyección expandida iterativa a una semana). Adicionalmente, los resultados y desvíos son evaluados de manera estratificada según la **Estación del Año**, lo que permite medir el impacto de la variabilidad meteorológica cíclica en las redes. El proyecto computa métricas clásicas de pronóstico, entre las cuales destacan:

- **Error Absoluto Medio (MAE):** Para cuantificar la magnitud promedio lineal del error en la escala energética real (MW).
- **Error Cuadrático Medio (RMSE):** Para penalizar logarítmicamente las desviaciones más grandes generadas por los sesgos del modelo durante picos de inyección.
- **Error Porcentual Absoluto Medio Simétrico (sMAPE):** Empleado como estándar de industria para dimensionar la falla en términos relativos porcentuales, independientemente de la capacidad instalada de la planta.
- **Pronóstico Probabilístico y MQLoss:** Las redes profundas evalúan también intervalos de confianza (90 % CI) para reportar la incertidumbre esperada y la cobertura del intervalo (*Pinball Loss*), sumando fiabilidad a la predicción puntual. Las predicciones finales son ajustadas para cumplir leyes físicas (mínimo de cero general y cero estricto de noche).

La consolidación de estas métricas se tabulará y graficará para facilitar el análisis comparativo financiero y operativo entre el modelo Transformer global y las líneas bases locales.

Protocolo de evaluación Cold-Start: contexto sintético, horizontes y ventanas de sensibilidad




Figura 4.8: Protocolo de evaluación Cold-Start: contexto sintético, horizontes de pronóstico y ventanas del análisis de sensibilidad sobre las cuales se computan las métricas comparativas.

El cronograma temporal que ordena la ejecución de estas cuatro fases corresponde a la carta Gantt de seis semanas presentada en la Figura 1.2 del Capítulo I, cuyas actividades se encuentran categorizadas según el objetivo específico al que tributan.

4.3. Estudio de Factibilidad

Factibilidad técnica

La factibilidad técnica de este proyecto está garantizada por la disponibilidad de herramientas de *software* de código abierto (*Open Source*) y librerías especializadas en *Machine Learning* y *Deep Learning*. Toda la orquestación del pipeline (ETL, entrenamiento y validación) se encuentra programada en *Python*, utilizando el ecosistema *Nixtla* (específicamente *NeuralForecast*) para la ejecución de los algoritmos atencionales de última generación (TFT y N-HiTS), así como *XGBoost* para las líneas base locales. Adicionalmente, el procesamiento matricial intensivo requerido por el paradigma *Cross-Site Learning* se aborda mediante el uso de aceleración por hardware computacional (GPUs), recursos que son accesibles a través de entornos de desarrollo estándar.

Factibilidad operativa

La operación del estudio es autónoma y reproducible: el pipeline completo se ejecuta desde un único punto de entrada con validación automatizada previa (gate de pruebas),

control de idempotencia para reanudar corridas interrumpidas y generación automática de reportes. La extensión del análisis a nuevas plantas o períodos no requiere infraestructura ni personal adicional.

Factibilidad económica

El costo marginal del proyecto es prácticamente nulo: las fuentes de datos son públicas (Coordinador Eléctrico Nacional y red climatológica CR2), la totalidad del software empleado es de código abierto y el cómputo se resuelve en hardware de consumo (una única GPU de gama media), sin requerir financiamiento externo ni servicios de nube de pago.

Factibilidad legal

Los datos empleados provienen de repositorios públicos de organismos oficiales chilenos y no contienen datos personales ni información sujeta a confidencialidad. Las licencias de las librerías utilizadas (ecosistema Python de código abierto) son compatibles con el uso académico e investigativo del presente trabajo.

Factibilidad Social

El proyecto no genera impactos sociales adversos. Indirectamente, la mejora del pronóstico de generación en plantas recién conectadas contribuye a la estabilidad del suministro eléctrico y reduce las barreras de entrada para nuevos actores renovables de menor escala.

Factibilidad Ambiental

La investigación tributa a la descarbonización de la matriz energética al facilitar la integración temprana de nueva capacidad solar. La huella de cómputo del estudio es acotada: los entrenamientos completos se resuelven en horas sobre una única GPU, sin infraestructura de centros de datos dedicada.

Capítulo V

Desarrollo de la Propuesta y Resultados

5. Desarrollo de la Propuesta y Resultados

Este capítulo documenta la ejecución de las cuatro fases metodológicas definidas en la Sección 4.2, junto a las evidencias y resultados obtenidos en cada una de ellas. Las evidencias complementarias (tablas completas de métricas por planta, registros de imputación y bitácoras de ejecución) se remiten a los Anexos.

5.1. Fase 0: Construcción del Pipeline de Datos (ETL)


La implementación del modelo de capas *Medallion* consolidó los registros horarios de generación del Coordinador Eléctrico Nacional (139 archivos mensuales, período 2014–2024) con las variables meteorológicas de la red CR2 (radiación global instantánea, temperatura del aire y humedad relativa), resultando en un corpus unificado de **94 plantas fotovoltaicas** y aproximadamente **4,37 millones de observaciones planta-hora** tras el proceso de depuración.

Durante la construcción de la capa *Bronze* se identificaron y resolvieron tres hallazgos relevantes de calidad de datos:

1. **Agregación multi-unidad:** centrales compuestas por múltiples unidades físicas de reporte (ej. PFV Jama, con dos unidades registradas bajo la misma central y una capacidad combinada de 51 MW) se consolidaron sumando la generación por hora, en coherencia con la capacidad declarada en el maestro de instalaciones.
2. **Transiciones de horario de verano (DST):** la hora repetida del primer domingo de abril se colapsó de forma segura (para generación solar corresponde a horas nocturnas de producción nula).
3. **Integridad del target:** en concordancia con la regla metodológica de no imputación de la variable objetivo, los vacíos de generación permanecen ausentes y las métricas se computan exclusivamente sobre observaciones reales.

La capa *Silver* incorporó las características cíclicas temporales (seno/coseno de hora, mes y estación), la asociación geográfica por Macrozona y la imputación trazable de exógenas (con variables indicadoras *is_imputed* y bitácora de imputación), mientras que la capa *Gold* materializó las particiones de validación LOPO por planta.

La Tabla 5.3 resume la composición del corpus resultante por macrozona. La cobertura se concentra en el Norte Chico y la Zona Central, en coherencia con la distribución real del parque fotovoltaico conectado al Sistema Eléctrico Nacional.



Orquestador único (src/orchestrator.py) · gate TDD (pytest) previo a cada corrida · Idempotencia con marcadores de completitud

Figura 5.9: Flujo de datos implementado: Landing → Bronze → Silver → Gold, con los volúmenes reales tras la depuración.

Macrozona	Plantas	Capacidad (MW)	Obs. (millones)	Desde	Hasta
Norte Chico	35	750	1.57	2014-01-01	2025-01-01
Norte Grande	12	732	0.58	2014-02-01	2025-01-01
Zona Central	46	390	2.17	2014-01-01	2025-01-01
Zona Sur	1	3	0.05	2019-08-01	2025-01-01
Total	94	1,876	4.37	2014-01-01	2025-01-01

Tabla 5.3: Composición del corpus unificado (capa Silver) por macrozona.

5.2. Fase 1: Sintonización de Hiperparámetros

La búsqueda de hiperparámetros se implementó mediante optimización bayesiana (*Optuna*), explorando la tasa de aprendizaje y la dimensión oculta de cada arquitectura global (mapeada al parámetro real de cada red: *encoder* en LSTM, unidades MLP por bloque en N-HiTS y dimensión del modelo en TFT e Informer). Para contener el costo computacional, la sintonización se ejecuta una única vez por arquitectura y estrategia de escala, reutilizando la configuración óptima en todos los pliegues LOPO; la fuga de información a nivel de hiperparámetros asociada a esta decisión se considera despreciable en la literatura de pronóstico global.

Adicionalmente, el entrenamiento incorpora detención temprana (*early stopping*) sobre una ventana de validación de 168 horas por serie y se ejecuta en **precisión completa (fp32)** en todas las arquitecturas. Esta última fue una decisión de diseño adoptada tras constatar durante la ejecución a escala que la precisión mixta (fp16) inducía divergencia numérica (predicciones NaN) en múltiples combinaciones arquitectura-planta —de forma sistemática en las redes recurrentes y en la atención prob-sparse, y de forma intermitente en el resto—; se privilegió la corrección numérica sobre la ganancia de velocidad.

La Tabla 5.4 presenta la configuración óptima seleccionada para cada arquitectura global, junto a la ventana de entrada y la precisión de entrenamiento.

Arquitectura	Ventana entrada (h)	Parám. de dimensión	Valor	Tasa aprendizaje	Precisión
LSTM	168	encoder_hidden_size	128	4.68e-03	fp32
N-HiTS	168	mlp_units	64	5.89e-03	fp32
TFT	168	hidden_size	32	1.83e-03	fp32
Informer	168	hidden_size	64	2.74e-04	fp32

Tabla 5.4: Hiperparámetros óptimos por arquitectura global (búsqueda bayesiana con *Optuna*) y precisión numérica de entrenamiento.

Para dimensionar el costo estructural de cada enfoque, la Tabla 5.5 contrasta el número de parámetros de cada modelo con su error de pronóstico, y la Figura 5.10 lo visualiza. La medida de complejidad es heterogénea por familia —pesos entrenables en las redes profundas, número de nodos del ensamble en los modelos de árboles—, por lo que la comparación es indicativa y no estrictamente conmensurable, pero evidencia que un mayor número de parámetros no se traduce necesariamente en mayor precisión bajo el régimen Cold-Start.

Modelo	Parámetros	rRMSE roll-out (%)	Tipo de parámetro
XGBoost local	18.156	70.3	nodos de árbol
LSTM local	223.110	133.1	pesos entrenables
N-HiTS local	337.017	89.5	pesos entrenables
XGBoost global	18.418	81.0	nodos de árbol
LSTM global	223.110	115.3	pesos entrenables
N-HiTS global	337.017	154.7	pesos entrenables
TFT global	173.194	116.5	pesos entrenables
Informer global	94.630	112.5	pesos entrenables

Tabla 5.5: Complejidad de cada modelo (número de parámetros) frente a su error mediano de pronóstico.




Figura 5.10: Complejidad del modelo (escala logarítmica) frente al error de pronóstico Cold-Start.

5.3. Fase 2: Simulación Cold-Start (LOPO)

La evaluación *Leave-One-Plant-Out* se ejecutó conforme al diseño metodológico: para cada planta objetivo, los modelos globales se entrenan con las restantes $N - 1$ instalaciones y la inferencia se inicializa con un contexto histórico 100% sintético ($y = \text{capacidad} \times PR_{\text{regional}} \times \text{perfil solar}$), donde el *Performance Ratio* regional se computa estrictamente sobre el conjunto de entrenamiento, estratificado por Macrozona y estación del año.

Como refinamiento metodológico surgido durante el desarrollo, la evaluación incorpora un **análisis de sensibilidad sobre la definición de la ventana de evaluación**, motivado por la detección de *rampas de puesta en marcha*: períodos iniciales de las series (de días a semanas) con generación nula previa a la operación comercial sostenida. Se evalúan por planta:

- **Ventana Raw:** desde la primera hora registrada de la planta (fiel al registro histórico, incluye la rampa).
- **Ventana Operacional:** desde la primera hora de producción sostenida (definida como el primer instante productivo que inaugura al menos 10 horas con generación superior al 5% de la capacidad dentro de las 72 horas siguientes).
- **Ventanas Estacionales:** la primera ventana de producción sostenida cuyo inicio cae en cada una de las cuatro estaciones del año, permitiendo cuantificar el efecto de la variabilidad meteorológica cíclica sobre la transferencia *Cold-Start*.

Cada ventana se evalúa en los dos horizontes definidos (*day1* y *rollout7d*, este último con realimentación autorregresiva de la mediana predicha), y las ventanas de evaluación se excluyen íntegramente del entrenamiento del baseline local para prevenir contaminación *train-on-test*.

5.4. Fase 3: Resultados y Análisis Comparativo

Los resultados que se presentan corresponden a la ejecución de la estrategia de escala *total*: evaluación LOPO sobre las **94 plantas objetivo**, con los modelos globales entrenados sobre la base histórica completa (2014–2024) de las restantes $N - 1$ instalaciones. Cada celda reportada corresponde a la **mediana** sobre las plantas evaluadas (robusta frente a casos extremos); n indica el número de plantas con evaluación válida para cada modelo. Para la lectura de las magnitudes debe considerarse que el rRMSE normaliza por la generación media horaria de la ventana, la cual incluye las horas nocturnas de producción nula: esto infla sistemáticamente el indicador (valores sobre 100 % son esperables en pronóstico horario fotovoltaico bajo esta normalización) y su valor reside en la **comparación relativa** entre arquitecturas evaluadas sobre ventanas idénticas. Como salvaguarda metodológica, las métricas se computan únicamente sobre observaciones reales y todos los modelos —tanto de árboles como profundos— emiten intervalos

de predicción P5/P50/P95 sobre una misma grilla horaria canónica, garantizando una comparación estrictamente pareada.

Resultados Globales por Arquitectura

Las Tablas 5.6 y 5.7 resumen el desempeño de las ocho configuraciones evaluadas en ambas definiciones de ventana; la Figura 5.11 sintetiza la comparación en la ventana operacional.

Modelo	Day 1 (24 h)			Roll-out 7 días			<i>n</i>
	RMSE (MWh)	sMAPE (%)	rRMSE (%)	RMSE (MWh)	sMAPE (%)	rRMSE (%)	
XGBoost local	0.39	56.8	59.2	0.53	52.2	70.3	94
LSTM local	0.88	81.6	109.1	1.08	91.1	133.1	94
N-HiTS local	0.65	68.8	73.3	0.81	70.1	89.5	94
XGBoost global	0.76	44.3	74.2	0.65	45.2	81.0	94
LSTM global	1.07	91.9	107.1	1.11	91.3	115.3	94
N-HiTS global	1.04	100.8	140.3	1.26	108.8	154.7	94
TFT global	0.87	90.1	107.7	0.96	87.4	116.5	94
Informer global	0.89	91.5	108.7	0.95	93.6	112.5	94

Tabla 5.6: Métricas medianas por arquitectura y horizonte — ventana *Raw* (desde la primera hora registrada; 94 plantas).

Modelo	Day 1 (24 h)			Roll-out 7 días			<i>n</i>
	RMSE (MWh)	sMAPE (%)	rRMSE (%)	RMSE (MWh)	sMAPE (%)	rRMSE (%)	
XGBoost local	0.35	51.4	40.6	0.50	51.5	62.2	33
LSTM local	0.75	82.2	102.6	1.04	91.4	146.9	33
N-HiTS local	0.71	56.9	73.6	0.87	69.1	104.0	33
XGBoost global	0.61	39.8	77.5	0.55	40.7	95.4	33
LSTM global	1.01	86.3	103.4	1.08	91.8	118.2	33
N-HiTS global	1.28	95.8	130.6	1.31	96.9	150.4	33
TFT global	0.90	89.5	110.2	0.97	96.2	133.1	33
Informer global	0.86	82.2	96.9	0.89	89.0	129.3	33

Tabla 5.7: Métricas medianas por arquitectura y horizonte — ventana *Operacional* (desde la primera producción sostenida; subconjunto de 33 plantas con rampa de puesta en marcha distinguible).




Figura 5.11: Error relativo mediano por arquitectura y horizonte en la ventana operacional.

Tres lecturas emergen con claridad de la ventana operacional (roll-out de 7 días). Primero, **XGBoost local** —entrenado con la historia propia de cada planta— es la configuración más precisa (rRMSE mediano de 62 %), seguido de **XGBoost global** (95 %), que se erige como el mejor modelo del paradigma *Cross-Site*. Segundo, entre las redes profundas globales, la **LSTM** (118 %) supera a las arquitecturas atencionales **Informer** (129 %) y **TFT** (133 %) y a la **N-HiTS** (150 %), un ordenamiento coherente con la advertencia de la literatura sobre el sobre-dimensionamiento de la atención frente a líneas base más simples [Zeng et al., 2023]. Tercero, la degradación entre el horizonte *day1* y el roll-out semanal es moderada en todas las familias, lo que indica que la realimentación autorregresiva de la mediana predicha no desestabiliza los pronósticos.

Análisis por Estación del Año

El análisis por estación del año constituye un eje central de esta evaluación: para cada planta se construyen ventanas de arranque en frío que inician en cada una de las cuatro estaciones (tomadas de su propia historia posterior a la puesta en marcha), lo que permite caracterizar cómo la variabilidad meteorológica cíclica afecta la transferencia de conocimiento. Cabe precisar que estas ventanas estacionales son **simulaciones del arranque en frío en distintas épocas del año** y son independientes de la estación en que la planta se conectó realmente: una planta conectada en verano también aporta

una ventana invernal. Las Tablas 5.8 y 5.9 presentan la sensibilidad estacional en ambos horizontes, y la Figura 5.12 la sintetiza para las arquitecturas representativas.

Modelo	Verano	Otoño	Invierno	Primavera
XGBoost local	21.9	22.4	68.6	66.1
LSTM local	57.9	124.3	110.1	126.4
N-HiTS local	50.7	50.5	100.8	72.0
XGBoost global	44.8	43.7	83.5	74.1
LSTM global	91.2	88.0	114.1	109.4
N-HiTS global	106.5	121.1	152.2	133.3
TFT global	84.1	88.1	122.5	110.3
Informer global	82.1	88.4	112.2	110.4
<i>n plantas</i>	94	92	93	94

Tabla 5.8: rRMSE mediano (%) del horizonte *day1* por estación del año en que inicia la ventana de evaluación.

Modelo	Verano	Otoño	Invierno	Primavera
XGBoost local	40.5	35.9	114.8	101.5
LSTM local	94.1	139.6	166.1	155.1
N-HiTS local	66.0	74.0	143.5	118.1
XGBoost global	51.8	53.7	133.5	106.1
LSTM global	93.9	97.0	186.3	136.2
N-HiTS global	114.0	130.3	188.7	148.9
TFT global	87.7	102.0	168.8	130.9
Informer global	87.9	92.9	172.0	137.0
<i>n plantas</i>	94	92	93	94

Tabla 5.9: rRMSE mediano (%) del roll-out de 7 días por estación del año en que inicia la ventana de evaluación.

El invierno es sistemáticamente la estación de mayor dificultad predictiva para todas las arquitecturas: en el roll-out semanal, XGBoost global pasa de 52 % (verano) a 133 % (invierno) y XGBoost local de 40 % a 115 %, un patrón que se repite en las redes profundas. La brecha se explica por la mayor variabilidad nubosa y la menor irradiación media invernal, que reducen la señal determinista del perfil solar y amplifican el peso relativo de los errores. Este hallazgo tiene una implicación operativa directa: la incertidumbre del pronóstico de un parque recién conectado depende de forma marcada de la estación de su puesta en marcha, siendo el invierno el escenario más adverso.




Figura 5.12: Sensibilidad estacional del Cold-Start para cuatro arquitecturas representativas.

Análisis de Sensibilidad: Ventana Raw vs. Operacional

Solo 33 de las 94 plantas presentan una rampa de puesta en marcha superior a 24 horas; para el resto, ambas definiciones de ventana coinciden. En la mediana agregada las diferencias son moderadas (Tablas 5.6 y 5.7), pero el promedio de la ventana *Raw* queda distorsionado en las plantas con rampa: al iniciar la evaluación sobre semanas de generación nula, la media de la ventana tiende a cero y el rRMSE se torna indefinido (reportado como no disponible para preservar la honestidad del agregado). El análisis confirma la decisión metodológica de **reportar ambas definiciones**: la ventana *Raw* es fiel al registro histórico, mientras que la *Operacional* produce métricas interpretables del desempeño sobre una planta que ya opera comercialmente.

Calidad Probabilística de los Intervalos

La Tabla 5.10 revela un contraste nítido en la calibración de los intervalos. Evaluada sobre las horas productivas —métrica que descuenta el acierto trivial nocturno—, **la regresión cuantílica de XGBoost calibra adecuadamente** (cobertura diurna de 0,99 en el modelo global y 0,86 en el local, en torno al 0,90 nominal), mientras que **las redes profundas globales quedan subcalibradas** (LSTM 0,54, Informer 0,65, TFT 0,44, N-HiTS 0,36). La explicación es coherente con el diseño experimental: el escalador local de cada red profunda se ajusta sobre el contexto sintético, cuya varianza (un perfil solar idealizado) es inferior a la variabilidad real de la planta, produciendo bandas demasiado estrechas; los baselines locales profundos, que disponen de contexto real, mejoran su cobertura (LSTM local 0,79, N-HiTS local 0,66). XGBoost, en cambio, aprende los

Modelo	Cobertura 90 % (con noche)	Cobertura diurna (horas $y > 0$)	Pinball P05 (MWh)	Pinball P95 (MWh)
XGBoost local	0.88	0.86	0.039	0.033
LSTM local	0.85	0.79	0.041	0.211
N-HiTS local	0.83	0.66	0.045	0.107
XGBoost global	0.98	0.99	0.045	0.091
LSTM global	0.51	0.54	0.212	0.140
N-HiTS global	0.68	0.36	0.091	0.277
TFT global	0.50	0.44	0.195	0.123
Informer global	0.56	0.65	0.133	0.114

Tabla 5.10: Calidad probabilística de los intervalos de 90 % (roll-out 7 días, ventana operacional). La *cobertura con noche* incluye las horas nocturnas, donde el forzamiento físico a cero garantiza un acierto trivial; la *cobertura diurna* (solo horas con $y > 0$) es la medida honesta del mérito probabilístico.

cuantiles P5/P50/P95 directamente de la dispersión real observada en el entrenamiento multi-planta, lo que explica su calibración superior. La calibración de los intervalos de las redes profundas bajo transferencia Zero-Shot —por ejemplo mediante predicción conformal— se identifica como línea de trabajo futuro.

Contraste de la Hipótesis

La hipótesis del Capítulo I postula que el modelo global multi-sitio es capaz de superar en precisión a un modelo entrenado localmente con la información histórica del centro. Los resultados permiten un veredicto matizado en tres planos:

1. **A igualdad de arquitectura profunda, la transferencia global es competitiva, con un balance mixto:** en el roll-out semanal, la LSTM global supera a la LSTM local (118 % frente a 147 %), evidenciando que el conocimiento climático generalizado puede exceder el valor de la historia propia cuando esta es limitada; sin embargo, la N-HiTS local supera a la N-HiTS global (104 % frente a 150 %), lo que indica que la ventaja del paradigma global no es universal y depende de la arquitectura. El resultado matiza —sin invalidar— la premisa de la transferencia.
2. **Frente al mejor baseline local maduro, la hipótesis no se sostiene en términos absolutos:** XGBoost local con historia propia (62 % en roll-out operacional; 41 % en *day1*) supera al mejor modelo global (XGBoost global, 95 % y 78 % respectivamente). Cuando la planta ya acumuló historia suficiente, el modelo local especializado con rezagos autorregresivos sigue siendo la opción más precisa.

3. **El valor operativo del modelo global reside en la disponibilidad inmediata:** el paradigma local exige meses de espera para acumular datos de entrenamiento, mientras que el modelo global emite pronósticos utilizables desde la primera hora de conexión —el escenario exacto que motiva esta investigación—. En ese régimen (historia local nula), el modelo global no tiene competidor local posible, y su calibración probabilística superior (en el caso de XGBoost global) lo hace directamente accionable para la gestión de riesgo.




Figura 5.13: Ejemplo de roll-out Cold-Start de 7 días: el modelo global, sin haber visto jamás la planta objetivo, reproduce el ciclo diario y la magnitud de los picos de generación a partir únicamente del clima entrante y de las características geográficas estáticas, con el forzamiento físico a cero durante la noche astronómica.

En síntesis, la evidencia respalda la transferencia *Cross-Site* como solución operativamente viable al problema del arranque en frío —pronósticos coherentes y calibrados desde el día uno, con un desempeño competitivo frente a los baselines profundos locales—, al tiempo que delimita honestamente su alcance: una vez que la planta acumula historia operativa suficiente, un modelo local basado en gradiente extremo con rezagos autorregresivos vuelve a ser el estándar a batir. La contribución del proyecto no es, por tanto, declarar un ganador absoluto, sino cuantificar rigurosamente el compromiso entre disponibilidad inmediata y precisión asintótica que gobierna la elección de paradigma durante la puesta en marcha de un nuevo parque solar.

Capítulo VI

Conclusiones y Trabajo Futuro

6. Conclusiones y Trabajo Futuro

Este capítulo cierra la investigación contrastando los resultados obtenidos con los objetivos y la hipótesis planteados en el Capítulo I, y proyecta las líneas de continuidad que la evidencia empírica sugiere.

Conclusiones

En el plano del modelado, se adaptó y sintonizó un conjunto de arquitecturas globales de última generación —TFT, Informer, N-HiTS y LSTM— para el entrenamiento simultáneo multi-serie sobre la base histórica completa de hasta 93 plantas, mediante un pipeline reproducible con validación automatizada; su puesta en marcha exigió resolver desafíos de ingeniería no triviales —la estabilidad numérica que motivó la adopción de precisión completa fp32, un presupuesto de cómputo por época corregido y la gestión de memoria en una GPU de gama media—, lo que demuestra la viabilidad técnica del enfoque con recursos computacionales accesibles. Ese modelo global integró de forma efectiva datos multimodales, combinando variables exógenas dinámicas (radiación, temperatura y humedad de la red CR2), características estáticas geográficas (macrozona y capacidad instalada) y atributos cíclicos deterministas, bajo la garantía —verificada por pruebas automatizadas— de que ninguna característica derivada de la generación del objetivo contaminara el entrenamiento; en particular, el prior de eficiencia regional, calculado exclusivamente sobre las plantas de entrenamiento de cada partición, demostró ser un mecanismo eficaz para sembrar el contexto sintético sin fuga de información.

Sobre esta base, la evaluación *Leave-One-Plant-Out* de las 94 plantas objetivo entregó un veredicto matizado de la hipótesis. A igualdad de arquitectura profunda el balance es mixto —la LSTM global supera a su contraparte local en el horizonte semanal (118 % frente a 147 % de rRMSE mediano operacional), mientras que la N-HiTS local supera a la global—, lo que revela que la ventaja del paradigma global no es universal. Frente al baseline local más fuerte, un XGBoost con historia propia y rezagos autorregresivos (62 %), el mejor modelo global (XGBoost global, 95 %) tampoco alcanza la paridad en términos absolutos. El valor del enfoque global se circunscribe, por tanto, a un único régimen: el de la escasez de datos extrema, donde el paradigma local simplemente no puede existir y solo el modelo global entrega pronósticos coherentes desde la primera hora de conexión.

Del desarrollo emergen además cuatro hallazgos metodológicos transferibles. Primero, las **rampas de puesta en marcha** (semanas iniciales de generación nula) distorsionan las métricas relativas si la ventana de evaluación se define ingenuamente desde el primer registro, lo que motivó el análisis de sensibilidad Raw/Operacional. Segundo, el **invierno es sistemáticamente la estación más difícil** para el arranque en frío en todas las arquitecturas, con errores que duplican o triplican los estivales. Tercero, la **calibración probabilística no se transfiere a las redes profundas**: sus intervalos de 90 % quedan subcalibrados bajo contexto sintético (cobertura diurna del 36–65 % frente al 90 % nominal),

mientras que la regresión cuantílica de XGBoost sí calibra adecuadamente —un contraste crítico para el uso operativo de estas predicciones en mercados eléctricos—. Cuarto, la **integridad del target** —no imputar jamás la generación ausente— resultó esencial para la honestidad de las métricas, en contraste con la práctica habitual de rellenar con ceros.

Cumplimiento de los Objetivos y Rechazo de la Hipótesis

Los tres objetivos específicos formulados en el Capítulo I se cumplieron en su totalidad —la adaptación de una arquitectura Transformer al entrenamiento multi-serie, su evaluación frente a los modelos locales bajo un protocolo *Cold-Start* estricto, y la integración de datos multimodales sin fuga de información—: el proyecto satisface por completo lo que se propuso construir y medir.

La hipótesis de investigación, en cambio, se **rechaza**. El enunciado del Capítulo I sostenía que el modelo global multi-sitio sería *más preciso* que un modelo entrenado localmente; la evidencia empírica sobre las 94 plantas lo contradice de forma inequívoca: ningún modelo global igualó al mejor *baseline* local —XGBoost con historia propia (62 % de rRMSE en el roll-out operacional) frente al 95 % del mejor modelo global— y las propias arquitecturas atencionales que constituían el eje de la propuesta quedaron sistemáticamente por detrás de dicha línea base. Se trata, en consecuencia, de un **resultado negativo**: la hipótesis no se confirma.

Lejos de invalidar la investigación, esta refutación constituye uno de sus aportes centrales. Somete a una prueba considerablemente más estricta que la habitual en la literatura —evaluación estrictamente ciega a la planta objetivo, sin ajuste ni contexto local, y contrastada contra líneas base locales maduras— la creencia extendida en la superioridad de los modelos globales atencionales, y demarca con precisión el único régimen en que el enfoque global conserva un valor operativo indiscutible: el arranque en frío puro, donde por definición no existe historia local con la cual entrenar un modelo dedicado.

Trabajos Futuros

El rechazo de la hipótesis no clausura la línea de investigación; al contrario, señala con precisión dónde debe mejorar el enfoque global. A continuación se analizan las causas más probables del desempeño insuficiente de los modelos globales y las líneas de trabajo que de cada una se derivan:

- **Ausencia de ajuste fino (causa más probable):** el modelo global operó en un régimen *zero-shot* estricto —cero adaptación a la planta objetivo—, mientras que las líneas base locales que lo superaron sí observan datos reales del sitio. Es esperable que buena parte de la brecha se explique por esta asimetría. La extensión natural es un *fine-tuning* en dos etapas: pre-entrenar globalmente y luego ajustar con los primeros días de datos reales de la planta nueva, cerrando gradualmente la distancia

con el baseline local a medida que crece la historia propia. La evidencia obtenida (el paradigma local domina con historia suficiente) acota además el período en que esta transición aporta valor.

- **Rediseño arquitectónico con máscaras de intermitencia:** las arquitecturas empleadas tratan la serie fotovoltaica como una señal continua, cuando en realidad es intrínsecamente intermitente —ceros nocturnos deterministas y huecos estocásticos inducidos por la nubosidad—. Incorporar **máscaras de intermitencia** explícitas en el mecanismo de atención (excluir las horas nocturnas del cómputo, o introducir una compuerta día/noche condicionada a la elevación solar) permitiría al modelo concentrar su capacidad representacional en la señal productiva, en lugar de gastarla aprendiendo la estructura trivial de la noche. Es, posiblemente, la vía de mejora arquitectónica de mayor potencial para revertir la desventaja de las redes profundas frente a XGBoost.
- **Volumen y diversidad de los datos:** el corpus de 94 plantas, aun siendo amplio para un estudio de pregrado, puede resultar insuficiente para que las arquitecturas atencionales aprendan la variedad climática subyacente; la literatura de modelos fundacionales de series de tiempo se entrena sobre miles de series de dominios heterogéneos. Ampliar el corpus —más plantas, más regiones y más años de historia— podría desbloquear la ventaja global que no se materializó a esta escala.
- **Presupuesto de cómputo y posible sub-entrenamiento:** los modelos profundos se entrenaron con un tope de pasos acotado por la memoria de una GPU de gama media (6 GB). Las arquitecturas de mayor capacidad (TFT, Informer) pudieron quedar sub-entrenadas respecto de su potencial, lo que ofrecería una explicación adicional a que fueran superadas por modelos más simples. Reentrenar con un presupuesto de cómputo mayor permitiría verificar si el ordenamiento observado es estructural o un artefacto del sub-entrenamiento.
- **Calibración de intervalos bajo transferencia:** la subcobertura detectada en las redes profundas sugiere incorporar predicción conformal u otro mecanismo de recalibración post-hoc que ensanche los intervalos sintéticos hacia la variabilidad real observada en plantas análogas de la misma macrozona.
- **Consistencia física independiente de sensores:** el forzamiento nocturno a cero depende de la radiación observada, vulnerable a huecos de imputación; una máscara astronómica (elevación solar calculada desde coordenadas y calendario) eliminaría el piso nocturno residual observado en los roll-outs.
- **Despliegue y ampliación territorial:** incorporar PatchTST cuando el ecosistema NeuralForecast soporte variables exógenas para dicha arquitectura, y refinar el prior

regional con un *clustering* climático más fino que la macrozona. El despliegue operacional (MLOps) permanece explícitamente fuera del alcance, conforme a la delimitación del proyecto.

Bibliografía

- ACERA (2025). Boletín estadístico acera (asociación chilena de energías renovables y almacenamiento). <https://cdn.acera.cl/wp-content/uploads/2026/01/2025-12-Boletin-Estadisticas-ACERA.pdf>.
- Antonanzas, J., Osorio, N., Escobar, R., Urraca, R., Martinez-de Pison, F. J., and Antonanzas-Torres, F. (2016). Review of photovoltaic power forecasting. *Solar Energy*, 136:78–111.
- Arslan, Z., Sahin, M. E., and Ulutas, H. (2025). Comparative evaluation of machine learning and transformer-based deep learning for solar energy forecasting on a real-world dataset. *Arabian Journal for Science and Engineering*, 51:6833–6863.
- Bai, S., Kolter, J. Z., and Koltun, V. (2018). An empirical evaluation of generic convolutional and recurrent networks for sequence modeling. *arXiv preprint arXiv:1803.01271*.
- Bak, S., Choi, S., Yang, D., Kim, D., Rho, H., and Lee, K. (2025). Transfer learning for photovoltaic power forecasting across regions using large-scale datasets. *IEEE Access*.
- Benidis, K., Rangapuram, S. S., Flunkert, V., Wang, Y., Maddix, D., Turkmen, A. C., Gasthaus, J., Bohlke-Schneider, M., Salinas, D., and Stella, L. (2022). Deep learning for time series forecasting: Tutorial and literature survey. *ACM Computing Surveys*, 55(6):1–36.
- Challu, C., Olivares, K. G., Oreshkin, B. N., Garza, F., Mergenthaler-Canseco, M., and Dubrawski, A. (2023). N-HiTS: Neural hierarchical interpolation for time series forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 6989–6997.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, pages 785–794. ACM.
- Comisión Nacional de Energía (2026). Reporte mensual sector energético. Technical report, Gobierno de Chile.
- Coordinador Eléctrico Nacional (2025). Informe del coordinador independiente del sistema eléctrico nacional. Technical report, CEN.
- Damato, S., Rubattu, N., Azzimonti, D., and Corani, G. (2026). Intermittent time series forecasting: local vs global models. *arXiv preprint arXiv:2601.14031*.
- Duffie, J. A. and Beckman, W. A. (2013). *Solar Engineering of Thermal Processes*. John Wiley & Sons, Hoboken, NJ, 4 edition.

- El-Saieed, A. M. (2025). An adaptive transformer model for long-term time-series forecasting of temperature and radiation in photovoltaic energy generation. *Applied Computational Intelligence and Soft Computing*, 2025.
- Ember (2025). Reducing curtailment in chile: Key to unlocking the full potential of renewable energy. <https://ember-energy.org/app/uploads/2025/09/EN-Report-Reducing-curtailment-in-Chile-key-to-unlocking-the-full-potential-of-renewable-energy.pdf>.
- Energía Estratégica (2025). Alertan que los pmgd podrían enfrentar pérdidas por 7400 millones anuales si avanza la bolsa pyme en chile. <https://www.energiiaestrategica.com/alertan-que-los-pmgd-podrian-enfrentar-perdidas-por-7400-millones-anuales-si-avanza-la-bolsa-pyme-en-chile>.
- Gu, A. and Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- International Energy Agency (2023). World energy outlook 2023. Technical report, International Energy Agency, Paris.
- Khan, W., Walker, S., and Zeiler, W. (2022). Improved solar photovoltaic energy generation forecast using deep learning-based ensemble stacking approach. *Energy*, 240:122812.
- Kumari, P. and Toshniwal, D. (2021). Deep learning models for solar irradiance forecasting: A comprehensive review. *Journal of Cleaner Production*, 318:128566.
- Li, R., Wang, D., Wang, Z., Liang, S., Li, Z., Xie, Y., and He, J. (2024). Transformer approach to nowcasting solar energy using geostationary satellite data. *Applied Energy*, 353:122112.
- Lim, B., Arik, S. Ö., Loeff, N., and Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748–1764.
- López Santos, M., García-Santiago, X., Echevarría Camarero, F., Blázquez Gil, G., and Carrasco Ortega, P. (2022). Application of temporal fusion transformer for day-ahead pv power forecasting. *Energies*, 15(14):5232.
- Mellit, A., Pavan, A. M., and Lughi, V. (2021). Deep learning neural networks for short-term photovoltaic power forecasting. *Renewable Energy*, 172:276–288.

- Mishra, A. et al. (2025). Spirit: Short-term prediction of solar irradiance for zero-shot transfer learning using foundation models. *arXiv preprint arXiv:2502.10307*.
- Montero-Manso, P. and Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. *International Journal of Forecasting*, 37(4):1632–1653.
- Nie, Y., Nguyen, N. H., Sinthong, P., and Kalagnanam, J. (2023). A time series is worth 64 words: Long-term forecasting with transformers. In *International Conference on Learning Representations (ICLR)*.
- Oreshkin, B. N., Carpow, D., Chapados, N., and Bengio, Y. (2020). N-beats: Neural basis expansion analysis for interpretable time series forecasting. In *International Conference on Learning Representations (ICLR)*.
- Pan, S. J. and Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359.
- Peixeiro, M. (2022). *Time Series Forecasting in Python*. Manning Publications, Shelter Island, NY.
- Salinas, D., Flunkert, V., Gasthaus, J., and Stella, L. (2020). Deepar: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3):1181–1191.
- Schein, A. I., Popescul, A., Ungar, L. H., and Pennock, D. M. (2002). Methods and metrics for cold-start recommendations. In *Proceedings of the 25th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '02)*, pages 253–260. ACM.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30.
- Zeng, A., Chen, M., Zhang, L., and Xu, Q. (2023). Are transformers effective for time series forecasting? In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 11121–11128.
- Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., and Zhang, W. (2021). Informer: Beyond efficient transformer for long sequence time-series forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 35, pages 11106–11115.
- Zhu, Z. et al. (2023). Energy forecasting with robust, flexible, and explainable machine learning algorithms. *AI Magazine*.

Anexos

A. Repositorio del Proyecto

El código fuente completo del proyecto (pipelines de datos, entrenamiento, evaluación LOPO y generación de reportes), junto a su suite de pruebas automatizadas anti-fuga de información, se encuentra versionado en el siguiente repositorio Git:

<https://github.com/cesar-aular/tesis>

B. Métricas por Planta

La tabla siguiente reporta el rRMSE mediano (%) del roll-out de 7 días en la ventana *Raw* para las cuatro configuraciones principales, desglosado por planta evaluada en la estrategia *half*. El archivo `all_metrics_summary.csv` del repositorio contiene el detalle completo (ocho modelos, todas las ventanas, ambos horizontes y las métricas probabilísticas).

Macrozona	Planta	XGB local	XGB global	LSTM	TFT
Norte Chico	amparo_del_sol	34.9	46.8	87.8	108.8
Norte Chico	cachiyuyo_solar_2	63.5	104.6	100.2	91.1
Norte Chico	canesa_solar_i	152.1	151.7	343.5	171.5
Norte Chico	chalinga_solar	31.9	50.2	74.0	64.3
Norte Chico	illapel_5x	32.5	56.6	96.3	80.7
Norte Chico	luna_del_norte	21.7	40.6	99.7	87.0
Norte Chico	norte_chico_i	57.4	227.1	117.6	90.9
Norte Chico	parque_solar_fotovoltaico_maranon	164.9	579.5	494.0	87.6
Norte Chico	pfv_malgarida	115.3	122.0	144.7	156.1
Norte Chico	pmg_castilla	64.8	85.3	117.1	129.1
Norte Chico	pmgd_pfv_olivia	87.8	59.1	115.0	114.7
Norte Chico	pmgd_pfv_olivier	58.3	60.5	109.0	120.2
Norte Chico	pmgd_pfv_sofia	2924.7	3227.8	1688.3	1286.6
Norte Chico	sol_del_norte	21.5	40.4	77.1	94.0
Norte Chico	solar_antay	292.5	486.0	243.4	274.5
Norte Chico	solar_chuchini	83.1	103.2	134.6	158.5
Norte Chico	solar_diego_de_almagro	109.9	750.0	132.0	265.4
Norte Chico	solar_el_romero	52.4	48.5	98.0	79.6
Norte Chico	solar_esperanza	57.1	78.2	141.3	141.9
Norte Chico	solar_javiera	272.7	440.9	100.2	207.4
Norte Chico	solar_la_silla	228.6	310.1	179.4	178.2
Norte Chico	solar_las_terrazas	101.9	60.2	149.9	108.1
Norte Chico	solar_llano_de_llampos	70.3	82.2	127.3	131.6
Norte Chico	solar_psf_lomas_coloradas	165.8	190.9	193.8	170.6
Norte Chico	solar_san_andres	114.3	70.8	137.5	106.8

Macrozona	Planta	XGB local	XGB global	LSTM	TFT
Norte Chico	solar_santa_cecilia	111.9	107.5	127.6	156.8
Norte Chico	talhuen	44.2	58.8	103.7	105.5
Norte Chico	tambo_real	44.4	291.2	70.2	166.9
Norte Chico	valle_solar_este_2	34.7	52.8	100.0	87.6
Norte Chico	valle_solar_oeste_2	57.2	73.3	102.9	131.1
Norte Grande	andes_solar	50.4	44.0	83.1	72.3
Norte Grande	conejo_solar	20.9	49.1	104.9	113.0
Norte Grande	fv_bolero	183.6	539.8	376.3	273.7
Norte Grande	lalackama	17.8	25.2	85.2	104.2
Norte Grande	lalackama_2	19.1	74.2	91.6	108.4
Norte Grande	pampa_solar_norte	20.4	59.3	103.5	89.2
Norte Grande	parque_solar_finis_terrae	1873.4	3917.1	1790.4	2112.0
Norte Grande	parque_solar_pampa_camarones	344.8	178.0	184.9	192.4
Norte Grande	pfv_andes_solar_ii	73.7	168.1	154.9	159.1
Norte Grande	solar_el_aguila_i	37.1	89.1	82.3	99.1
Norte Grande	solar_jama	32.1	24.6	74.8	82.4
Norte Grande	uribe_solar	138.2	162.5	126.2	126.0
Zona Central	altos_de_til_til	118.4	127.0	188.8	202.4
Zona Central	chancon	47.3	52.9	84.8	66.0
Zona Central	chimbarongo	73.5	83.2	85.9	98.5
Zona Central	don_eugenio	48.5	55.8	73.5	72.4
Zona Central	donihue	146.3	212.4	246.7	164.7
Zona Central	el_pilpen	36.0	42.7	83.1	60.4
Zona Central	el_roble	73.0	75.9	91.1	93.9
Zona Central	el_sauce	77.5	72.2	92.7	80.1
Zona Central	fotovolt_solar_i	111.8	154.5	362.0	288.0
Zona Central	gr_santa_rosa	115.0	87.8	145.3	151.1
Zona Central	la_blanquina	156.8	250.6	226.7	210.8
Zona Central	la_frontera	68.4	61.2	122.8	91.7
Zona Central	la_lajuela	68.9	82.4	106.5	81.0
Zona Central	la_manga_i	25.6	66.9	99.5	74.3
Zona Central	las_perdices	100.6	137.5	232.9	316.6
Zona Central	laurel	145.4	131.9	279.4	326.1
Zona Central	lipangue	47.7	67.0	97.6	127.2
Zona Central	los_libertadores	25.9	31.8	67.9	92.6
Zona Central	luna	63.0	67.4	217.3	418.0
Zona Central	peralillo	54.6	57.0	81.3	63.6
Zona Central	pfv_jose_soler_mallafre	106.5	112.6	125.9	116.5
Zona Central	pfv_marchigue_ii	37.4	48.7	81.3	61.6
Zona Central	pfv_santa_adriana	160.0	159.7	289.4	299.0
Zona Central	pfv_villa_seca	60.7	51.4	80.1	78.5
Zona Central	pirque	92.5	94.7	241.8	141.0

Macrozona	Planta	XGB local	XGB global	LSTM	TFT
Zona Central	pmgd_antonia_solar	88.6	82.1	258.8	139.1
Zona Central	pmgd_fv_barcelona	165.2	195.2	189.4	139.0
Zona Central	portezuelo	44.8	46.7	75.5	78.0
Zona Central	psf_lo_sierra	38.6	69.2	115.3	117.6
Zona Central	pv_ranguil	175.3	267.6	416.0	272.5
Zona Central	quilapilun	39.9	42.1	75.4	81.4
Zona Central	rla_solar	98.7	59.3	173.0	155.1
Zona Central	santiago_solar	34.5	64.0	76.7	77.5
Zona Central	solar_loma_los_colorados	118.7	137.5	110.9	136.5
Zona Central	talca	159.0	439.1	484.2	321.9
Zona Central	tricahue_2	148.9	92.6	141.0	119.2
Zona Central	valle_de_la_luna_ii	43.8	44.5	75.2	93.6
Zona Central	villa_prat	56.2	58.6	85.2	74.0
Zona Sur	las_codornices	80.9	81.0	125.6	108.5

C. Registro de Imputación de Variables Exógenas

Resumen del registro de imputación de la capa Silver (`imputation_log.csv`): horas-planta imputadas por variable meteorológica y macrozona. Cada imputación queda además señalizada al modelo mediante la variable indicadora `_is_imputed` correspondiente. La generación (variable objetivo) no aparece en este registro porque jamás se imputa.

Variable imputada	Norte Chico	Norte Grande	Zona Central	Zona Sur	Total
humedad-relativa	36,183	6,495	57,156	1,299	101,133
radiacion-global-instantanea	38,917	7,227	57,182	1,358	104,684
temp-aire-seco	36,183	6,495	57,156	1,299	101,133
Total	111,283	20,217	171,494	3,956	306,950

Tabla C.12: Horas-planta imputadas en la capa Silver por variable exógena y macrozona.

D. Hallazgos de Calidad de Datos

Durante la construcción del corpus se documentaron los siguientes hallazgos, resueltos en la capa Bronze del pipeline:

- **Agregación multi-unidad:** centrales con múltiples unidades físicas reportando bajo el mismo identificador (ej. PFV Jama: dos unidades, 51 MW combinados) se con-

solidaron sumando la generación por hora. Sin esta corrección, la serie subcontaba aproximadamente la mitad de la producción real de la central.

- **Duplicación por reejecución:** el modo de escritura incremental de la capa Bronze podía duplicar el dataset completo en reejecuciones forzadas (factor de hasta $3,17\times$ detectado); se corrigió limpiando las salidas previas y añadiendo deduplicación defensiva aguas abajo.
- **Transiciones de horario de verano (DST):** la hora repetida del primer domingo de abril se colapsa de forma segura (en generación solar corresponde a horas nocturnas de producción nula).
- **Rampas de puesta en marcha:** 33 de las 94 plantas evaluadas presentan períodos iniciales de generación nula superiores a 24 horas (hasta semanas), motivando el análisis de sensibilidad Raw/Operacional del Capítulo V.
- **Sentinelas y fechas fuera de rango:** los registros meteorológicos con valor –9999 se descartan y las fechas se restringen al período 2014–2024 antes del parseo.